漸近統計勉強会

びしゅ @Bergerac_lim

2026 年 4 月 17 日

目次

1 Introduction 3

2 Stochastic Convergence 4
2.1 Basic Theory 4
2.2 Stochastic o and O Symbols 13
2.3 Characteristic Functions 14
2.4 Almost-Sure Representation 19
2.5 Convergence of Moments 19
2.6 Convergence-Determining Class 21
2.7 Law of the Iterated Logarithm 21
2.8 Lindeberg-Feller Theorem 22
2.9 Convergence in Total Variation 23

3 What is Statistical Estimation? 25
3.1 Statistical Experiments 25
3.2 What is a Good Estimator? 26

4 How Can We Construct a Good Estimator? 28
4.1 Maximum Likelihood Estimation 28
4.2 M-estimation and Z-estimation 31

5 What is the Best Estimator? 36
5.1 Hodge's Counter Example 36
5.2 To the Efficiency Theory 37

6 Contiguity 40
6.1 Likelihood Ratios 40

6.2 Contiguity 41

7 Local Asymptotic Normality 48
7.1 Localized Statistical Experiments 48
7.2 Local Asymptotic Normality 48
7.3 Convergence to a Normal Experiment 55

8 Efficiency of Estimators 59
8.1 Regularity of Estimators 59
8.2 Lower Bound for Experiments 62
8.3 Convolution-Based Efficiency Bounds 64
8.4 Risk-Based Efficiency Bounds 68
8.5 Achieving the Bound 69

Interlude: Statistical Inference $\times$ Machine Learning 73

9 Debiased Inference: Efficiency Theory 75
9.1 Data $\cdot$ Model $\cdot$ Target 75
9.2 Tangent Space and LAN 78
9.3 Pathwise-Differentiability 81
9.4 Efficiency Bounds for Regular Estimators 84
9.5 Achieving the Bounds 86

10 Debiased Inference: Methodology 88
10.1 Plug-in Estimation 88
10.2 Deriving the EIF 90
10.3 One-Step Estimation 93

1 Introduction

本稿は, van der Vaart (2000), Asymptotic Statistics の勉強会ノートである.

本稿でフォローするのは, 2 章から 8 章までと 25 章の内容である. ただし, 2 章および 6 章から 8 章まではおおむね Asymptotic Statistics の通りに進んでいくが, そのほかの章は別の資料を参照しつつオリジナルの方針で進む. 収束概念や頻出定理をフォローしつつ, パラメトリックモデルの推測に関する一般論, 統計的実験の列に関する局所漸近正規性や情報量下限, セミパラメトリックモデルにおける有効性概念を整理することを目標とし, その他の内容には深入りしない.

2 Stochastic Convergence

本章では, 確率分布に基づく収束概念と重要定理たちをフォローする. まずは各収束概念の定義を確認したのち, 数理統計において特に重要な分布収束について, その同値な言いかえを示す. さらに, 収束が連続変換で保たれることや, 周辺分布での収束概念が同時分布について引き継がれるための条件, 分布の収束を特性関数に押し付ける手筋についても考える. その他, モーメントの収束や全変動の収束などのトピックにも触れる.

2.1 Basic Theory

まずは, 確率変数列の収束概念について振り返る. 断りがなければ, 確率変数はある確率空間 $(\Omega, \mathcal{F}, \mathrm{P})$ 上に定まっているものとする.

Definition 2.1: 確率変数列の収束

X_n, X は $\mathbb{R}^k$-値確率変数とする.
(a) $\{X_n\}$ が X に**概収束** (almost-sure converegence) するとは,

$$\mathrm{P}\left(\lim_{n\to\infty} d(X_n, X) = 0\right) = 1$$

をみたすことをいい, $X_n \xrightarrow{a.s.} X$ とかく.
(b) $\{X_n\}$ が X に**確率収束** (convergence in probability) するとは,

$$^{\forall}\varepsilon > 0, \quad \lim_{n\to\infty} \mathrm{P}\left(d(X_n, X) < \varepsilon\right) = 1$$

をみたすことをいい, $X_n \xrightarrow{p} X$ とかく.
(c) $\{X_n\}$ が X に**分布収束** (convergence in distribution) するとは, X の分布関数の任意の連続点 $x \in \mathbb{R}^k$ に対して,

$$\mathrm{P}\left(X_n \le x\right) \to \mathrm{P}\left(X \le x\right)$$

をみたすことをいい, $X_n \xrightarrow{d} X$ とかく.

Example 2.1: CLT

$\mathbb{R}^k$-値確率変数 Y の i.i.d. コピー $\{Y_n\}$ について, $\mathrm{E}[|Y|] < \infty$ ならば, $\bar{Y}_n \xrightarrow{a.s.} \mathrm{E}[Y]$ が従う (大数の強法則). さらに, $\mathrm{E}[|Y|^2] < \infty$ ならば,

$$\sqrt{n}(\bar{Y}_n - \mathrm{E}[Y]) \xrightarrow{d} N(0, \mathrm{Cov}[Y]).$$

が従う (中心極限定理).

分布収束については, いくつかの同値な言いかえが存在することが知られている. 次の補題はそれらをまとめたものである.

Lemma 2.2: Portmanteau

X_n, X は $\mathbb{R}^k$-値確率変数とする. 以下の主張は同値である.
(i)$X_n \xrightarrow{d} X$.
(ii) 任意の有界連続関数 $f : \mathbb{R}^k \to \mathbb{R}$ に対して, $\mathrm{E}[f(X_n)] \to \mathrm{E}[f(X)]$.
(iii) 任意の有界 Lipschitz 連続関数 $f : \mathbb{R}^k \to \mathbb{R}$ に対して, $\mathrm{E}[f(X_n)] \to \mathrm{E}[f(X)]$.
(iv) 任意の非負連続関数 $f : \mathbb{R}^k \to \mathbb{R}$ に対して, $\liminf_{n\to\infty} \mathrm{E}[f(X_n)] \geq \mathrm{E}[f(X)]$.
(v) 任意の開集合 $G \subset \mathbb{R}^k$ に対して, $\liminf_{n\to\infty} \mathrm{P}(X_n \in G) \geq \mathrm{P}(X \in G)$.
(vi) 任意の閉集合 $F \subset \mathbb{R}^k$ に対して, $\limsup_{n\to\infty} \mathrm{P}(X_n \in F) \leq \mathrm{P}(X \in F)$.
(vii) 任意の $B \subset \mathbb{R}^k$ $(\mathrm{P}(X \in \delta B) = 0)$ に対して[a] , $\lim_{n\to\infty} \mathrm{P}(X_n \in B) = \mathrm{P}(X \in B)$.

[a] このような集合 B を continuity set という.

Proof. 次の要領で示す:

$$\begin{aligned}(\mathrm{i}) \Rightarrow &(\mathrm{ii}) \Rightarrow (\mathrm{iii}) \Rightarrow (\mathrm{v}) \Rightarrow (\mathrm{vii}) \Rightarrow (\mathrm{i}) \\ &(\mathrm{ii}) \Leftrightarrow (\mathrm{iv}),\ (\mathrm{v}) \Leftrightarrow (\mathrm{vi})\end{aligned}$$

(i)⇒(ii): まず, X の分布関数 $F^X(\cdot) = \mathrm{P}(X \leq \cdot)$ が連続であると仮定して示す. このとき, (i) より, 任意の長方形 $I \subset \mathbb{R}^k$ に対して

$$\mathrm{P}(X_n \in I) \to \mathrm{P}(X \in I) \tag{2.1}$$

となる[*1]. ここで, $\varepsilon > 0$ を任意にとって fix する. I を十分大きくとって, $\mathrm{P}(X \notin I) < \epsilon$ となるようにする. f は I 上で一様連続であることに注意すると, さらにその I を有限個の長方形に $I = \bigsqcup I_j$ と分割して, 各 I_j 上で f の変動が ε より小さくなるようにできる. つまり, ${}^\forall j$, ${}^\forall x, y \in I_j, |f(x) - f(y)| < \varepsilon$ とできる. ${}^\forall x_j \in I_j$ を任意に fix し, $f_\varepsilon(u) = \sum_j f(x_j)\mathbb{1}_{I_j}(u)$ とおくと, I 上で $|f - f_\varepsilon| < \varepsilon$ が成り立つ. f は有界であるから, (ε によらず) ある $M > 0$ が存在して $|f| \leq M$ とできるので,

$$\begin{aligned}|\mathrm{E}[f(X_n)] - \mathrm{E}[f_\varepsilon(X_n)]| &= |\mathrm{E}[(f - f_\varepsilon)(X_n)]| \\ &\leq |\mathrm{E}[(f - f_\varepsilon)(X_n); I]| + |\mathrm{E}[(f - f_\varepsilon)(X_n); I^c]| \\ &\leq \varepsilon + 2M\mathrm{P}(X_n \notin I).\end{aligned}$$

同様にして,

$$|\mathrm{E}[f(X)] - \mathrm{E}[f_\varepsilon(X)]| \leq \varepsilon + 2M\mathrm{P}(X \notin I).$$

[*1] 分布関数が連続なとき, 長方形に乗っている確率は分布関数の 2^k 個の点での値の足し引きで表現することができる.

さらに,

$$|\mathrm{E}[f_\varepsilon(X_n)] - \mathrm{E}[f_\varepsilon(X)]| \le \sum_j |\mathrm{P}(X_n \in I_j) - \mathrm{P}(X \in I_j)||f(x_j)| \to 0. \tag{2.2}$$

以上の評価を併せると,

$$\begin{aligned}
&\limsup_{n\to\infty} |\mathrm{E}[f(X_n)] - \mathrm{E}[f(X)]| \\
&\le \limsup_{n\to\infty} |\mathrm{E}[f(X_n)] - \mathrm{E}[f_\varepsilon(X_n)]| + \limsup_{n\to\infty} |\mathrm{E}[f_\varepsilon(X_n)] - \mathrm{E}[f_\varepsilon(X)]| \\
&\quad + \limsup_{n\to\infty} |\mathrm{E}[f_\varepsilon(X)] - \mathrm{E}[f(X)]| \\
&\le 2\varepsilon + 4M\mathrm{P}(X \notin I) \le (2+4M)\varepsilon.
\end{aligned}$$

ただし, 収束 (2.1) に注意する. ε はいくらでも小さくとれるので, (ii) が示された.

$F^X(\cdot) = \mathrm{P}(X \le \cdot)$ が連続であるとは限らない場合の議論は略. F^X の不連続点が高々可算個しか存在しない (Froda の定理) ことに注目して示す.

(ii)⇒(iii): 自明.

(iii)⇒(v): Lipschitz 連続関数列 $\{f_m\}$ が存在して, $0 \le f_m \uparrow \mathbb{1}_G$ とできることに注意する. たとえば, $f_m(x) = (md(x, G^c)) \wedge 1$ とおけばよい. 収束は $x \in G$ あるいは $x \in G^c$ で場合分けすればただちにわかり,

$$|f_m(x) - f_m(y)| \le md(x,y) \quad ({}^\forall x, y)$$

より Lipschitz 連続性もすぐにわかる. 各 m について, (iii) より

$$\liminf_{n\to\infty} \mathrm{P}(X_n \in G) \ge \liminf_{n\to\infty} \mathrm{E}[f_m(X_n)] \ge \mathrm{E}[f_m(X)].$$

$m \to \infty$ の単調収束定理によって, (v) を得る.

(v)⇔(vi): 補集合をとればよい. (⇒) は,

$$\begin{aligned}
\limsup_{n\to\infty} \mathrm{P}(X_n \in F) &= \limsup_{n\to\infty} (1 - \mathrm{P}(X_n \in F^c)) \\
&= 1 - \liminf_{n\to\infty} \mathrm{P}(X_n \in F^c) \\
&\le 1 - \mathrm{P}(X \in F^c) = \mathrm{P}(X \in F).
\end{aligned}$$

(⇐) も同様である.

(v) and (vi)⇒(vii): まず, 次の式に注目する.

$$\begin{aligned}
\mathrm{P}(X \in B^\circ) &\le \liminf_{n\to\infty} \mathrm{P}(X_n \in B^\circ) \le \limsup_{n\to\infty} \mathrm{P}(X_n \in \bar{B}) \\
&\le \mathrm{P}(X \in \bar{B}) = \mathrm{P}(X \in B^\circ) + \mathrm{P}(X \in \delta B)
\end{aligned}$$

もしも $\mathrm{P}(X \in \delta B) = 0$ ならば, 上の不等号はすべて等号になる. つまり,

$$\liminf_{n\to\infty} \mathrm{P}(X_n \in B^\circ) = \limsup_{n\to\infty} \mathrm{P}(X_n \in \bar{B}) = \mathrm{P}(X \in B).$$

このことと, $\liminf_{n\to\infty} \mathrm{P}(X_n \in B^\circ) \le \liminf_{n\to\infty} \mathrm{P}(X_n \in B)$, $\limsup_{n\to\infty} \mathrm{P}(X_n \in B) \le \limsup_{n\to\infty} \mathrm{P}(X_n \in \bar{B})$ をあわせて,

$$\liminf_{n\to\infty} \mathrm{P}(X_n \in B) = \limsup_{n\to\infty} \mathrm{P}(X_n \in B) = \mathrm{P}(X \in B).$$

(vii)⇒(i): x が F^X の連続点のとき,

$$\begin{aligned}\mathrm{P}(X \in \delta((-\infty, x])) &= \mathrm{P}(X \in \{x\}) \\ &= \mathrm{P}(X \le x) - \lim_{u\uparrow x} \mathrm{P}(X \le u) = 0.\end{aligned}$$

これにより (vii) が使えて (i) を得る.

(ii)⇔(iv): (Exercise)

(⇒): 任意の非負連続関数 g に対して, $g_m = g \wedge m$ とおくと, これは有界連続関数であり, $g_m \uparrow g$ である. 各 m で (ii) を用いれば,

$$\liminf_{n\to\infty} \mathrm{E}[g(X_n)] \ge \liminf_{n\to\infty} \mathrm{E}[g_m(X_n)] \ge \mathrm{E}[g_m(X)].$$

$m \to \infty$ の単調収束定理によって, (iv) を得る.

(⇐): (iv)⇒(v) を示せばよい ((v)⇒(ii) はすでに得られている). 上の (iii)⇒(v) の証明と同じ f_m を使う. これは非負連続かつ $f_m \uparrow \mathbb{1}_G$ であり, 各 m で (iv) を用いると

$$\begin{aligned}\liminf_{n\to\infty} \mathrm{P}(X_n \in G) &= \liminf_{n\to\infty} \mathrm{E}[\mathbb{1}_G(X_n)] \\ &\ge \liminf_{n\to\infty} \mathrm{E}[f_m(X_n)] \ge \mathrm{E}[f_m(X)]\end{aligned}$$

$m \to \infty$ の単調収束定理によって, (v) を得る. □

Theorem 2.3: Continuous mapping

X_n, X は $\mathbb{R}^k$-値確率変数とする. $g : \mathbb{R}^k \to \mathbb{R}^m$ は $C \subset \mathbb{R}^k$ 上で連続であり, $\mathrm{P}(X \in C) = 1$ であるとする.

(i) $X_n \xrightarrow{d} X \;\Rightarrow\; g(X_n) \xrightarrow{d} g(X)$.

(ii) $X_n \xrightarrow{p} X \;\Rightarrow\; g(X_n) \xrightarrow{p} g(X)$.

(iii) $X_n \xrightarrow{a.s.} X \;\Rightarrow\; g(X_n) \xrightarrow{a.s.} g(X)$.

Proof. (i) Portmanteau を用いる. 任意に閉集合 $F \subset \mathbb{R}^k$ を fix し $\mathrm{P}(g(X_n) \in F) = \mathrm{P}(X_n \in g^{-1}(F))$ を考える. いま,

$$g^{-1}(F) \subset \overline{g^{-1}(F)} \subset g^{-1}(F) \cup C^c$$

が成り立つ. 2 つ目の包含は次のようにしてわかる: ${}^\forall x \in \overline{g^{-1}(F)}$, ${}^\exists(x_m)$ s.t. $x_m \to x$ かつ $g(x_m) \in F$. もし $x \in C$ ならば $g(x_m) \to g(x) \in F$ であり, さもなくば $x \in C^c$ である. Portmanteau より,

$$\begin{aligned}\limsup_{n\to\infty} \mathrm{P}(X_n \in g^{-1}(F)) &\le \limsup_{n\to\infty} \mathrm{P}(X_n \in \overline{g^{-1}(F)}) \le \mathrm{P}(X \in \overline{g^{-1}(F)}) \\ &\le \mathrm{P}(X \in g^{-1}(F) \cup C^c) = \mathrm{P}(X \in g^{-1}(F)).\end{aligned}$$

(ii) 任意に $\varepsilon > 0$ を fix する．$\delta > 0$ に対し，

$$B_\delta := \{x \in \mathbb{R}^k \,;\, {}^\exists y \in \mathbb{R}^k \ \text{ s.t. } \ d(x,y) < \delta \ \text{ and } \ d(g(x), g(y)) > \varepsilon\}$$

とおく．このとき，

$$X \notin B_\delta \ \text{ and } \ d(g(X_n), g(X)) > \varepsilon \Rightarrow d(X_n, X) \geq \delta.$$

したがって，

$$\begin{aligned}
&\mathrm{P}(d(g(X_n), g(X)) > \varepsilon) \\
&\quad = \mathrm{P}(d(g(X_n), g(X)) > \varepsilon \ \text{ and } \ X \in B_\delta) + \mathrm{P}(d(g(X_n), g(X)) > \varepsilon \ \text{ and } \ X \notin B_\delta) \\
&\quad \leq \mathrm{P}(X \in B_\delta) + \mathrm{P}(d(X_n, X) \geq \delta) \\
&\quad = \mathrm{P}(X \in B_\delta \cap C) + \mathrm{P}(d(X_n, X) \geq \delta).
\end{aligned}$$

任意の固定された $\delta > 0$ に対して $n \to \infty$ で右辺第 2 項は 0 に収束し，$\delta \downarrow 0$ で $B_\delta \cap C \downarrow \emptyset$ より第 1 項もいくらでも小さくできる．
(iii) g の連続性の定義より明らか． □

任意の確率変数 X に対して次が成り立つ．

$${}^\forall \varepsilon > 0, {}^\exists M > 0 \ \text{ s.t. } \ \mathrm{P}(|X| > M) < \varepsilon.$$

このことが確率変数の族について一様に成り立つという性質は非常に有用である．

Definition 2.2: Tightness

確率変数の族 $\{X_\alpha \,;\, \alpha \in A\}$ が **tight** である (あるいは**緊密**である) とは，次が成り立つことをいう:

$${}^\forall \varepsilon > 0, {}^\exists M > 0 \ \text{ s.t. } \ \sup_{\alpha \in A} \mathrm{P}(|X_\alpha| > M) < \varepsilon.$$

つまり，$\{X_\alpha \,;\, \alpha \in A\}$ が「ほとんど」あるコンパクト集合に収まるという条件が tightness である．次の定理は Heine-Borel の定理の確率変数列への一般化を与える．

Theorem 2.4: Prohorov

X_n, X は $\mathbb{R}^k$-値確率変数とする．
(i) $\{X_n\}$ が X に分布収束するとき，$\{X_n\}$ は tight である．
(ii) $\{X_n\}$ が tight であるとき，ある X とある部分列 $\{n_j\} \subset \{n\}$ が存在して，$\{X_{n_j}\}$ は X に分布収束する．

Proof. (i) 任意に $\varepsilon > 0$ を fix し，$M > 0$ を十分大きくとって $\mathrm{P}(|X| \geq M) < \varepsilon$ とする．Portmanteau より

$$\limsup_{n \to \infty} \mathrm{P}(|X_n| \geq M) \leq \mathrm{P}(|X| \geq M) < \varepsilon.$$

つまり,

$$^{\exists}N \in \mathbb{N} \ \text{ s.t. } \ ^{\forall}n \geq N,\ \mathrm{P}(|X_n| \geq M) < 2\varepsilon.$$

$n = 1, 2, \ldots, N-1$ でも同じことが成り立つように, 必要に応じて $M > 0$ を大きくとり直せば,

$$^{\forall}\varepsilon > 0, ^{\exists}M > 0 \ \text{ s.t. } \ \sup_{n\in\mathbb{N}} \mathrm{P}(|X_n| > M) < 2\varepsilon.$$

を得る[*2] .

(ii) Helly の補題 (後述) より, 分布関数の部分列 $\{F_{n_j}\}$ が存在して, ”defective”なある分布関数[*3] F に (F の連続点上で) 収束する. したがって, F が実は proper な分布関数であることを示せば十分. すなわち,

$$\begin{aligned}&(a)\ F(x) \to 1 \ \ (x \to \infty),\\ &(b)\ F(x) \to 0 \ \ (x_i \to -\infty, i \in \{1, 2, \ldots, k\})\end{aligned}$$

を示したい. $\{X_n\}$ は tight であるから,

$$^{\forall}\varepsilon > 0,\ ^{\exists}M \in \mathbb{R}^k \ \text{ s.t. } \ \inf_n F_n(M) > 1 - \varepsilon.$$

特に M は F の連続点からとれる. したがって,

$$^{\forall}\varepsilon > 0,\ ^{\exists}M \in \mathbb{R}^k \ \text{ s.t. } \ F(M) = \lim_{j\to\infty} F_{n_j}(M) > 1 - \varepsilon.$$

すなわち, (a) が得られた. (b) も同様にして示せる ((b) の否定を考えると $\{X_n\}$ が tight であることに矛盾する). □

Lemma 2.5: Helly

$\{X_n\}$ に対し, その分布関数列 $\{F_n\}$ のある部分列 $\{F_{n_j}\}$ と defective な分布関数 F が存在して, $\{F_n\}$ は F の連続点上で収束する.
(証明略)

Example 2.6: L^p-bounded ⇒ tight

ある $p > 0$ について $\{X_n\}$ が L^p-有界, すなわち $\sup_n E[|X_n|^p] < \infty$ のとき, $\{X_n\}$ は tight である. 実際, Markov の不等式より,

$$\sup_n \mathrm{P}(|X_n| > M) \leq \sup_n \frac{E[|X_n|^p]}{M^p}.$$

M を大きくすることで, 右辺はいくらでも小さくすることができる.

[*2] このような M のとり直しを考えると, tightness の証明は, $^{\forall}\varepsilon > 0,\ ^{\exists}M > 0 \ \text{ s.t. } \ \limsup_{n\to\infty} \mathrm{P}(|X_n| > M) \leq \varepsilon$ を示せば十分であることに注意する. 今後は断りなくこのことを用いる.

[*3] 下の (a),(b) がどちらも成り立っているとは限らない分布関数をいう.

各収束概念の関係や, 収束が同時分布に関して閉じるための条件については, 次の定理で与えられる.

Theorem 2.7

X_n, X, Y_n は $\mathbb{R}^k$-値確率変数とする.
(i) $X_n \xrightarrow{a.s.} X \;\Rightarrow\; X_n \xrightarrow{p} X$.
(ii) $X_n \xrightarrow{p} X \;\Rightarrow\; X_n \xrightarrow{d} X$.
(iii) $X_n \xrightarrow{d} c$: const. $\;\Rightarrow\; X_n \xrightarrow{p} c$.
(iv) $X_n \xrightarrow{d} X$ and $d(X_n, Y_n) \xrightarrow{p} 0 \;\Rightarrow\; Y_n \xrightarrow{d} X$. [a]
(v) $X_n \xrightarrow{d} X$ and $Y_n \xrightarrow{p} c$: const. $\;\Rightarrow\; (X_n, Y_n) \xrightarrow{d} (X, c)$.
(vi) $X_n \xrightarrow{p} X$ and $Y_n \xrightarrow{p} Y \;\Rightarrow\; (X_n, Y_n) \xrightarrow{p} (X, Y)$.

[a] $d(X_n, Y_n) \xrightarrow{p} 0$ が成り立つとき, X_n と Y_n は**漸近同等** (asymptotically equivalent) であるという. つまり, 「漸近同等な 2 つの確率変数について, 片方が分布収束するならばもう片方も同じ収束先に分布収束する」.

Proof. (i) 任意に $\varepsilon > 0$ を fix する. 仮定より, $\mathrm{P}(\limsup_{n\to\infty}\{d(X_n, X) > \varepsilon\}) = 0$ であることに注意する. すなわち, Fatou の補題より,

$$\limsup_{n\to\infty} \mathrm{P}(\{d(X_n, X) > \varepsilon\}) \le \mathrm{P}(\limsup_{n\to\infty}\{d(X_n, X) > \varepsilon\}) = 0.$$

(iv) 任意の有界 Lipschitz 連続関数 f を fix する. すなわち, ある $M, L > 0$ が存在して

$$|f| < M \;\text{ and }\; |f(x) - f(y)| < Ld(x, y).$$

任意に $\varepsilon > 0$ を fix すると,

$$\begin{aligned}
&|\mathrm{E}[f(Y_n)] - \mathrm{E}[f(X_n)]| \\
&\le \mathrm{E}[|f(Y_n) - f(X_n)|] \\
&= \mathrm{E}[|f(Y_n) - f(X_n)|\,;\, \{d(X_n, Y_n) \ge \varepsilon\}] + \mathrm{E}[|f(Y_n) - f(X_n)|\,;\, \{d(X_n, Y_n) < \varepsilon\}] \\
&\le 2M\mathrm{P}(d(X_n, Y_n) \ge \varepsilon) + L\varepsilon.
\end{aligned}$$

したがって,

$$\begin{aligned}
&\limsup_{n\to\infty} |\mathrm{E}[f(Y_n)] - \mathrm{E}[f(X)]| \\
&\qquad \le \limsup_{n\to\infty} |\mathrm{E}[f(Y_n)] - \mathrm{E}[f(X_n)]| + \limsup_{n\to\infty} |\mathrm{E}[f(X_n)] - \mathrm{E}[f(X)]| < L\varepsilon.
\end{aligned}$$

(ii) $d(X_n, X) \xrightarrow{p} 0$ と $X \xrightarrow{d} X$ より, (iv) を用いればしたがう.
(iii) 点 $c \in \mathbb{R}^k$ の ε-開球を $\mathrm{ball}(c, \varepsilon)$ とかく. Portmanteau より, 任意の $\varepsilon > 0$ に対して

$$\begin{aligned}
\limsup_{n\to\infty} \mathrm{P}(d(X_n, c) \ge c) &= \limsup_{n\to\infty} \mathrm{P}(X_n \in \mathrm{ball}(c, \varepsilon)^c) \\
&\le \mathrm{P}(c \in \mathrm{ball}(c, \varepsilon)^c) = 0.
\end{aligned}$$

(v) $d((X_n, Y_n), (X_n, c)) = d(Y_n, c) \xrightarrow{p} 0$ より, $(X_n, c) \xrightarrow{d} (X, c)$ を示せば十分である. 任意の有界連続関数 $(x, y) \mapsto f(x, y)$ に対し, $y = c$ を fix した関数 $x \mapsto f(x, c)$ も有界連続関数であるから, 仮定と Portmanteau より,

$$|\mathrm{E}[f(X_n, c)] - \mathrm{E}[f(X, c)]| \to 0.$$

(vi) $d((x_1, y_1), (x_2, y_2)) \leq d(x_1, x_2) + d(y_1, y_2)$ より, 任意の $\varepsilon > 0$ に対して,

$$\begin{aligned}
\mathrm{P}(d((X_n, Y_n), (X, Y)) > \varepsilon) &\leq \mathrm{P}(d(X_n, X) + d(Y_n, Y) > \varepsilon) \\
&\leq \mathrm{P}\left(d(X_n, X) > \frac{\varepsilon}{2}\right) + \mathrm{P}\left(d(Y_n, Y) > \frac{\varepsilon}{2}\right) \\
&\to 0.
\end{aligned}$$

以上で定理の主張がすべて示された. □

この定理の (v) と連続写像定理の合わせ技は便利である. すなわち, もし $X_n \xrightarrow{d} X, Y_n \xrightarrow{p} c$: const. ならば, 連続関数 g について,

$$g(X_n, Y_n) \xrightarrow{d} g(X, c)$$

が得られる. g として和や積を考えると次の補題がしたがう.

Lemma 2.8: Slutsky

X_n, Y_n は確率変数とする. $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{p} c$: const. ならば,
(i) $X_n + Y_n \xrightarrow{d} X + c$.
(ii) $Y_n X_n \xrightarrow{d} cX$.
(iii) Y_n^{-1} が a.s. で存在して $c \neq 0$ のとき, $Y_n^{-1} X_n \xrightarrow{d} c^{-1} X$.
ただし, X_n, Y_n の次元は整合的とする.

Example 2.9: t-statistic

$\{Y_n\}$ は i.i.d. とし, $\mathrm{E}[Y_1] = 0, \mathrm{E}[Y_1^2] < \infty$ とする. t-統計量

$$t_n = \sqrt{n}\frac{\bar{Y}_n}{S_n}, \quad S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(Y_i - \bar{Y}_n)^2$$

について, $t_n \xrightarrow{d} N(0, 1)$ が成り立つ.
このことは次のようにしてわかる. まず, CLT より $\sqrt{n}\bar{Y}_n \xrightarrow{d} N(0, \mathrm{Var}[Y_1])$ がしたがう.
また,

$$\begin{aligned}
S_n^2 &= \frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \bar{Y}_n)^2\right\} = \frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}Y_i^2 - (\bar{Y}_n)^2\right\} \\
&\xrightarrow{p} 1 \times \{\mathrm{E}[Y_1^2] - (\mathrm{E}[Y_1])^2\} = \mathrm{Var}[Y_1].
\end{aligned}$$

このことと Slutsky の補題から主張を得る.

Example 2.10: Confidence intervals

ある 1 次元ターゲットパラメータ θ とある推定量の列 S_n, T_n について,

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \sigma^2), \quad S_n^2 \xrightarrow{p} \sigma^2$$

が成り立っているとする. このとき, ランダムな区間 $[T_n - \frac{S_n}{\sqrt{n}} z_\alpha, T_n + \frac{S_n}{\sqrt{n}} z_\alpha]$ は, (漸近的に) 有意水準 $1 - 2\alpha$ の信頼区間となる. 実際, Slutsky の補題より

$$\begin{aligned}
\mathrm{P}\left(\theta \in \left[T_n - \frac{S_n}{\sqrt{n}} z_\alpha, T_n + \frac{S_n}{\sqrt{n}} z_\alpha\right]\right) &= \mathrm{P}\left(-\frac{S_n}{\sqrt{n}} z_\alpha \le T_n - \theta \le \frac{S_n}{\sqrt{n}} z_\alpha\right) \\
&= \mathrm{P}\left(-z_\alpha \le \frac{\sqrt{n}(T_n - \theta)}{S_n} \le z_\alpha\right) \\
&\to P(Z \in [-z_\alpha, z_\alpha]), \quad Z \sim N(0, 1).
\end{aligned}$$

Coffee Break

Theorem 2.7 からもわかるように, 一般に, 定数に確率収束する項が統計量に混ざっていても, それ自体は極限の議論に対して本質的に影響することはあまりなく, その部分を収束先の定数で置き換えて議論を進めてしまっても結果的には問題ない場合が多い. もちろん実際には厳密な議論が必要ではあるが, ともかく「十分大きな n でほぼ定数の項を見つけて除き, その他の部分の漸近挙動に注目する」という手筋に慣れると, 上の例も自明に感じられると思われる. ほかにも, MLE の漸近正規性の証明において, スコア関数の中心極限定理をフィッシャー情報行列でスケーリングする際にこの手筋があらわれる.

$X_n \xrightarrow{d} X$ で, X の分布関数が連続であるとき, 任意の x で $\mathrm{P}(X_n \le x) \to \mathrm{P}(X \le x)$ となる. 実は, この収束は x に関して一様に成り立つ.

Lemma 2.11: Glivenko-Cantelli

X_n, X は $\mathbb{R}^k$-値確率変数で, $X_n \xrightarrow{d} X$ とする. X の分布関数が連続であるならば,

$$\sup_x |\mathrm{P}(X_n \le x) - \mathrm{P}(X \le x)| \to 0.$$

Proof. まずは 1 次元の場合を考える. $K \in \mathbb{N}$ を fix し, $F = F^X$ の連続性より,

$$-\infty = x_0 < x_1 < \cdots < x_K = \infty, \quad F(x_i) = \frac{i}{K}$$

となるようにできて, 任意の $x \in [x_{i-1}, x_i]$ に対して,

$$\begin{aligned}
F_n(x) - F(x) &\le F_n(x_i) - F(x_{i-1}) = F_n(x_i) - F(x_i) + \frac{1}{K} \\
F_n(x) - F(x) &\ge F_n(x_{i-1}) - F(x_i) = F_n(x_{i-1}) - F(x_{i-1}) + \frac{1}{K}
\end{aligned}$$

すなわち, 任意の x に対して,

$$|F_n(x) - F(x)| \leq \sup_{i=0,1,\ldots,K} |F_n(x_i) - F(x_i)| + \frac{1}{K}.$$

fix された K ごとに右辺第 1 項は $n \to \infty$ で 0 に収束する. $K \to \infty$ とすれば主張を得る.

2 次元以上の場合には, 対角線を上と同様の方法で K 分割して有限個の長方形を考え, $|F_n(x) - F(x)|$ を抑えればよい. □

2.2 Stochastic o and O Symbols

0 に確率収束する確率変数列を略して $o_p(1)$ とかき, tight な確率変数列を略して $O_p(1)$ とかく. より一般に, 確率変数列 $\{R_n\}$ について

$$\begin{aligned} X_n = o_p(R_n) &:\Leftrightarrow X_n = Y_n R_n \ \text{ and } \ Y_n = o_p(1), \\ X_n = O_p(R_n) &:\Leftrightarrow X_n = Y_n R_n \ \text{ and } \ Y_n = O_p(1). \end{aligned}$$

これらの記号について, 以下の関係が成り立つ:

$$\begin{aligned} o_p(1) + o_p(1) &= o_p(1) \\ O_p(1) + O_p(1) &= O_p(1) \\ o_p(1)O_p(1) &= o_p(1) \\ (1 + o_p(1))^{-1} &= O_p(1) \\ o_p(R_n) &= R_n o_p(1) \\ O_p(R_n) &= R_n O_p(1) \\ o_p(O_p(1)) &= o_p(1). \end{aligned}$$

Stochastic order 記法は, 通常のオーダー記法と同様に左から右に読む (左右対称ではない[*4]).

Lemma 2.12: Stochastic order は関数の連続率を引き継ぐ

関数 $R : C \to \mathbb{R}$ $(0 \in C \subset \mathbb{R}^k)$ は $R(0) = 0$ をみたすとし, X_n は C-値確率変数で $X_n = o_p(1)$ とする. このとき, 任意の $p > 0$ に対して,
(i) $R(h) = o(\|h\|^p)$, $h \to 0$ ならば $R(X_n) = o_p(\|X_n\|^p)$.
(ii) $R(h) = O(\|h\|^p)$, $h \to 0$ ならば $R(X_n) = O_p(\|X_n\|^p)$.

Proof. 関数 g を,

$$g(h) := \begin{cases} R(h)/\|h\|^p & \text{if } \ h \neq 0, \\ 0 & \text{if } \ h = 0 \end{cases}$$

[*4] たとえば, $o_p(1) = O_p(1)$ は正しいが $O_p(1) = o_p(1)$ は正しくない.

とおく．このとき, $R(X_n) = g(X_n)\|X_n\|^p$ である．
(i) 仮定より, g は 0 で連続であることに注意する．連続写像定理より, $g(X_n) \xrightarrow{p} g(0) = 0$.
(ii) 仮定より, g は 0 の近傍で有界である:

$$^{\exists}M > 0, ^{\exists}\delta > 0 \ \text{ s.t. } \ \|h\| \le \delta \Rightarrow |g(h)| \le M.$$

したがって,

$$\mathrm{P}(|g(X_n)| > M) \le \mathrm{P}(\|X_n\| > \delta) \to 0.$$

すなわち, $g(X_n) = O_p(1)$. □

2.3 Characteristic Functions

X は $\mathbb{R}^k$-値確率変数であるとする．X の特性関数 $\phi_X : \mathbb{R}^k \to \mathbb{C}$ は

$$\phi_X(t) = \mathrm{E}[e^{it^\top X}], \quad (t \in \mathbb{R}^k)$$

により定まる．これは複素数値関数として有界かつ連続であることに注意する．つまり, 任意の $t \in \mathbb{R}^k$ を fix したとき, Portmanteau (ii) を適用すると, $X_n \xrightarrow{d} X$ ならば $\phi_{X_n}(t) \to \phi_X(t)$ がしたがう．実は逆も正しい: 特性関数の各点収束は, 対応する確率変数列の分布収束を特徴づける．

Theorem 2.13: Levy's continuity theorem

X_n, X は $\mathbb{R}^k$-値確率変数であるとする．このとき,

$$X_n \xrightarrow{d} X \iff \phi_{X_n}(t) \to \phi_X(t) \ \ (^{\forall}t \in \mathbb{R}^k).$$

さらに, ϕ_{X_n} がある関数 $\tilde{\phi} : \mathbb{R}^k \to \mathbb{C}$ に各点収束して $\tilde{\phi}$ が 0 で連続なとき, $\tilde{\phi}$ はある確率変数 $\tilde{X}$ の特性関数であり, $X_n \xrightarrow{d} \tilde{X}$ となる．

Proof. ($\Rightarrow$) Portmanteau (ii) よりただちにしたがう．
($\Leftarrow$) まず, $\{X_n\}$ が tight であると仮定した下で示す．このとき, 任意の部分列 $\{X_{n'}\}$ は tight であり, Prohorov の定理よりそのさらなる部分列 $\{X_{n''}\}$ およびある確率変数 Y が存在して, $X_{n''} \xrightarrow{d} Y$ となる．このことに ($\Rightarrow$) を適用すると $\phi_{X_{n''}}(t) \to \phi_Y(t)$ となるが, 収束先の一意性と仮定に注意すると $\phi_Y = \phi_X$ でもあり, 実は収束先 Y の特性関数は部分列の取り方によらない．Lemma 2.15 で示すように, 特性関数は確率分布を特徴づけるため,

$$^{\exists}Y \ \text{ s.t. } \ \left[^{\forall}\{X_{n'}\}, \ ^{\exists}\{X_{n''}\} \ \text{ s.t. } \ X_{n''} \xrightarrow{d} Y\right] \ \text{ and } \ P_Y = P_X,$$

すなわち

$$^{\forall}\{X_{n'}\}, \ ^{\exists}\{X_{n''}\} \ \text{ s.t. } \ X_{n''} \xrightarrow{d} X$$

となり, $X_n \xrightarrow{d} X$ を得る (後の Coffee Break も参照). $\{X_n\}$ が tight とは限らない場合は, 実は考えなくてもよい: ϕ_X の連続性により $\{X_n\}$ は必ず tight になるのである. このことは下の議論からしたがう.

定理後半の証明に移る. 証明のためには, (ϕ_{X_n} の収束先の関数 $\tilde{\phi}$ が 0 で連続であることを用いて) $\{X_n\}$ が tight になることを示せば十分である. 実際, $\{X_n\}$ が tight ならば上の議論が使えて, 分布収束先 $\tilde{X}$ を上の Y で定めることができる.

X_n の各成分が tight ならば X_n 自身も tight であるから, X_n は 1 次元であるとして議論しても一般性を失わない. 任意の x と $\delta > 0$ に対して,

$$\mathbb{1}\{|\delta x| > 2\} \leq 2\left(1 - \frac{\sin \delta x}{\delta x}\right) = \frac{1}{\delta}\int_{-\delta}^{\delta}(1 - \cos tx)dt.$$

x を X_n でおきかえ, 期待値をとり, Fubini の定理と優収束定理をあわせると,

$$\begin{aligned} \mathrm{P}(|X_n| > 2/\delta) &\leq \frac{1}{\delta}\int_{-\delta}^{\delta} \mathrm{Re}(1 - \phi_{X_n}(t))dt \\ &\to \frac{1}{\delta}\int_{-\delta}^{\delta} \mathrm{Re}(1 - \tilde{\phi}(t))dt. \end{aligned}$$

$\tilde{\phi}(0) = \lim \phi_{X_n}(0) = 1$ であり, $\tilde{\phi}$ が 0 で連続であることに注目する. すなわち,

$$^{\forall}\varepsilon > 0,\ ^{\exists}\delta > 0 \ \text{ s.t. } \ |t| < \delta \Rightarrow |1 - \tilde{\phi}(t)| < \varepsilon.$$

したがって,

$$^{\forall}\varepsilon > 0,\ ^{\exists}\delta > 0 \ \text{ s.t. } \ \limsup_{n\to\infty} \mathrm{P}(|X_n| > 2/\delta) \leq 2\varepsilon.$$

つまり, $\{X_n\}$ は tight である. □

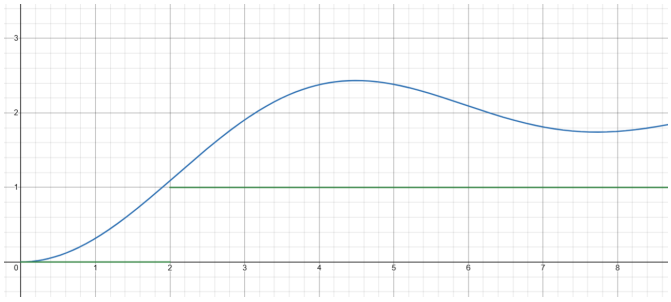

図 1　緑: $\mathbb{1}\{|x| > 2\}$, 青: $2\left(1 - \frac{\sin x}{x}\right)$

Coffee Break : Subsequence Principle

通常, ある部分列の収束をいうだけではもとの列の収束を導くことはできない. しかし, より強く

(i) 任意の部分列に対して, さらにある部分列が存在して収束すること

(ii) そのような収束先が部分列によらず一意であること

を示すことができれば, もとの列の収束を導くことができる. このことは, 実数列の場合には比較的簡単に示すことができる (演習問題とする). 実数列で正しいことが示せれば, 分布収束の定義あるいは Portmanteau より, 確率変数列の分布収束に対しても正しいことが確認できる. この原理を **Subsequence Principle** とよぶ.

Theorem 2.13 の証明においては, もとの列は tight であるという仮定にもとづき, 任意に fix した部分列に Prohorov の定理を適用することで (i) を示した. さらに, 特性関数のもとの列の収束は, 部分列の分布収束先を一意に特徴づけることを用いて (ii) を示した. このような「列の tightness + 部分列の収束先の拘束」の合わせ技で確率変数列の分布収束を示すという手筋はとても便利であり, Prohorov の定理の典型的な使い方の一つといえる.

Example 2.14: Normal distribution

$N_k(\mu, \Sigma)$ の特性関数は,

$$t \mapsto e^{it^\top \mu - \frac{1}{2} t^\top \Sigma t}$$

で与えられる. 実際, $X \sim N_k(0, I)$ とすると, X の分布の確率密度関数は $f_X(x) = \frac{1}{(2\pi)^{k/2}} e^{-\frac{1}{2}x^\top x}$ であり, $\Sigma^{1/2}X + \mu \sim N_k(\mu, \Sigma)$ である. 任意の $z \in \mathbb{R}^k$ に対して, $\Sigma^{1/2}X + \mu$ の特性関数は,

$$\begin{aligned}
\mathrm{E}[e^{z^\top(\Sigma^{1/2}X+\mu)}] &= e^{z^\top \mu} \int e^{z^\top(\Sigma^{1/2}x)} \frac{1}{(2\pi)^{k/2}} e^{-\frac{1}{2}x^\top x} dx \\
&= e^{z^\top \mu} \int e^{(\Sigma^{1/2}z)^\top x - \frac{1}{2}x^\top x} dx \frac{1}{(2\pi)^{k/2}} \\
&= e^{z^\top \mu + \frac{1}{2}z^\top \Sigma z} \int e^{-\frac{1}{2}(x-\Sigma^{1/2}z)^\top (x-\Sigma^{1/2}z)} dx \frac{1}{(2\pi)^{k/2}} \\
&= e^{z^\top \mu + \frac{1}{2}z^\top \Sigma z}.
\end{aligned}$$

$z \in \mathbb{C}^k$ のときでも, 両辺が解析的であることと実軸上で一致していることから, 解析接続の一意性 (一致の定理) によりこの等式は成り立つ. $z = it$ を考えれば, 主張を得る.

Theorem 2.13 の証明でも用いたように, 特性関数は分布を特徴づける.

Lemma 2.15

X, Y は $\mathbb{R}^k$-値確率変数であるとする. このとき,

$$P_X = P_Y \iff \phi_X(t) = \phi_Y(t) \ \ ({}^\forall t \in \mathbb{R}^k).$$

Proof. ($\Rightarrow$) 自明.

($\Leftarrow$) Fubini の定理より, ${}^\forall\sigma > 0, {}^\forall u \in \mathbb{R}^k$ に対して, X, Y と独立な $Z \sim N_k(0,1)$ を用いて

$$\begin{aligned}
\int e^{-it^\top u} e^{-\frac{1}{2}t^\top t\sigma^2} \mathrm{E}[e^{it^\top X}]dt &= \mathrm{E}\left[\int e^{it^\top (X-u)} e^{-\frac{1}{2}t^\top t\sigma^2} dt\right] \\
&= \mathrm{E}\left[\int e^{-\frac{1}{2}\left(\sigma t - i\frac{X-u}{\sigma}\right)^\top \left(\sigma t - i\frac{X-u}{\sigma}\right)} dt\ e^{-\frac{1}{2}(X-u)^\top (X-u)/\sigma^2}\right] \\
&= \frac{(2\pi)^{k/2}}{\sigma^k} \mathrm{E}\left[e^{-\frac{1}{2}(X-u)^\top (X-u)/\sigma^2}\right] \\
&= \frac{(2\pi)^{k/2}}{\sigma^k} \int e^{-\frac{1}{2}(u-x)^\top (u-x)/\sigma^2} P_X(dx) \\
&= (2\pi)^k \int f_{\sigma Z}(u-x) P_X(dx)
\end{aligned}$$

とかける. ただし, $U = X + \sigma Z$ である. 畳み込みの公式より, 右辺は U の密度関数 $f_U(u)$ について $(2\pi)^k f_U(u)$ となっていることに注意する. X と Y について同じ計算が成り立つから, 仮定より

$$\begin{aligned}
(2\pi)^k f_{X+\sigma Z}(u) &= \int e^{-it^\top u} e^{-\frac{1}{2}t^\top t} \mathrm{E}[e^{it^\top X}]dt \\
&= \int e^{-it^\top u} e^{-\frac{1}{2}t^\top t} \mathrm{E}[e^{it^\top Y}]dt = (2\pi)^k f_{Y+\sigma Z}(u).
\end{aligned}$$

すなわち, 任意の $\sigma > 0$ に対して $X + \sigma Z$ と $Y + \sigma Z$ は同じ分布にしたがう. $\sigma \downarrow 0$ として Slutsky の定理を考えると, $X + \sigma Z \xrightarrow{d} X$, $Y + \sigma Z \xrightarrow{d} Y$ となり, $P_X = P_Y$ を得る. □

独立な確率変数の和の特性関数は, 各特性関数の積になる. このことと Levy の連続性定理を用いると, 大数の弱法則が証明できる.

Proposition 2.16: Weak law of large nambers, WLLN

$\{Y_n\}$ は確率変数 Y の i.i.d. コピーとし, 特性関数を ϕ とかく. このとき,

$$\bar{Y}_n \xrightarrow{p} \mu \quad \Leftrightarrow \quad \phi \text{ は } 0 \text{ で微分可能で } \phi'(0) = i\mu.$$

Proof. ($\Rightarrow$) 略. (本も略しているしあんまり使わないし...)
($\Leftarrow$) $\phi(0) = 1$ より, 0 まわりのテイラー展開から $\phi(t) = 1 + i\mu t + o(t)$ である. 各 t で $n \to \infty$ とすると, i.i.d. の仮定より

$$\mathrm{E}\left[e^{it\bar{Y}_n}\right] = \left\{\phi\left(\frac{t}{n}\right)\right\}^n = \left\{1 + i\mu\frac{t}{n} + o\left(\frac{1}{n}\right)\right\}^n \to e^{it\mu}.$$

これは定数 μ の特性関数であり, Theorem 2.13 および Theorem2.7 より $\bar{Y}_n \xrightarrow{p} \mu$ を得る. □

$\phi(t) = \mathrm{E}[e^{itY}]$ が 0 で微分可能であることの十分条件としては, たとえば $\mathrm{E}[|Y|] < \infty$ がある. このとき, $\left|\frac{d}{dt}e^{itY}\right| = |iYe^{itY}| = |Y|$ より積分記号下での微分ができて,

$$\phi'(t) = \frac{d}{dt}\mathrm{E}[e^{itY}] = \mathrm{E}[iYe^{itY}]$$

となる．特に $\phi'(0) = i\mathrm{E}[Y]$ であるから, WLLN の収束先は $\mathrm{E}[Y]$ になる．同様に, $\phi(t) = \mathrm{E}[e^{itY}]$ が 0 で m 回微分可能であるための十分条件として $\mathrm{E}[|Y|^m] < \infty$ がある．

2 次モーメントの存在まで仮定すると, $\bar{Y}_n$ をスケーリングしたものに分布収束がいえる．

Proposition 2.17: Central limit theorem, CLT

$\{Y_n\}$ は確率変数 Y の i.i.d. コピーとし, 特性関数を ϕ とかく．また, $\mathrm{E}[Y] = 0$, $\mathrm{E}[Y^2] = 1$ であるとする．このとき,

$$\sqrt{n}\bar{Y}_n \xrightarrow{d} N(0,1).$$

Proof. 積分記号下での微分により, $\phi'(0) = 0, \phi''(0) = i^2\mathrm{E}[Y^2] = -1$. したがって,

$$\begin{aligned}\mathrm{E}[e^{it(\sqrt{n}\bar{Y}_n)}] = \left\{\phi\left(\frac{t}{\sqrt{n}}\right)\right\}^n &= \left\{1 + 0 \cdot \frac{t}{\sqrt{n}} + \frac{1}{2!}(-1)\frac{t^2}{n} + o\left(\frac{1}{n}\right)\right\}^n \\ &= \left\{1 - \frac{1}{2!}\frac{t^2}{n} + o\left(\frac{1}{n}\right)\right\}^n \to e^{-\frac{t^2}{2}}.\end{aligned}$$

これは $N(0,1)$ の特性関数であり, Levy の連続性定理より主張を得る． □

多次元の場合はどうか．ここで, 次のことに注意する．

$$\begin{aligned}&{}^\forall t \in \mathbb{R}^k,\ \phi_{X_n}(t) = \mathrm{E}[e^{it^\top X_n}] \to \mathrm{E}[e^{it^\top X}] = \phi_X(t) \\ \Leftrightarrow\ &{}^\forall u \in \mathbb{R}, {}^\forall t \in \mathbb{R}^k,\ \phi_{t^\top X_n}(u) = \mathrm{E}[e^{iu(t^\top X_n)}] \to \mathrm{E}[e^{iu(t^\top X)}] = \phi_{t^\top X}(u)\end{aligned}$$

つまり,

$$X_n \xrightarrow{d} X \quad \Leftrightarrow \quad t^\top X_n \xrightarrow{d} t^\top X \ \ ({}^\forall t \in \mathbb{R}^k)$$

である．これは **Cramér-Wald のデバイス**として知られる．特に $(\Leftarrow)$ が有用であり, 多次元での分布収束を 1 次元の分布収束に帰着させるためによく用いられる．ただし, 内積の収束先の分布から内積をとる前の収束先の分布を逆算する必要があることに注意する．

Example 2.18: Multivariate CLT

$\{Y_n\}$ は確率変数 Y の i.i.d. コピーとし, $\mathrm{E}[Y] = \mu$, $\mathrm{E}[(Y-\mu)(Y-\mu)^\top] = \Sigma$ とする．このとき, 1 次元の CLT より, 任意の $t \in \mathbb{R}^k$ に対して,

$$t^\top\left\{\frac{1}{\sqrt{n}}\sum_{i=1}^n (Y_i - \mu)\right\} = \frac{1}{\sqrt{n}}\sum_{i=1}^n \left\{t^\top(Y_i - \mu)\right\} \xrightarrow{d} N(0, t^\top\Sigma t).$$

Cramér-Wald のデバイスより,

$$\frac{1}{\sqrt{n}}\sum_{i=1}^n (Y_i - \mu) \xrightarrow{d} N_k(0, \Sigma)$$

がしたがう．

2.4 Almost-Sure Representation

この本では用いられないが, 分布収束を, 確率空間と確率変数の適当な取り換えを考えることで, 概収束にすることができる.

Theorem 2.19: Almost-sure representation

X_n, X は $\mathbb{R}^k$-値確率変数であるとする. $X_n \xrightarrow{d} X$ とすると, ある確率空間 $(\widetilde{\Omega}, \widetilde{\mathcal{F}}, \widetilde{\mathrm{P}})$ とその上の $\widetilde{X}_n, \widetilde{X}$ が存在して, $\widetilde{\mathrm{P}}_{X_n} = \mathrm{P}_{X_n}$, $\widetilde{\mathrm{P}}_X = \mathrm{P}_X$ かつ $\widetilde{X}_n \xrightarrow{a.s.} \widetilde{X}$ となるようにできる.

Proof. 略. 1 次元の場合は $\widetilde{X}_n = F_{X_n}^{-1}(U)$, $U \sim \mathrm{Unif}(0,1)$ とすればよい. □

2.5 Convergence of Moments

Portmanteau (ii) より, f が有界連続関数のとき, $X_n \xrightarrow{d} X \;\Rightarrow\; \mathrm{E}[f(X_n)] \to \mathrm{E}[f(X)]$ であった. ここで, 有界性の仮定を外すことはできない. 特に, $f(x) = |x|^p$ のような場合のモーメントの収束は, 分布収束から直接導くことはできない.

Definition 2.3

$\{Y_n\}$: $\mathbb{R}^k$-値確率変数列が**漸近一様可積分** (asymptotically uniformly integrable) であるとは,

$$\lim_{M\to\infty} \limsup_{n\to\infty} \mathrm{E}[|Y_n| \mathbb{1}\{|Y_n| \geq M\}] = 0$$

をみたすことをいう[a].

[a] $\limsup_{n\to\infty}$ が $\sup_{n\in\mathbb{N}}$ の場合を一様可積分という. Tightness の場合と違って小さな n に対する M の取り換えが効かないため, この 2 つは等価にならない.

漸近一様可積分性をあわせるとモーメントの収束までいえる.

Theorem 2.20

関数 $f : \mathbb{R}^k \to \mathbb{R}$ は $C \subset \mathbb{R}^k$ 上で連続とし, $X_n \xrightarrow{d} X$ かつ $\mathrm{P}(X \in C) = 1$ とする. さらに $\{f(X_n)\}$ が漸近一様可積分ならば $\mathrm{E}[f(X_n)] \to \mathrm{E}[f(X)]$.

Proof. $Y_n = f(X_n), Y = f(X)$ とおく. また, $f \geq 0$ として議論しても一般性を失わない. 連続写像定理より $Y_n \xrightarrow{d} Y$ であり, 三角不等式より任意の $M > 0$ に対して

$$|\mathrm{E}[Y_n] - \mathrm{E}[Y]| \leq |\mathrm{E}[Y_n] - \mathrm{E}[Y_n \wedge M]| + |\mathrm{E}[Y_n \wedge M] - \mathrm{E}[Y \wedge M]| + |\mathrm{E}[Y \wedge M] - \mathrm{E}[Y]|.$$

右辺第 1 項は, $\{Y_n\}$ の漸近一様可積分性より

$$\lim_{M\to\infty}\limsup_{n\to\infty}|\mathrm{E}[Y_n]-\mathrm{E}[Y_n\wedge M]| = \lim_{M\to\infty}\limsup_{n\to\infty}\mathrm{E}[|Y_n|\mathbb{1}\{|Y_n|\geq M\}] = 0.$$

右辺第 2 項については, 有界連続関数 $u\mapsto u\wedge M$ に Portmanteau (ii) が適用でき,

$$\limsup_{n\to\infty}|\mathrm{E}[Y_n\wedge M]-\mathrm{E}[Y\wedge M]| = 0.$$

右辺第 3 項は単調収束定理より

$$\lim_{M\to\infty}|\mathrm{E}[Y\wedge M]-\mathrm{E}[Y]| = 0.$$

以上の評価を, 最初の不等式の両辺で極限をとって適用すれば主張を得る. □

Example 2.21

$X_n \xrightarrow{d} X$ かつある $p>0$ に対して $\limsup_{n\to\infty}\mathrm{E}[|X_n|^p]<\infty$ とする. このとき, 任意の $k<p$ $(k\in\mathbb{N})$ に対して $\mathrm{E}[X_n^k]\to\mathrm{E}[X^k]$ となる.
実際, Markov の不等式より,

$$\begin{aligned}\mathrm{E}[|X_n|^k\mathbb{1}\{|X_n|^k\geq M\}] &= \mathrm{E}[|X_n|^p|X_n|^{k-p}\mathbb{1}\{|X_n|\geq M^{\frac{1}{k}}\}]\\ &\leq \mathrm{E}[|X_n|^p|M^{\frac{1}{k}}|^{k-p}\mathbb{1}\{|X_n|\geq M^{\frac{1}{k}}\}]\\ &\leq M^{1-\frac{p}{k}}\mathrm{E}[|X_n|^p].\end{aligned}$$

したがって

$$\lim_{M\to\infty}\limsup_{n\to\infty}\mathrm{E}[|X_n|^k\mathbb{1}\{|X_n|^k\geq M\}] = 0$$

となり, $u\mapsto u^k$ の連続性と $\{X_n^k\}$ の漸近一様可積分性より Theorem 2.21 を適用して主張を得る.

もしも収束先 X の分布がモーメントによって特徴づけられるならば, モーメントの収束から逆向きに分布収束を導ける.

Theorem 2.22

X_n, X は $\mathbb{R}^k$-値確率変数であり, 任意の $p\in\mathbb{N}$ で $\mathrm{E}[X_n^p]\to\mathrm{E}[X^p]$ とする. X のモーメントが P_X を決定するとき, $X_n\xrightarrow{d}X$ がしたがう.

Proof. $\mathrm{E}[|X_n|]=O(1)$ より, $\{X_n\}$ は tight である. Prohorov の定理より, 任意の部分列 $\{X_{n'}\}$ に対して, さらにある部分列 $\{X_{n''}\}$ と確率変数 Y が存在して $X_{n''}\xrightarrow{d}Y$ とできる. Example 2.21 より, 任意の $p\in\mathbb{N}$ に対して $\mathrm{E}[X_{n''}^p]\to\mathrm{E}[Y^p]$ であることに注意する. さらに, 仮定より任意の $p\in\mathbb{N}$ に対して $\mathrm{E}[Y^p]=\mathrm{E}[X^p]$ がいえて, $P_X=P_Y$ までわかる. つまり, 収束先 Y の分布は部分列によらず X の分布に等しく, $X_n\xrightarrow{d}X$ がしたがう. □

Example 2.23

正規分布はモーメントにより特徴づけられる．したがって，奇数の p について $\mathrm{E}[X_n^p] \to 0$，偶数の p について $\mathrm{E}[X_n^p] \to (p-1)!!$ を示せば，$X_n \xrightarrow{d} N(0,1)$ を得る．

2.6 Convergence-Determining Class

Definition 2.4

$\mathbb{R}^k$ 上の関数の集合 $\mathcal{F}$ が **convergence-determining class** であるとは，任意の $\mathbb{R}^k$-値確率変数 X_n, X に対して

$$X_n \xrightarrow{d} X \;\Leftrightarrow\; {}^\forall f \in \mathcal{F},\ \mathrm{E}[f(X_n)] \to \mathrm{E}[f(X)]$$

であることをいう．

Portmanteau (ii) より，有界連続関数の集合は convergence-determining class である．しかし，より小さな関数のクラスも convergence-determining class になりうる．

Lemma 2.24

$\mathbb{R}^k = \mathbb{R}^l \times \mathbb{R}^m$ 上の関数の集合

$$\{(x,y) \mapsto f(x)g(y)\,;\ f, g \text{ は有界連続関数 }\}$$

は convergence-determining class である．

Lemma 2.25

ある関数の可算集合 $\mathcal{F} \subset \{f : \mathbb{R}^k \to [0,1]\,;\ f \text{ は連続関数 }\}$ が存在して，convergence-determining class となり，しかも次が成り立つ:

$$X_n \xrightarrow{d} X \Rightarrow \sup_{f \in \mathcal{F}} |\mathrm{E}[f(X_n)] - \mathrm{E}[f(X)]| \to 0.$$

2.7 Law of the Iterated Logarithm

上で見た大数法則と中心極限定理はどちらも，数理統計において核心的な役割を果たす．その一方で，少し変わったスケーリングを考えることで 2 つの収束定理の「中間」の収束を導くことができる．数理統計への応用はあまり見られないようであるが，興味深い結果なのでおさえておく．

$\{Y_n\}$ は確率変数 Y の i.i.d. コピーとし，$\mathrm{E}[Y] = 0$ とすると，大数の強法則より $\frac{1}{n}\sum_{i=1}^n Y_i \xrightarrow{a.s.} 0$ である．さらに $\mathrm{E}[Y^2] = 1$ のとき，中心極限定理より $\frac{1}{\sqrt{n}}\sum_{i=1}^n Y_i \xrightarrow{d} N(0,1)$ である．つまり，和

を n で割ると期待値 0 につぶれ, $\sqrt{n}$ で割るとちょうど正規分布の形に膨らみつつおさまる. さて, 発散スピードが n よりは遅く $\sqrt{n}$ よりは速い定数列 a_n で和を割ることで, 期待値につぶす (退化させる) ことなくある有界区間の中におさめることは可能だろうか. 実はこれは, $\sqrt{n}$ よりもほんの少しだけ発散オーダーの大きな $a_n = \sqrt{n \log\log n}$ によって可能であり, しかも区間の上限と下限は $\sqrt{2}$ になることが知られている！

Proposition 2.26: Law of the iterated logarithm

$\{Y_n\}$ は確率変数 Y の i.i.d. コピー, $\mathrm{E}[Y] = 0, \mathrm{E}[Y^2] = 1$ のとき,

$$\limsup_{n\to\infty} \frac{Y_1 + \cdots + Y_n}{\sqrt{n \log\log n}} = \sqrt{2} \quad \text{a.s.}$$

が成り立つ. 逆に, この主張が i.i.d. 確率変数列 $\{Y_n\}, \{-Y_n\}$ に対して成り立つならば, $\mathrm{E}[Y] = 0, \mathrm{E}[Y^2] = 1$ である.

ここで, Slutsky の補題を思い出すと,

$$Z_n = \frac{Y_1 + \cdots + Y_n}{\sqrt{n \log\log n}} \xrightarrow{p} 0.$$

これは一見すると上の命題と矛盾しているように思われるかもしれないが, 実際は矛盾していない (2 つの収束概念の違いに注意する). つまり, 確率測度を用いて Z_n が $(-\varepsilon, \varepsilon)$ に入る ω たちの集合を測るとその測度は 1 に近づいていく一方で, 各点でみると, $(-\varepsilon, \varepsilon)$ から飛び出ては $\pm\sqrt{2}$ の近傍に何回でもタッチしてしまう ω ばかりなのである.

2.8 Lindeberg-Feller Theorem

上で見た中心極限定理は i.i.d. 確率変数列に対するものであったが, 独立性や同分布性をゆるめた拡張も考えられる. 次の命題は同分布性を仮定から外した比較的シンプルな拡張を与える[*5] .

Proposition 2.27: Lindeberg-Feller central limit theorem

$\mathbb{R}^k$-値確率変数の三角列 $Y_{n,1}, \ldots, Y_{n,m_n}$ は独立であり, 次をみたすとする.

$$\begin{aligned} {}^\forall\varepsilon > 0, \quad \sum_{i=1}^{m_n} \mathrm{E}[|Y_{n,i}|^2 \mathbb{1}_{\{|Y_{n,i}|>\varepsilon\}}] &\to 0, \\ \sum_{i=1}^{m_n} \mathrm{Cov}[Y_{n,i}] &\to \Sigma. \end{aligned}$$

[*5] もっとも一般化が進んだ拡張としてマルチンゲール中心極限定理がある. これはいいニュースである一方で, 漸近統計の本質的限界を示唆してもいると思う.

このとき,

$$\sum_{i=1}^{m_n}(Y_{n,i} - \mathrm{E}[Y_{n,i}]) \xrightarrow{d} N(0, \Sigma).$$

この命題が使われる状況としては, たとえばデザイン行列 X を fix したときの線形回帰が挙げられる. 詳細は本を参照. この本の以降のパートで線形回帰を考える際は, (通常の中心極限定理が適用可能な)X がランダムな場合を考える.

2.9 Convergence in Total Variation

Definition 2.5: Convergence in total variation

$\mathbb{R}^k$-値確率変数列 $\{X_n\}$ が X に**全変動収束** (convergence in total variation) するとは,

$$\sup_B |\mathrm{P}(X_n \in B) - \mathrm{P}(X \in B)| \to 0$$

が成り立つことをいう. ただし, sup はすべてのボレル集合にわたってとる.

すなわち, 確率分布における全変動距離の収束である. Portmanteau よりただちに, 全変動収束するならば分布収束することがわかる. 全変動収束の十分条件としては, 確率密度関数の各点収束がある. 実際, $\mathrm{P}_{X_n}, \mathrm{P}_X \ll \mu$ として密度関数を p_n, p とかくと, (符号付測度の Hahn 分解より)

$$\sup_B |\mathrm{P}(X_n \in B) - \mathrm{P}(X \in B)| = \frac{1}{2}\int |p_n - p| d\mu$$

となり, 右辺について積分と極限の交換を保証すればよさそうだ.

Proposition 2.28

$f_n : \mathbb{R}^k \to \mathbb{R}$ が μ-a.e. で f に収束し, ある $p \geq 1$ で $\limsup \int |f_n|^p d\mu \leq \int |f|^p d\mu < \infty$ が成り立つとする. このとき, $\int |f_n - f|^p d\mu \to 0$.

Proof. 不等式 $(a+b)^p \leq 2^p a^p + 2^p b^p \quad (a, b \geq 0)$ を考える. 仮定より,

$$0 \leq 2^p |f_n|^p + 2^p |f|^p - |f_n - f|^p \to 2^{p+1}|f|^p \quad \text{a.e.}$$

であるから, Fatou の補題より,

$$\begin{aligned}\int 2^{p+1}|f|^p d\mu &\leq \liminf_{n\to\infty} \int (2^p|f_n|^p + 2^p|f|^p - |f_n - f|^p) d\mu \\ &\leq \int 2^{p+1}|f|^p d\mu - \limsup_{n\to\infty} \int |f_n - f|^p d\mu.\end{aligned}$$

以上で主張を得る. □

Corollary 2.29: Scheffé

X_n, X は $\mathbb{R}^k$-値確率変数とし, $\mathrm{P}_{X_n}, \mathrm{P}_X \ll \mu$ であるとする。密度関数を p_n, p とかく．もし $p_n \to p$ (μ-a.e.) ならば X_n は X に全変動収束する．

とくに, 特性関数の積分を抑えられる場合には, 中心極限定理の精緻化が得られる．

Theorem 2.30: Central limit theorem in total variation

$\{Y_n\}$ は確率変数 Y の i.i.d. コピーとし, $\mathrm{E}[Y^2] < \infty$ とする．また, Y の特性関数 ϕ はある $\nu \geq 1$ に対して $\int |\phi(t)|^\nu dt < \infty$ をみたすとする．このとき, $\sqrt{n}(\bar{Y}_n - \mathrm{E}[Y])$ はある正規分布に全変動収束する．

3 What is Statistical Estimation?

3 章から 5 章では, パラメトリックモデルの統計的推測に関する基本事項をまとめる. 統計的推測とは, **データを生成する真のシステムを, 限られたデータからうまく推測するための理論・方法論**を指す. ここで, 本稿における統計的推測の基本思想を宣言しておく.

1. 統計的推測の究極の目標はよい推定量の構成であり, そのよさは推定量がしたがう確率分布によって評価される.
2. よい推定量の構成は, よい推定関数の構成によって達成される.
3. ひとたび統計的実験が定まれば, 推定量のよさの限界も定まる.

何がしたいか分からなくなったときは, いつでも上の公理からモチベーションを復元することができる.

3.1 Statistical Experiments

あまり御託ばかり並べても退屈なので、さっそく分析設定のつくり方をみていこう. すべての始まりは**データ**：確率変数列 $\boldsymbol{X}_n = \{X_n\}$ である. n を**サンプルサイズ**という. 本稿ではつねに, $\{X_n\}$ は X の i.i.d. コピーであるとする. X は確率空間 $(\Omega, \mathcal{F}, \mathbb{P}_{\theta_0})$ から可測空間 $(\mathcal{X}, \mathcal{B})$ への写像であるとし, X が $(\mathcal{X}, \mathcal{B})$ 上に誘導する確率分布を P_{θ_0} とかく. 添え字 $\theta \in \Theta \subset \mathbb{R}^p$ を**パラメータ**といい, データの挙動を実際に支配する $\theta_0 \in \Theta$ をパラメータの**真値**という. いま, 真値 θ_0 は我々にとって未知であり, 真値の候補たる Θ しか知りえない状況で, データを用いて θ_0 の値を推定したいとする. したがって, 実際にはすべての $\theta \in \Theta$ に対する分布 P_θ を検討する. 検討対象の分布を集めた集合 $\{\mathrm{P}_\theta\,;\,\theta \in \Theta\}$ を**統計モデル**という. 統計的推測の分析設定は, サンプルサイズ n のデータが誘導する, すべての可能な確率空間にもとづいて書き下す.

Definition 3.1: 統計的実験

三つ組 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\,;\,\theta \in \Theta\})$ を**統計的実験** (statistical experiment) という.

基本的には実数値のデータ：$\mathcal{X} = \mathbb{R}^k$ の場合のみ考えればよい. また, $\mathcal{X}$ 上のある σ-有限測度 μ が存在して, 任意の $\theta \in \Theta$ について $\mathrm{P}_\theta \ll \mu$ であるとする. このとき, Radon-Nykodim 微分 $f(x;\theta)$ が存在して,

$$\mathrm{P}_\theta(dx) = f(x;\theta)\mu(dx)$$

とかける. i.i.d. に注意すれば, n 個の観測についても同様に

$$\mathrm{P}_\theta^n(dx) = \prod_{i=1}^n f(x_i;\theta)\mu(d\mathbf{x}_n)$$

となる.

冒頭で，「統計的推測とは，データを生成する真のシステムを，限られたサンプルからうまく推測するための理論・方法論」であると述べた．これは数学の言葉でいえば，「データ $\mathbf{x}_n \in \mathbb{R}^n$ からパラメータ $\theta \in \Theta$ への（可測）写像 $\hat{\theta}_n : \mathbf{x}_n \mapsto \hat{\theta}_n(\mathbf{x}_n)$ を構成し，$\hat{\theta}_n$ のよさについて検討すること」であるといえる．$\hat{\theta}_n$ はそれ自体，$\mathrm{P}^n_{\theta_0}$ を Θ 上に誘導する確率変数であることに注意する．それもただの確率変数ではなく，真値 θ_0 の推測に役立つように工夫して構成しなければならないものである．データの関数を一般に**統計量**というが，$\hat{\theta}_n$ のような確率変数を特に θ_0 の**推定量**という．

Example 3.1: 正規分布の推測

$X \sim N(\mu_0, \sigma_0^2)$，$\theta = (\mu, \sigma^2) \in \Theta = (-\infty, \infty) \times (0, \infty)$ とする．このとき，$(\mathcal{X}, \mathcal{A}, \mathrm{P}_\theta) = (\mathbb{R}, \mathcal{B}(\mathbb{R}), f(x;\theta)dx)$ となる．ただし，f は確率密度関数

$$f(x;\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}.$$

さて，真値 θ_0 を，データ $X_1, X_2, \ldots, X_n$ を用いて推定するよい方法はあるだろうか？すなわち，推定量 $\hat{\theta}_n : \mathbb{R}^n \ni \mathbf{x}_n \mapsto \hat{\theta}_n(\mathbf{x}_n) \in \Theta$ をどのように構成すればよいだろうか？

一般に注意すべきことは二つある．一つ目は，推定量は空から降ってくるものではなく，自ら構成しなければならないということであり，二つ目は，何をもってよい推定量であるとみなすかどうかも，自ら決めておかなければならないということである．

極端な話，一つ目についていえば，$\hat{\theta}_n = (0, 100)$ なるノンランダムな推定量を考えたっていいわけだし，二つ目についていえば，単に分散が小さければよいとするならノンランダムな推定量はみな最良ということになる．この推定量がまともではないことは，推定量がデータの情報を一切使っていないことからも直観的に明らかかもしれないが，より正確には，未知の θ_0 のうまい推測という我々の目標にかなっていないことが一番の問題なのである．ここで「真値が $\theta_0 = (0, 100)$ のときは必ず真の値を言い当てることができる最強の推定量になるじゃないか」と思われたかもしれない．しかし，実際に $\theta_0 = (0, 100)$ かどうかを知りえない以上，これは意味のない主張である．統計学では一般に，真値 θ_0 がある値のときにだけうまくいく推定量は，よい推定量とは言わないことに注意する．

では，よい推定量とは具体的には何か？

3.2 What is a Good Estimator?

結論から述べてしまうと，よい推定量とは，（任意の θ_0 について）**分布が θ_0 のまわりに集中している推定量**である．軽く書いたが，この思想自体，統計学の偉大な発明である．

この思想にもとづき，学部の標準的な統計学の講義では，推定量の不偏性と有効性について習う．あらためて，適当な統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_\theta\ ;\ \theta \in \Theta\})$ を考える．いま，パラメータは 1 次元とする．**不偏推定量**とは，

$$\mathrm{E}_{\theta_0}\left[\hat{\theta}_n\right] = \theta_0 \quad ({}^\forall\theta_0 \in \Theta)$$

が成り立つ推定量 $\hat{\theta}_n$ をいう．**有効推定量**とは, 不偏であって,

$$\mathrm{Var}_{\theta_0}\left[\hat{\theta}_n\right] = I(\theta_0)^{-1} \quad ({}^\forall\theta_0 \in \Theta)$$

が成り立つ推定量 $\hat{\theta}_n$ をいう[*6]．ただし, $I(\theta_0)$ は**フィッシャー情報量**

$$I(\theta_0) := \mathrm{E}_{\theta_0}\left[\left(\frac{\partial}{\partial\theta}\log f(X;\theta)\right)^2 |_{\theta=\theta_0}\right] = -\mathrm{E}_{\theta_0}\left[\frac{\partial^2}{\partial\theta^2}\log f(X;\theta)\ |_{\theta=\theta_0}\right]$$

である．$\frac{\partial}{\partial\theta}\log f(X;\theta)$ を**スコア関数**という．詳細は標準的な数理統計学の教科書を参照してほしい．重要な点だけ補足すると, 統計的推測において「有効」とは「期待値が真値に等しく分散が限界まで小さい」という意味である．クラメール-ラオの不等式より, 任意の不偏推定量 $\hat{\theta}_n$ に対して

$$\mathrm{Var}_{\theta_0}\left[\hat{\theta}_n\right] \geq I^{-1}(\theta_0) \quad ({}^\forall\theta_0 \in \Theta)$$

が成り立つ．つまり, 不偏性という（それ自体うれしい）性質で推定量のクラスを制限し, そこからよーいドンで分散の小ささを測って勝負したとき, 理論値を達成してほかの推定量を打ち負かすことができるのが有効推定量である．要するに, 推定量の分布の 1 次モーメント（予選）と 2 次モーメント（決勝）によって推定量を評価しようという話だ．以上が, 有限のサンプルサイズ n に関する推測統計学の標準的フレームワークである．

その一方で漸近統計とは, サンプルサイズ $n \to \infty$ の統計学である．なぜそのような設定を考えるのかといえば, 有限の n に対してよい推定量かどうかを評価するのは一般に困難だからだ．上のフレームワークに沿って推定量を評価しようと思うと, どうしても推定量の分布の 1 次モーメントと 2 次モーメントの具体的な評価が（固定された n の下で）必要になる．提案する推定量が単純である保証はなく, 一般にはそのような積分評価は困難になり, 解析的に陽に表示が得られるとも限らない．統計学の試験においてあらわれる不偏推定量たちは, そのような評価が可能な都合のいい例外なのである．

したがって漸近統計では, 推定量の分布を n ごとに直接評価するのではなく, その $n \to \infty$ における挙動に注目する．

Definition 3.2: Consistency

推定量 $\hat{\theta}_n$ が**一致性** (consistency) をみたすとは, 任意の $\theta_0 \in \Theta$ に対して,

$${}^\forall\varepsilon > 0, \quad \mathrm{P}^n_{\theta_0}(|\hat{\theta}_n - \theta_0| > \varepsilon) \to 0 \quad (n \to \infty)$$

が成り立つことをいう．

この定義は,「$\hat{\theta}_n$ は $\mathrm{P}^n_{\theta_0}$ の下で θ_0 に確率収束する」と読んでもよいが,「$\hat{\theta}_n$ の $\mathrm{P}^n_{\theta_0}$ の下での分布は θ_0 に退化する」と読むこともできる．これは「n を増やしていけば分布が θ_0 のまわりに集中

[*6] 存在しないこともある．

していく推定量」であることを要請しており, 上で述べた思想に適合しているといえるだろう. ただしこれでは, 単に真値に近い推定結果が得られると言っているにすぎず, それ以上の情報を読み取ることはできない. 漸近統計では, 推定量の分布に関するさらなる要請をする.

Definition 3.3: Asymptotic Normality

推定量 $\hat{\theta}_n$ が**漸近正規性** (asymptotic normality) をみたすとは, 任意の $\theta_0 \in \Theta$ に対して, $\mathrm{P}^n_{\theta_0}$ の下で, ある（真値に依存した）正定値対称行列 Σ_{θ_0} が存在して,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N_p(0, \Sigma_{\theta_0})$$

が成り立つことをいう.

定義より, 漸近正規性をみたす推定量は一致性もみたす（ぜひ確かめてみてほしい）. 漸近正規性を示すことができれば, 推定量が真値のまわりでどのような形でどれくらいブレるのかが分かることになり, 「単に真値に近い」というよりも圧倒的に多くの情報を我々にもたらす. そのおかげで信頼区間や検定統計量の構成が可能になるわけなので, これも推定量にとって不可欠な性質といえよう.

とはいえ, 次のような疑問をもつかもしれない：「どんな統計的実験においても, 漸近正規性をみたす推定量を構成することは可能なのだろうか。また, 収束先の分布が正規分布であることは必然なのだろうか。」まずは次章で, 前者の問いについて考える. 後者の問いについては 8 章の議論を待つ必要がある：必ずしも必然ではないが, ベストな推定量の漸近分布は正規分布であることがわかっている.

4 How Can We Construct a Good Estimator?

適当な統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_\theta \,;\, \theta \in \Theta\})$ が与えられたとする. 本章では, 一致性と漸近正規性をみたす推定量の構成方法を考える. 定義より, もしも θ_0 が X の期待値に等しいならば, $\hat{\theta}_n$ を $\{X_n\}$ の標本平均で定めることで, 中心極限定理そのものから $\hat{\theta}_n$ の漸近正規性がしたがう. 一般の θ_0 に対してはどうすればよいだろうか？きっと同様に中心極限定理が重要なはたらきをするに違いないとして, 具体的に何に対する中心極限定理を考えればよいのだろうか？

4.1 Maximum Likelihood Estimation

現状, データ $\{X_n\}$ がある未知の $\theta_0 \in \Theta$ に関する分布 P_{θ_0} に i.i.d. にしたがっているということ以外に, めぼしい情報はない. このような状況で真値 θ_0 に近い値をデータから当てたいという要請自体が, パッと見では相当無茶に見える. が, このことは尤度をうまく用いれば可能であるという方法論を, R.A.Fisher が 1922 年に体系化した.

Definition 4.1: Likelihood Function

次で定まる関数

$$L_n(\theta; \boldsymbol{X}_n) = \prod_{i=1}^{n} f(X_i; \theta)$$

を**尤度関数**（likelihood function）という．また,

$$l_n(\theta; \boldsymbol{X}_n) = \log L_n(\theta; \boldsymbol{X}_n) = \sum_{i=1}^{n} \log f(X_i; \theta)$$

を**対数尤度関数**（log-likelihood function）という．引数 $\boldsymbol{X}_n$ は通常略す．

対数をとるのは, 関数自体が i.i.d. 確率変数列の和として表現できて極限定理が適用しやすくなるためである．また, 気持ちとしては, θ と $\boldsymbol{X}_n$ は引数として対等ではない．むしろ, 後者を fix するごとに定まる前者の関数（データが得られて $\boldsymbol{X}_n$ の値が確定してしまった後の θ の関数）としてみると, 見通しが良くなる．

Definition 4.2: Maximum Likelihood Estimator

推定量 $\hat{\theta}_n = \hat{\theta}_n(\boldsymbol{X}_n)$ が**最尤推定量** (MLE; maximum likelihood estimator) であるとは,

$$l_n(\hat{\theta}_n) = \max_{\theta \in \Theta} l_n(\theta)$$

をみたすこととする．

これは $\boldsymbol{X}_n$ の実現値ごとに成り立つ等式である．最尤推定量の分析において重要なのは, $\hat{\theta}_n$ が closed form で書けるとは限らない点である．つまり, $\hat{\theta}_n$ の分析を, それを定義する対数尤度関数 l_n の分析に帰着させなければならない．

定義まで済んだところで, まずは最尤推定量が一致性をもつかどうかについて検討してみよう．たとえば, 平均 μ, 分散 σ^2 の正規分布から乱数を発生させ続ければ, 実現値のヒストグラムは真の密度関数にどんどん近づいていくだろう．つまり,「μ_1 と μ_2 という 2 つの値のうちどちらかが本当の平均のとき, どっちが本当の平均かな〜」と迷ったとしたら, 実現値のヒストグラムがどちらの正規分布に近づいていくかを見ればよいのである．μ_1 と μ_2 が近いほど識別は難しくなるが, それでもサンプルサイズを大きくしてヒストグラムをいくらでも精緻にしていけば, それはほとんど真の密度関数そのもののはずで, 真値でない方の密度関数からはズレているはずだ．**真値ではないパラメータは, 真値と比べて, 実現値に対する当てはまりでほとんど確実に劣っていく**．最尤推定はこのことを原理として用いる．

以上の直観を正確に書き下そう．まず, 真の分布からのズレを定量化する指標として, 次で定義される **KL 情報量**がある：任意の $\theta \in \Theta$ に対して,

$$KL(\theta_0, \theta) := E_{\theta_0}\left[\log \frac{f(X; \theta_0)}{f(X; \theta)}\right] \geq 0.$$

等号は $f(X;\theta_0) = f(X;\theta)$ a.s. のときに限り成り立つ．さて，ここで対数尤度関数を n で割って極限をとると，大数の法則より

$$\frac{1}{n} l_n(\theta; \boldsymbol{X}_n) = \frac{1}{n} \sum_{i=1}^{n} \log f(X_i;\theta) \xrightarrow{p} E_{\theta_0}\left[\log f(X;\theta)\right] \leq E_{\theta_0}\left[\log f(X;\theta_0)\right].$$

したがって，対数尤度関数 $l_n(\theta; \boldsymbol{X}_n)$ の最大化は漸近的に $E_{\theta_0}\left[\log f(X;\theta)\right]$ の最大化に等価であり，それは KL 情報量の不等式より θ_0 でのみ達成されるというわけである．このことは，最尤推定量が θ_0 に漸近することを示唆している．この議論と先ほどの段落で述べた直観との対応も確認してみてほしい．特に，真の密度関数に近づいていくヒストグラムの挙動を直接見るかわりに，$\frac{1}{n} l_n(\theta; \boldsymbol{X}_n)$ の挙動を見ていることに注意しよう．$\theta \mapsto E_{\theta_0}\left[\log f(X;\theta)\right]$ は真の密度関数からのズレを測る「神様の物差し」であり，θ に関する最大化を通して必ず真値を識別できる（が目に見えない）関数である．そこで，対数尤度にもとづくランダムな関数（こちらは目に見える）で神様の物差しを近似することによって，神の所業に迫ろうというわけである．

実は，以上の議論においていくつか留意点がある．まず，いま述べた各点 $\theta \in \Theta$ での確率収束は，実際には θ に関して一様に成り立っていなければならない（**一様大数の法則**）．厳密には，$l_n(\theta; \boldsymbol{X}_n)$ の最大値を与える $\theta = \hat{\theta}_n$ が θ_0 から逃げながらでも，各点での確率収束は可能だからである．また，厳密には

$$f(X;\theta_0) = f(X;\theta)\ a.s. \quad \Rightarrow \quad \theta_0 = \theta$$

が成り立っていなければならない（**識別可能条件**）．異なるパラメータが同じ真の密度関数を与えてしまうならば，いくらヒストグラムが精緻になったとしても 2 つのパラメータのどちらが真値かを識別しようがない．一致性の厳密な証明は次節でより一般化された形で行う．

Q1. 識別可能条件が成り立たないパラメータの例を与えよう．たとえば、正規分布を $\sigma \in \mathbb{R}$ で parametrize すると...？

次に，最尤推定量の漸近正規性について検討しよう．繰り返しになるが，最尤推定量 $\hat{\theta}_n$ はある関数の最大化によって間接的に定義される確率変数であるから，一般に陽な表現をもつとは限らない．したがって，ゴールである $\sqrt{n}(\hat{\theta}_n - \theta_0)$ の分布収束も，ある関数の収束によって示す必要がありそうである．

このことは，スコア関数に対する平均値の定理を考えることで達成される．いま，対数尤度関数 $l_n(\theta; \boldsymbol{X}_n)$ は θ に関して C^2-級であるとする．最尤推定量は，定義より（細かいことを無視すれば）

$$\dot{l}_n(\hat{\theta}_n) = \frac{\partial}{\partial \theta} l_n(\theta; \boldsymbol{X}_n) \mid_{\theta=\hat{\theta}_n} = 0$$

をみたす．ここで，ランダムなベクトル値関数 $\dot{l}_n(\theta)$ に対する平均値の定理より，

$$\dot{l}_n(\theta) - \dot{l}_n(\theta_0) = \left(\int_0^1 \ddot{l}_n(\theta_0 + u(\theta - \theta_0)) du \right) (\theta - \theta_0)$$

が成り立つことに注意すると, $\theta = \hat{\theta}_n$ とすれば

$$\frac{1}{\sqrt{n}}\dot{l}_n(\theta_0) = -\left(\int_0^1 \frac{1}{n}\ddot{l}_n(\theta_0 + u(\hat{\theta}_n - \theta_0))du\right)\sqrt{n}(\hat{\theta}_n - \theta_0).$$

これで, 我々が注目している $\sqrt{n}(\hat{\theta}_n - \theta_0)$ に関する表現を得ることができた. いまやったことは, ある意味でニュートン法の逆である. $\dot{l}_n(\theta) = 0$ の根が $\hat{\theta}_n$ とわかっている状態で, 傾き $\ddot{l}_n(\theta_0)$ と $(\theta_0 - \hat{\theta}_n)$ をかけた値が近似的に $\dot{l}_n(\theta_0)$ に等しいことを利用しているのを確かめよう.

さて, さらに大雑把な議論になるが, $\hat{\theta}_n$ の一致性より $\theta_0 + u(\hat{\theta}_n - \theta_0) \approx \theta_0$ とみなしてよいことにする. このとき,

$$-\left(\int_0^1 \frac{1}{n}\ddot{l}_n(\theta_0 + u(\hat{\theta}_n - \theta_0))du\right) \approx -\frac{1}{n}\ddot{l}_n(\theta_0) \xrightarrow{p} I(\theta_0).$$

ここで, $I(\theta_0)$ はフィッシャー情報量であった. さらに, 中心極限定理より

$$\frac{1}{\sqrt{n}}\dot{l}_n(\theta_0) \xrightarrow{d} N(0, I(\theta_0)).$$

これらをもとに, 先ほどの等式の両辺に $I^{-1}(\theta_0)$ をかけて極限をとれば, Slutsky の定理より

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} I^{-1}(\theta_0)N(0, I(\theta_0)) = N(0, I^{-1}(\theta_0)).$$

以上の議論により, ざっくりとではあるが, 最尤推定量が一致性と漸近正規性をもつだろうということが分かった. 次節では, 尤度関数による最尤推定の枠組みを, 「推定関数による Z-推定」にまで一般化させながら, 一致性と漸近正規性をもつ推定量の構成のための本質的な条件について考察する.

Q2. 本節では, 何に対する中心極限定理が最尤推定量の漸近正規性を導いたか？

4.2 M-estimation and Z-estimation

最尤法は, 確かに, 一致性と漸近正規性をもつ推定量の構成方法として非常に有力である. しかし実のところ, 最尤法は「いい感じの関数を用意して, その関数の最大化で推定量を定義している」ことが本質なのであって, 対数尤度関数にこだわらずとも, 一致性と漸近正規性をみたすような推定量を作れることがわかっている. 本節では, 関数を使った推定量の構成方法についての一般化を行い, それにより定まる推定量が一致性と漸近正規性をみたすための条件について確認する.

Definition 4.3: M-推定量と Z-推定量

(a) あるランダムな $\mathbb{R}$-値関数 $\Psi_n(\theta) = M(\boldsymbol{X}_n, \theta)$ について, 推定量 $\hat{\theta}_n$ が

$$\Psi_n(\hat{\theta}_n) = \inf_{\theta \in \Theta} \Psi_n(\theta)$$

をみたすとき, $\Psi_n(\theta)$ を**コントラスト関数** (contrast function) といい, $\hat{\theta}_n$ を **M-推定量** (M-estimator) という.
(b) あるランダムな $\mathbb{R}^p$-値関数 $\Phi_n(\theta) = Z(\boldsymbol{X}_n, \theta)$ について, 推定量 $\hat{\theta}_n$ が

$$\Phi_n(\hat{\theta}_n) = 0$$

をみたすとき, $\Phi_n(\theta)$ を**推定関数** (estimating function) といい, $\hat{\theta}_n$ を **Z-推定量** (Z-estimator) という. 方程式 $\Phi_n(\theta) = 0$ は**推定方程式** (estimating equation) とよばれる.

M-推定量が最大化ではなく最小化によって定義されているのは単なる慣習であり, 深い意味はない. 本稿では特に Z-推定量の方に注目して議論を進めるが, 両者は一定の条件の下で行ったり来たりできることに注意されたい. 実際, コントラスト関数 $\Psi_n(\theta)$ が θ で微分可能かつ, 最小値を Θ の内点でとるとき, 推定関数 $\Phi_n(\theta)$ を $\frac{\partial}{\partial\theta}\Psi_n(\theta)$ で定義すれば, Ψ_n に関する M-推定量は Φ_n に関する Z-推定量でもある. また, 先に推定関数 $\Phi_n(\theta)$ が与えられたときには, コントラスト関数 $\Psi_n(\theta)$ を $|\Phi_n(\theta)|$ で定義すれば, Φ_n に関する Z-推定量は Ψ_n に関する M-推定量でもある. したがって, 両者の間には本質的な違いはなく, どちらを採用するかは単に流儀の問題である.

Example 4.1: 最尤推定量

Definition 2.2 の最尤推定量は,

$$\Psi_n(\theta) := -\frac{1}{n} l_n(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log f(X_i;\theta)$$

なるコントラスト関数に関する M-推定量である. また, 上に述べたような適当な条件の下では, 最尤推定量は

$$\Phi_n(\theta) := \frac{1}{n}\frac{\partial}{\partial\theta} l_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \frac{\partial}{\partial\theta}\log f(X_i;\theta)$$

なる推定関数に関する Z-推定量でもある. 推定関数がスコア関数で定まっていることに由来して, この場合の推定方程式を**スコア方程式**ともよぶ.

あらかじめ n で割った形を考えているのは, 単にそのまま大数法則が成り立つ形にしておくためであり, やはり深い意味はない.

Example 4.2: モーメント推定量

パラメータの次元 p だけ関数 $g_1, g_2, \ldots, g_p$ を用意し, 推定関数を

$$\Phi_n^{(k)}(\theta) := \frac{1}{n}\sum_{i=1}^{n} g_k(X_i) - \mathrm{E}_\theta[g_k(X)] \quad (k = 1, 2, \ldots, p)$$

によって定義する. この推定関数によって定まる Z-推定量は, ある関数たちの標本モーメントと一致するような分布を選択することに由来して, **モーメント推定量**とよばれる.

Example 4.3: 最小二乗推定量

線形回帰モデル $\mathbf{Y} = \boldsymbol{X}\theta_0 + \varepsilon$ において, θ_0 の**最小二乗推定量**は, コントラスト関数

$$\Psi_n(\theta) := \frac{1}{n}(\mathbf{Y} - \boldsymbol{X}\theta)^\top(\mathbf{Y} - \boldsymbol{X}\theta)$$

に関する M-推定量として定義される. 一階条件を考えれば, 推定関数

$$\Phi_n(\theta) := \frac{1}{n}\boldsymbol{X}^\top(\mathbf{Y} - \boldsymbol{X}\theta)$$

に関する Z-推定量としてみることもできる. この場合の推定方程式は**正規方程式**とよばれる.

このように, よく知られた様々な推定量は, ある関数を用いた M-推定量や Z-推定量としても表現することができる. したがって, M-推定量や Z-推定量の一致性と漸近正規性を一般的な設定の下で示すことができれば, その特別な場合としてかける推定量たちに対しても, 自動的にそれらの性質を証明したことになる点に注意しよう.

Theorem 4.4: Z-推定量の一致性

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ と推定関数 $\Phi_n(\theta)$ について以下を仮定する.
(i) (一様大数の法則) あるノンランダムな関数 $\Phi(\theta)$ が存在して,

$$\sup_{\theta\in\Theta} |\Phi_n(\theta) - \Phi(\theta)| \xrightarrow{p} 0.$$

(ii) (識別可能条件) 関数 $\Phi(\theta)$ は次をみたす.

$$\inf_{|\theta-\theta_0|>\varepsilon} |\Phi(\theta)| > |\Phi(\theta_0)| = 0 \quad ({}^\forall\varepsilon > 0).$$

このとき, $\Phi_n(\theta)$ に関する Z-推定量 $\hat{\theta}_n$ は一致性をみたす.

Proof. 仮定 (i) と Z-推定量 $\hat{\theta}_n$ の定義より,

$$\begin{aligned}|\Phi(\hat{\theta}_n)| &\leq |\Phi(\hat{\theta}_n) - \Phi_n(\hat{\theta}_n)| + |\Phi_n(\hat{\theta}_n)| \\ &\leq \sup_{\theta\in\Theta} |\Phi(\theta) - \Phi_n(\theta)| + |\Phi_n(\hat{\theta}_n)| = o_P(1).\end{aligned}$$

識別可能条件に注意すると, 任意の $\varepsilon > 0$ に対して, ある $c > 0$ が存在して

$$|\theta - \theta_0| > \varepsilon \quad \Rightarrow \quad |\Phi(\theta)| > c$$

であるから,

$$\mathrm{P}\left(|\hat{\theta}_n - \theta_0| > \varepsilon\right) \leq \mathrm{P}\left(|\Phi(\hat{\theta}_n)| > c\right) \to 0.$$

すなわち, $\hat{\theta}_n$ は θ_0 の一致推定量である. □

2.1 節で述べた直観そのものとは少し異なる流儀になっているが, 「ノンランダムな神様の物差しをランダムな物差しによって近似する」点は共通していて, ここでは前者の物差しが $\Phi(\theta)$ に, 後者の物差しが $\Phi_n(\theta)$ に対応している. 一様大数の法則は, 一様性を除いた確率収束が成り立っていれば, 可積分性に関する追加的な条件を課すことによって示すことができる.

Q3. 識別可能条件 (ii) が, Φ を神様の物差したらしめる条件になっていることを直観できるか？

続いて, Z-推定量が漸近正規性をみたすための条件を確認する.

Theorem 4.5: Z-推定量の漸近正規性

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ と推定関数 $\Phi_n(\theta)$ について, $\Phi_n(\theta)$ に関する Z-推定量 $\hat{\theta}_n$ は一致性をみたすとし, さらに以下を仮定する.

(i) $\Theta \subset \mathbb{R}^p$ は有界閉凸集合であり, $\theta_0 \in \mathrm{Int}(\Theta)$.

(ii) $\Phi_n \in C^1(\Theta)$ a.s., $\Phi \in C^1(\Theta)$.

(iii) ある $\mathbb{R}^p$-値確率変数 Z が存在して, $\sqrt{n}\Phi_n(\theta_0) \xrightarrow{d} Z$.

(iv) $\nabla_\theta \Phi(\theta_0)$ は正則行列.

(v) $\sup_{\theta\in\Theta} |\nabla_\theta \Phi_n(\theta) - \nabla_\theta \Phi(\theta)| \xrightarrow{p} 0$.

このとき, $\Phi_n(\theta)$ に関する Z-推定量 $\hat{\theta}_n$ は次をみたす：

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} -[\nabla_\theta \Phi(\theta_0)]^{-1} Z.$$

とくに, 確率変数 Z が正規分布にしたがうならば, $\hat{\theta}_n$ は漸近正規性をみたす.

Proof. 基本的な方針についてのみ述べる[*7]. まず, 仮定 (i) と (ii) から, ベクトル値関数 $\Phi_n(\theta)$ に対する平均値の定理が使えて,

$$\Phi_n(\hat{\theta}_n) - \Phi_n(\theta_0) = \left(\int_0^1 \nabla_\theta \Phi_n(\theta_0 + u(\hat{\theta}_n - \theta_0))du\right)(\hat{\theta}_n - \theta_0).$$

[*7] 証明は清水 (2023) p.100-101 による.

左辺第 1 項はゼロである．ここで, 事象 $A_n = A_n^1 \cap A_n^2 \in \mathcal{B}^n$ を次のように定める．

$$A_n^1 = \{\hat{\theta}_n \in \mathrm{Int}(\Theta)\}, \quad A_n^2 = \{|\det J_n| > |\det \nabla_\theta \Phi(\theta_0)|/2\}$$

$$\text{where } \ J_n = \int_0^1 \nabla_\theta \Phi_n(\theta_0 + u(\hat{\theta}_n - \theta_0))du.$$

このとき, 実は $\mathrm{P}_{\theta_0}^n(A_n) \to 1$ が成り立つ．A_n 上では J_n は正則行列であることに注意し[*8],

$$\begin{aligned}\sqrt{n}(\hat{\theta}_n - \theta_0) &= -J_n^{-1}\sqrt{n}\Phi_n(\theta_0)\mathbb{1}_{A_n} + \sqrt{n}(\hat{\theta}_n - \theta_0)\mathbb{1}_{A_n^c} \\ &=: Z_n^{(1)} + Z_n^{(2)}.\end{aligned}$$

$Z_n^{(2)} \xrightarrow{p} 0$ より, $Z_n^{(1)}$ の漸近挙動に注目すればよい．実は,

$$J_n^{-1}\mathbb{1}_{A_n} \xrightarrow{p} \nabla_\theta \Phi(\theta_0)^{-1}$$

が成り立ち, これと仮定 (iii) を合わせれば

$$Z_n^{(1)} \xrightarrow{d} -[\nabla_\theta \Phi(\theta_0)]^{-1} Z.$$

Slutsky の定理より結論を得る． □

特に最尤推定量について漸近正規性を示したければ, 統計的実験とスコア関数が上の定理の条件をみたすことを示せばよいのである．

Q4. Example 4.1 のように推定関数を定めれば, Theorem 4.5 の結果が 4.1 節で導いた予想に対応することを確かめてみよう．

以上 2 つの大きな定理をまとめると, 一致性と漸近正規性をみたす推定量を構成するために示すべき条件は大まかに次の 3 つに整理できる．

1. $\Phi_n(\theta)$ と $\nabla_\theta \Phi_n(\theta)$ に対する一様大数の法則.
2. $\Phi_n(\theta)$ の極限 $\Phi(\theta)$ の識別可能条件.
3. $\sqrt{n}\Phi_n(\theta)$ に対する中心極限定理.

すなわち, **よい推定量の構成は, よい推定関数の構成によって達成される．**

また, 上の 2 つの定理の証明においては, i.i.d. であることを一切使っていない点に注意しよう．すなわち, i.i.d. でないような統計的実験においても, かわりに何らかの極限定理や仮定を用いて一様大数の法則や推定関数の中心極限定理を示すことさえできれば, 一般に Z-推定量の一致性と漸近正規性を示すことが可能なのである．

[*8] J_n^{-1} を, A_n 上では J_n の逆行列, A_n^c 上では単位行列などと定めることによって

5 What is the Best Estimator?

4 章において,「よい推定量とは,（任意の θ_0 について）分布が θ_0 のまわりに集中している推定量である」と述べた. そして, 具体的な性質として一致性と漸近正規性を導入し, それらをみたす推定量を構成するためには, よい推定関数を構成すればよいことが明らかになった. 推定関数は, 最尤法に則ってスコア関数から定めてもよいし, 他にも, Theorem 4.4, 4.5 の仮定をみたす限りにおいてどんな推定関数でも考えることができる.

では,「漸近正規性をみたす推定量の中で最もよい推定量」は何だろうか. 素朴に考えれば, それは「漸近分布が真値のまわりに最も集中している推定量」になるだろう. 本章でやりたいことは, 3.2 節で述べた有効性概念の漸近統計版：**漸近有効性**の定式化を試み, 漸近有効な推定量の正体について考えることである.

5.1 Hodge's Counter Example

3.2 節では, クラメール-ラオの不等式が不偏推定量の分散の下限を与えることを利用して, 分散がその下限に等しい不偏推定量が存在すれば, それを有効推定量とよぶことを述べた. この結果を漸近統計に移植することはできないだろうか. 4 章でみたように, 漸近正規性をみたす推定量は, 定義より漸近分布のバイアスがゼロになっている. このことは**漸近不偏性**ともよばれる. もし, 漸近不偏な推定量に対するクラメール-ラオの不等式のような何かがあるとすれば, 漸近正規性をみたす推定量たちの漸近分散の下限は, おなじくフィッシャー情報量の逆行列で与えられるはずだ.

予想. どんな漸近正規性をみたす推定量 $\hat{\theta}_n$ に対しても, その漸近分布 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, \Sigma(\theta_0))$ について, $\Sigma(\theta_0) \geq I(\theta_0)^{-1}$ が（二次形式の意味で）成り立つ.

R.A.Fisher は上述した先駆的な業績の中でこのように予想した. この予想は, 半分正しく, 半分間違っている.

Definition 5.1: Fisher の意味で漸近有効

フィッシャー情報量 $I(\theta_0)$ について, $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1})$ をみたす推定量 $\hat{\theta}_n$ は, **Fisher の意味で漸近有効**であるという.

このように定義された漸近有効性が, 実のところ意図した定義になっていないことが, Hodges によって 1951 年に指摘された. このままでは, $I(\theta_0)^{-1}$ は漸近分散の下限にはなれないのである.

Example 5.1: Hodges の反例

パラメータは 1 次元とする．$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1})$ をみたす推定量 $\hat{\theta}_n$ があるとする．いま，あらたな推定量 $\check{\theta}_n$ を，任意に fix した $\alpha \in (0,1)$ に対して

$$\check{\theta}_n := \hat{\theta}_n \mathbb{1}_{\{|\hat{\theta}_n| > n^{-1/4}\}} + \alpha \hat{\theta}_n \mathbb{1}_{\{|\hat{\theta}_n| \le n^{-1/4}\}}$$

で定める．このとき，

$$\sqrt{n}(\check{\theta}_n - \theta_0) \xrightarrow{d} \begin{cases} N(0, I(\theta_0)^{-1}) & (\theta_0 \neq 0), \\ N(0, \alpha^2 I(\theta_0)^{-1}) & (\theta_0 = 0). \end{cases}$$

したがって，もしも真値が $\theta_0 = 0$ であれば，$\check{\theta}_n$ はもとの推定量 $\hat{\theta}_n$ よりも厳密に小さい漸近分散をもち，そうでなければ同じ漸近分布をもつ．α はいくらでも 0 に近づけることができ，このことは，現状だと漸近分散の下限を構成することはできないことを意味する．

つまり，上の予想は $\theta_0 = 0$ において破られている．Hodges の反例は，ある点（上の例では 0）を決め打ちして局所的に推定量を Shrink させることによって，その点が真値のときのパフォーマンスをブーストしているのである．このように言うと聞こえはいいが，実際には，決め打ちした点と真値がわずかにズレているような場合には，誤って決め打ちした値に推定量が吸い寄せられることになり，挙動が不安定になってしまう．正確には 8 章でみるが，推定量のよさをはかる「リスク関数」が，真値の近傍で病的なふるまいをすることが分かっている．

5.2 To the Efficiency Theory

では，どうすればよいか．4.1 節での議論を思い出そう．推定量の有効性の議論は，まずは期待値によって予選を行い，その後に分散によって決勝戦を行う，というように進んだ．5.1 節の漸近有効性においては，まずは漸近正規性によって予選を行い，漸近分散によって決勝戦を行っている．そうすると，勝者と予想していた推定量は，実際には Hodges の反例というあまり望ましくない抜け道により打倒されてしまう，というのが現在の状況である．

したがって，ひとつの方策として，「予選のしかたを工夫する」ということが考えられる．つまり，Hodges の反例が決勝戦に参加できないような基準を予選のうちに課しておけばよいのだ．それが，推定量の**正則性**と呼ばれる概念である．真値の近傍での病的なふるまいを許さないように，真の分布に近づいていくようなあらたな分布の列（分布の摂動）を考え，その列の下でも安定的に分布収束することを推定量に要請するのである．

今後の議論は，Asymptotic Statistics に沿って以下のように進む：

- 6 章で，漸近分布の測度変換に関する重要ツール：Le Cam の第三補題について抑える
- 7 章で，きれいな統計的実験の下では，摂動した分布の下でも推定量が分布収束する（正則とは限らない）場合，その漸近分布は強く拘束されることをみる．

- 8 章で, きれいな統計的実験の下では, 任意の正則な推定量の漸近分布は, $N(0, I(\theta_0)^{-1})$ およびそれと独立なある分布との畳み込みになることをみる.

最後の事実を Hájek–Le Cam の畳み込み定理という. これをよりどころに, きれいな統計的実験の下で $N(0, I(\theta_0)^{-1})$ に収束する正則な推定量を**畳み込み定理の意味で漸近有効である**という.

Q5. 4 章の議論より, 最尤推定量は適当な仮定の下で $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1})$ をみたす. 最尤推定量が畳み込み定理の意味で漸近有効であることを示すには, 何を証明すれば十分だろうか？

正則な推定量のクラスは, 統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n \,;\, \theta \in \Theta\})$ さえ決めれば固定されてしまう. つまり, **ひとたび統計的実験が定まれば, 推定量のよさの限界も定まる.** これが有効性理論の神髄だ. そして多くの場合, その限界に達する推定量の作り方は最尤法なのである.

さらに遠くまで見ると, 本勉強会の最終ゴールはセミパラメトリック有効性理論のフォローである. 上で行った議論はすべて, パラメトリックな設定：統計モデルが有限個の実数の組み合わせによって対応づけられている場合の議論であった. この設定は非常に制約的である. 実際の統計学的分析においては, データが i.i.d. に得られていること以外何もわかっていない, というような場合も多い. そのときには, 無理にパラメトリックモデルに押し込もうとするのではなく, わかっている条件以外にはどんなバリエーションも許容する「セミパラメトリックモデル」を用いるべきだ. セミパラメトリックモデルに対しても有効性理論を展開することができ, i.i.d. のプレーンな設定における漸近統計の結論と呼んでも差し支えないものになる. セミパラメトリックモデル下での最もよい推定量の構成方法は, 愚直な最尤法とは少し趣が異なり, 機械学習的な手法との融合によって筋よく与えられることが, 最近の研究で盛んに調べられている. 我々はその理論を目指して進む.

以降の記法に関する補足

以降の章では, 「確率変数を異なる確率測度の列の下で分布収束させる」議論が続き, 分布収束をすべて $\xrightarrow{d}$ とかくと紛らわしくなるため, ここでノーテーションについて補足しておく.

可測空間 $(\mathcal{X}^n, \mathcal{A}^n)$ とその上のある確率測度 P^n について考える. ここで, 確率変数列 $S_n : \mathcal{X}^n \to \mathbb{R}^k$ が P^n の下で S に分布収束するとは, S_n による P^n の push-forward が S の分布に弱収束することをいう. つまり, 任意の有界連続関数 $f : \mathbb{R}^k \to \mathbb{R}$ に対して,

$$\mathrm{E}_{\mathrm{P}^n}[f(S_n)] \to \mathrm{E}[f(S)].$$

が成り立つことをいう. このことを $S_n \overset{\mathrm{P}^n}{\Longrightarrow} S$ とかく. 本来ならば, S が住んでいる確率空間についても明示しなければならない (上の収束先の期待値がどの確率測度の下でとられているかが不明になってしまう) が, Asymptotic Statistics では基本的にこれを省略しているように思われる. 断りがなければ, 分布収束先の確率変数は適当な確率空間 $(\mathcal{S}, \mathcal{F}, \mathrm{P})$ 上に定まっているものとし, 上の定義において $\mathrm{E}[f(S)]$ は P の下での期待値であるとする. このような定義においても, Portmanteau の同値な言いかえは同様に成り立つことに注意する.

その他, 確率変数列の分布に関して定義された諸性質や示された主張は, もとの確率基の確率測度を P から P^n に置き換えてしまっても (その push-forward にしか依存しないので) 同様に書き換えられる.

6 Contiguity

Contiguity とは,「漸近的絶対連続性」を定式化したものである. 語感から想像されるように, この性質は漸近分布どうしの測度変換を可能にするための十分条件としてはたらく. まずは通常の測度変換について復習したのち, Contiguity の定義および Le Cam の第 1 補題, 第 3 補題についておさえよう.

6.1 Likelihood Ratios

ある可測空間 $(\mathcal{X}, \mathcal{A})$ と, その上の確率測度 P, Q があるとする. Q が P に関して**絶対連続** (absolutely continuous) であるとは,

$$^{\forall}A \in \mathcal{A}, \quad P(A) = 0 \;\; \Rightarrow \;\; Q(A) = 0$$

が成り立つことをいい, $\mathrm{Q} \ll \mathrm{P}$ とかく. また, Q が P と**直交** (orthogonal) しているとは, ある $\mathcal{X}_P, \mathcal{X}_Q \in \mathcal{A}$ が存在して,

$$\mathcal{X} = \mathcal{X}_P + \mathcal{X}_Q, \quad \mathrm{P}(\mathcal{X}_Q) = \mathrm{Q}(\mathcal{X}_P) = 0$$

が成り立つことをいい, $\mathrm{Q} \perp \mathrm{P}$ とかく.

本章では, $(\mathcal{X}, \mathcal{A})$ 上のある σ-有限測度 μ が存在して, $\mathrm{P}, \mathrm{Q} \ll \mu$ であるとする. 対応する確率密度関数を p, q とかく. ここで, $\mathcal{X}_p = \{p > 0\}, \mathcal{X}_q = \{q > 0\}$ とおくと, Q は次のような (P に依存して定まる) 分解をもつ.

$$^{\forall}A \in \mathcal{A}, \quad \mathrm{Q}^a(A) := \mathrm{Q}(A \cap \{p > 0\}), \; \mathrm{Q}^{\perp}(A) := \mathrm{Q}(A \cap \{p = 0\}).$$

$\mathrm{Q} = \mathrm{Q}^a + \mathrm{Q}^{\perp}$ が成り立ち, これを Q の P による**ルベーグ分解** (Lebesgue decomposition) とよぶ. また,

$$\frac{\mathrm{dQ}}{\mathrm{dP}} = \frac{q}{p}$$

を Q の P に対する**尤度比** (likelihood ratio) という. ただし, $p = 0$ の点では任意に値を定めることにする. この場合でも, 尤度比は P-a.s. で well-defined であることに注意する.

Lemma 6.1: 絶対連続性の同値な言いかえ

(i) $\mathrm{Q} = \mathrm{Q}^a + \mathrm{Q}^{\perp}$, $\mathrm{Q}^a \ll \mathrm{P}$, $\mathrm{Q}^{\perp} \perp \mathrm{P}$.
(ii) $\mathrm{Q}^a(A) = \int_A (q/p)\mathrm{dP} \;\; (A \in \mathcal{A})$.
(iii) $\mathrm{Q} \ll \mathrm{P} \;\Leftrightarrow\; \mathrm{Q}(p = 0) = 0 \;\Leftrightarrow\; \int (q/p)\mathrm{dP} = 1$.

Proof. (i) 定義より明らか.

(ii) 次式よりしたがう：

$$\mathrm{Q}^a(A) = \int_{A\cap\{p>0\}} q \,\mathrm{d}\mu = \int_{A\cap\{p>0\}} \frac{q}{p} p \,\mathrm{d}\mu = \int_{A\cap\{p>0\}} \frac{q}{p}\mathrm{dP} = \int_A \frac{q}{p}\mathrm{dP}.$$

(iii) まず, (i) と定義より $\mathrm{Q} \ll \mathrm{P} \;\Leftrightarrow\; \mathrm{Q}^\perp = 0 \;\Leftrightarrow\; \mathrm{Q}(p=0) = 0$ であるから, 一つ目の主張を得る. また, (ii) について $A = \mathcal{X}$ とおけば,

$$\mathrm{Q}^a(\mathcal{X}) = \int \frac{q}{p}\mathrm{dP}.$$

これが 1 であることと $Q^\perp = 0$ であることは同値であるから, 二つ目の主張を得る. □

測度論において, ラドン=ニコディム微分やそれを用いた測度変換は, 絶対連続な測度の組においてのみ定義されるものであった. 実際, Lemma 6.1(iii) は, 測度変換は Q が P に関して絶対連続なときにしか等号で成り立たないことを意味する. その一方で, 以降で扱うのは「漸近的絶対連続性」なので, n ごとに定まっている 2 つの測度自体が絶対連続であるとは限らない. 尤度比 dQ/dP を P-a.s. で定義しているのはこのような事情による. すなわち, 確率変数 $S : \mathcal{X} \to \mathbb{R}^k$ と非負可測関数 $f : \mathbb{R}^k \to \mathbb{R}$ に対して, 一般には次の**不等式**が成り立つ.

$$\begin{aligned}\int f(S)\,\mathrm{dQ} = \int f(S) q \,\mathrm{d}\mu &\geq \int_{\{p>0\}} f(S) q \,\mathrm{d}\mu \\ &= \int_{\{p>0\}} f(S)\frac{q}{p} p \,\mathrm{d}\mu = \int_{\{p>0\}} f(S)\frac{\mathrm{dQ}}{\mathrm{dP}}\,\mathrm{dP} = \int f(S)\frac{\mathrm{dQ}}{\mathrm{dP}}\,\mathrm{dP}.\end{aligned}$$

つまり, p のサポートの外でのふるまいが, 尤度比の定義や P による積分から無視されてしまうことによって, 測度変換の途中でボリュームが抜け落ちてしまっている. Q のうち P と直交する部分の情報は, 尤度比による復元が不可能なのである. この不等式は以降でもたびたび用いるため注意されたい.

6.2 Contiguity

もしも $\mathrm{Q} \ll \mathrm{P}$ ならば, ラドン=ニコディムの定理より, 任意の $B \in \mathcal{B}(\mathbb{R}^k)$ に対して

$$\mathrm{Q}(S \in B) = \mathrm{E}_\mathrm{P}\left[\mathbb{1}_B(S)\frac{\mathrm{dQ}}{\mathrm{dP}}\right]$$

が成り立つ. さらに, このことと standard machine から, Q-可積分であるか非負の $f(S)$ については

$$\mathrm{E}_\mathrm{Q}[f(S)] = \mathrm{E}_\mathrm{P}\left[f(S)\frac{\mathrm{dQ}}{\mathrm{dP}}\right]$$

もしたがう. このような測度変換公式の漸近分布版をつくることが本節の目標である. ラドン=ニコディムの定理が無条件に成り立つものではなかったように, その漸近分布版においても適切な仮定が必要になる.

Definition 6.1: Contiguity

可測空間の列 $(\mathcal{X}^n, \mathcal{A}^n)$ と, その上の確率測度の列 $\mathrm{P}^n, \mathrm{Q}^n$ があるとする. Q^n が P^n に関して **contiguous** であるとは,

$$^\forall\{A_n\}\ (A_n \in \mathcal{A}^n), \quad \mathrm{P}^n(A_n) \to 0 \ \Rightarrow\ \mathrm{Q}^n(A_n) \to 0$$

が成り立つことをいい, $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ とかく. また, $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ かつ $\mathrm{Q}^n \triangleright \mathrm{P}^n$ が成り立つとき, P^n と Q^n は **mutually contiguous** であるといい, $\mathrm{Q}^n \triangleleft\triangleright \mathrm{P}^n$ とかく.

$\mathrm{Q}^n \triangleleft \mathrm{P}^n$ と, n ごとの $\mathrm{Q}^n \ll \mathrm{P}^n$ の間には, 直接の包含関係は存在しないことに注意する. contiguity は極限に対する条件であるから, contiguous だが n ごとに絶対連続でない例の構成は簡単である. n ごとに絶対連続だが contiguous でない例は, 2 つの正規分布の列 $P^n = N(0,1), Q^n = N(\theta_n, 1)$ について, θ_n が非有界な場合を考えればよい.

その一方で, Lemma 6.1 の contiguity バージョンをつくることは可能である. これは Le Cam の第 1 補題とよばれている. そのステートメントを把握するうえで, Lemma 6.1 (iii) における尤度比の立ち位置について理解しておこう. まず, $\mathrm{dP}^n/\mathrm{dQ}^n$ が Q^n-a.s. で定義されていることに注意すれば, $\mathrm{Q}^n(\mathrm{dP}^n/\mathrm{dQ}^n > 0) = 1$ が 1 つ目の同値記号に対応する条件だとわかる. また, $\int(\mathrm{dQ}^n/\mathrm{dP}^n)\mathrm{dP}^n = 1$ は 2 つ目の同値記号に対応する条件となる. 実際にはこれらの条件を, 尤度比の (部分) 列の分布収束先に対して適用すればよいことが, 次の補題により明らかになる.

さらなる補足として, 尤度比は非負なので, 6.1 節の最後に述べた不等式において $f \equiv 1$ として

$$\mathrm{E}_{\mathrm{P}^n}\left[\frac{\mathrm{dQ}^n}{\mathrm{dP}^n}\right] \le 1, \quad \mathrm{E}_{\mathrm{Q}^n}\left[\frac{\mathrm{dP}^n}{\mathrm{dQ}^n}\right] \le 1$$

が成り立つ点に注目する. すなわち, $(\mathrm{dQ}^n/\mathrm{dP}^n)$ は P^n の下で L^1-有界であり, $(\mathrm{dP}^n/\mathrm{dQ}^n)$ は Q^n の下で L^1-有界である. したがって Example 2.6 より, $(\mathrm{dQ}^n/\mathrm{dP}^n)$ は P^n の下で tight であり, $(\mathrm{dP}^n/\mathrm{dQ}^n)$ は Q^n の下で tight である. つまり, Contiguity とは無関係に, Prohorov の定理より尤度比の任意の部分列に対してさらなる部分列に対する分布収束を導くことができる. 次の補題の証明にあたっては, このことをうまいこと活用する.

Lemma 6.2: Le Cam's first lemma

以下の 4 条件は同値である.

(i) $\mathrm{Q}^n \triangleleft \mathrm{P}^n$.

(ii) 任意の $\{n\}$ の部分列 $\{n'\}$ について, $\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} \xRightarrow{\mathrm{Q}^{n'}} U$ ならば $\mathrm{P}(U > 0) = 1$.

(iii) 任意の $\{n\}$ の部分列 $\{n'\}$ について, $\frac{\mathrm{dQ}^{n'}}{\mathrm{dP}^{n'}} \xRightarrow{\mathrm{P}^{n'}} V$ ならば $\mathrm{E}[V] = 1$.

(iv) 任意の統計量 $T_n : \mathcal{X}^n \to \mathbb{R}^k$ について, $T_n \xRightarrow{\mathrm{P}^n} 0$ ならば $T_n \xRightarrow{\mathrm{Q}^n} 0$.

Proof. (i)⇔(iv) : (⇒) を示すには, $A_n := \{|T_n| > \varepsilon\}$ とおけばよい. (⇐) を示すには, $T_n := \mathbb{1}_{A_n}$

とおけばよい.
(i)⇒(ii)：$\varepsilon > 0$ ごとに定まる実数列を

$$g_n(\varepsilon) := \mathrm{Q}_n\left(\frac{\mathrm{dP}^n}{\mathrm{dQ}^n} < \varepsilon\right) - \mathrm{P}(U < \varepsilon)$$

で定義する．まず, 仮定と Portmanteau(v) より, 任意の $\varepsilon > 0$ に対して,

$$\begin{aligned}\liminf_{n'\to\infty} g_{n'}(\varepsilon) &= \liminf_{n'\to\infty} \mathrm{Q}_{n'}\left(\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} < \varepsilon\right) - \mathrm{P}(U < \varepsilon) \\ &\geq \mathrm{P}(U < \varepsilon) - \mathrm{P}(U < \varepsilon) = 0.\end{aligned}$$

したがって, 適当なレートで $\varepsilon_{n'} \downarrow 0$ とさせながら

$$\liminf_{n'\to\infty} g_{n'}(\varepsilon_{n'}) \geq 0$$

を成り立たせることも可能である．したがって,

$$\mathrm{P}(U = 0) = \lim_{n'\to\infty} \mathrm{P}(U < \varepsilon_{n'}) \leq \liminf_{n'\to\infty} \mathrm{Q}_{n'}\left(\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} < \varepsilon_{n'}\right).$$

その一方で,

$$\mathrm{P}^{n'}\left(\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} < \varepsilon_{n'} \ \wedge \ q_{n'} > 0\right) = \int_{\mathrm{dP}^{n'}/\mathrm{dQ}^{n'} \leq \varepsilon_{n'}} \frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} \mathrm{dQ}^{n'} \leq \int \varepsilon_{n'} \mathrm{dQ}^{n'} = \varepsilon_{n'} \to 0.$$

(i) を仮定していたから,

$$\mathrm{Q}^{n'}\left(\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} < \varepsilon_{n'}\right) = \mathrm{Q}^{n'}\left(\frac{\mathrm{dP}^{n'}}{\mathrm{dQ}^{n'}} < \varepsilon_{n'} \ \wedge \ q_{n'} > 0\right) \to 0.$$

尤度比の非負性と Portmanteau(v) より U が非負であることに注意すれば, $\mathrm{P}(U > 0) = 1 - \mathrm{P}(U = 0) = 1$ を得る.
(iii)⇒(i)：いま, $\mathrm{P}^n(A_n) \to 0$ であるとする．すると $\mathbb{1}_{\mathcal{X}^n - A_n} \overset{\mathrm{P}^n}{\Longrightarrow} 1$ であるから, Prohorov の定理より, 任意の部分列 $\{n'\}$ に対してさらなる部分列 $\{n''\}$ と確率変数 V が存在して,

$$\left(\frac{\mathrm{dQ}^{n''}}{\mathrm{dP}^{n''}}, \mathbb{1}_{\mathcal{X}^{n''} - A_{n''}}\right) \overset{\mathrm{P}^{n''}}{\Longrightarrow} (V, 1)$$

が成り立つ．ここで, 関数 $(v, t) \mapsto vt$ は $[0, \infty) \times \{0, 1\}$ 上で非負かつ連続であるから, Portmanteau(iv) より,

$$\begin{aligned}\liminf_{n\to\infty} \mathrm{Q}^{n''}(\mathcal{X}^{n''} - A_{n''}) &= \liminf_{n\to\infty} \int \mathbb{1}_{\mathcal{X}^{n''} - A_{n''}} \mathrm{dQ}^{n''} \\ &\geq \liminf_{n\to\infty} \int \mathbb{1}_{\mathcal{X}^{n''} - A_{n''}} \frac{\mathrm{dQ}^{n''}}{\mathrm{dP}^{n''}} \mathrm{dP}^{n''} \geq \mathrm{E}[1 \cdot V].\end{aligned}$$

(iii) の仮定の下では右辺は 1 であるから,

$$\mathrm{Q}^{n''}(A_{n''}) = 1 - \mathrm{Q}^{n''}(\mathcal{X}^{n''} - A_{n''}) \to 0.$$

収束先 0 は部分列の取り方によらないから, $\mathrm{Q}^n(A_n) \to 0$ を得る.
(ii)⇒(iii)：確率測度を $\mu^n := \frac{1}{2}(\mathrm{P}^n + \mathrm{Q}^n)$ で定義すると, $\mathrm{P}^n, \mathrm{Q}^n \ll \mu^n$ であり, 密度関数 $\frac{\mathrm{dP}^n}{\mathrm{d}\mu^n}, \frac{\mathrm{dQ}^n}{\mathrm{d}\mu^n}$ は閉区間 $[0,2]$ に値をとることに注意する. (iii) の前件に関する部分列を $\{n'\}$ とおくと, さらなるある部分列 $\{n''\}$ が存在して,

$$\frac{\mathrm{dP}^{n''}}{\mathrm{dQ}^{n''}} \xRightarrow{\mathrm{Q}^{n''}} U, \quad \frac{\mathrm{dQ}^{n''}}{\mathrm{dP}^{n''}} \xRightarrow{\mathrm{P}^{n''}} V, \quad W_n := \frac{\mathrm{dP}^{n''}}{\mathrm{d}\mu_{n''}} \xRightarrow{\mu^{n''}} W$$

となるようにできる[*9]. また, W_n は μ_n の下でつねに期待値が 1 であるから, 有界性に注意すれば $\mathrm{E}[W] = 1$ もしたがう.

ここで, 有界連続関数 $f : \mathbb{R} \to \mathbb{R}$ を任意にとって fix すると, 次で定まる関数 $g : [0,2] \to \mathbb{R}$ も有界連続関数になる：

$$g(w) := \begin{cases} f(w/(2-w))(2-w) & (w \in [0,2)), \\ 0 \quad (w = 2). \end{cases}$$

ここで,

$$\frac{\mathrm{dQ}^{n''}}{\mathrm{d}\mu_{n''}} = \frac{2\mathrm{d}\mu^{n''} - \mathrm{dP}^{n''}}{\mathrm{d}\mu^{n''}} = 2 - W_{n''}$$

かつ

$$\frac{\mathrm{dP}^{n''}}{\mathrm{dQ}^{n''}} = \frac{\mathrm{dP}^{n''}}{\mathrm{d}\mu_{n''}} \Big/ \frac{\mathrm{dQ}^{n''}}{\mathrm{d}\mu_{n''}} = \frac{W_{n''}}{2 - W_{n''}}$$

であるから, Portmanteau(ii) より,

$$\begin{aligned} \mathrm{E}_{\mathrm{Q}^{n''}}\left[f\left(\frac{\mathrm{dP}^{n''}}{\mathrm{dQ}^{n''}}\right)\right] &= \mathrm{E}_{\mu^{n''}}\left[f\left(\frac{\mathrm{dP}^{n''}}{\mathrm{dQ}^{n''}}\right)\frac{\mathrm{dQ}^{n''}}{\mathrm{d}\mu_{n''}}\right] \\ &= \mathrm{E}_{\mu^{n''}}\left[f\left(\frac{W_{n''}}{2 - W_{n''}}\right)(2 - W_{n''})\right] \\ &= \mathrm{E}_{\mu^{n''}}\left[g(W^{n''})\right] \\ &\to \mathrm{E}[g(W)] = \mathrm{E}\left[f\left(\frac{W}{2-W}\right)(2-W)\right]. \end{aligned}$$

仮定より, 左辺は $\mathrm{E}[f(U)]$ に収束するから,

$$\mathrm{E}[f(U)] = \mathrm{E}\left[f\left(\frac{W}{2-W}\right)(2-W)\right].$$

[*9] 実際には, 部分列はいっぺんにとれるわけではないので, U に関して部分列をとり, W に関してさらなる部分列をとったものを $\{n''\}$ とおく.

ただし, 右辺の被積分関数の $W=2$ における値は 0 とする. 有界連続関数の列 $\{f_m\}$ を $1 \geq f_m \downarrow \mathbb{1}_{\{0\}}$ となるようにとり, 各 f_m に対して成り立つ上式を考え優収束定理を用いれば,

$$\begin{aligned}
\mathrm{P}(U=0) &= \mathrm{E}[\mathbb{1}_{\{0\}}(U)] = \mathrm{E}[\lim_{m\to\infty} f_m(U)] \\
&= \lim_{m\to\infty} \mathrm{E}[f_m(U)] = \lim_{m\to\infty} \mathrm{E}\left[f_m\left(\frac{W}{2-W}\right)(2-W)\right] \\
&= \mathrm{E}\left[\mathbb{1}_{\{0\}}\left(\frac{W}{2-W}\right)(2-W)\right] \\
&= \mathrm{E}\left[\mathbb{1}_{\{W=0\}}(2-W)\right] = 2\mathrm{P}(W=0).
\end{aligned}$$

同様にして, $\mathrm{P}^{n''}$ と $\mathrm{Q}^{n''}$ を入れ替えて $\mathrm{E}_{\mathrm{P}^{n''}}\left[f\left(\frac{\mathrm{dQ}^{n''}}{\mathrm{dP}^{n''}}\right)\right]$ の極限を考えると, 任意の有界連続関数 $f:\mathbb{R}\to\mathbb{R}$ に対して

$$\mathrm{E}[f(V)] = \mathrm{E}\left[f\left(\frac{2-W}{W}\right)W\right]$$

を得る. ただし, 右辺の非積分関数の $W=0$ での値は 0 とする. 有界連続関数の列 f_m を $0 \leq f_m(x) \uparrow x$ となるようにとり, 各 f_m に対して成り立つ上式を考え単調収束定理を用いれば,

$$\mathrm{E}[V] = \mathrm{E}\left[\left(\frac{2-W}{W}\right)W\right] = \mathrm{E}\left[(2-W)\mathbb{1}_{\{W>0\}}\right] = 2\mathrm{P}(W>0)-1.$$

すなわち,

$$1 = 2\mathrm{P}(W=0) + 2\mathrm{P}(W>0) - 1 = \mathrm{P}(U=0) + \mathrm{E}[V].$$

(ii) を仮定しているので, $\mathrm{P}(U=0)=0$ であり, $\mathrm{E}[V]=1$ を得る. □

次の事実は, Le Cam の第 1 補題と第 3 補題のかけ橋となる.

Example 6.3: 尤度比の対数正規分布への収束と contiguity

いま,

$$\frac{\mathrm{dP}^n}{\mathrm{dQ}^n} \xRightarrow{\mathrm{Q}^n} e^{N(\mu,\sigma^2)}$$

であるとする. このとき, $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ であり, $\mathrm{Q}^n \triangleleft\triangleright \mathrm{P}^n$ であることと $\mu = -\frac{1}{2}\sigma^2$ であることは同値.

Proof. $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ であることは, 収束先について $\mathrm{P}(e^{N(\mu,\sigma^2)} > 0) = 1$ が成り立つことと Lemma 6.2(ii) よりただちにしたがう.

逆向きの contiguity : $\mathrm{P}^n \triangleleft \mathrm{Q}^n$ については, Lemma 6.2(iii) を, $\mathrm{P}^n, \mathrm{Q}^n$ の役割を入れ替えて用いることでわかる. すなわち, 収束先の期待値は正規分布の特性関数の $-i$ における値であることに注目し,

$$\mathrm{E}[e^{N(\mu,\sigma^2)}] = e^{\mu+\sigma^2/2} = 1 \quad\Leftrightarrow\quad \mu + \frac{\sigma^2}{2} = 0$$

より主張を得る. □

次の補題により本章の目標は達成される.

Lemma 6.4: 漸近分布の測度変換

$\mathrm{Q}^n \triangleleft \mathrm{P}^n$ であり, 確率変数列 $X_n : \mathcal{X}^n \to \mathbb{R}^k$ について

$$\left(X_n, \frac{\mathrm{dQ}^n}{\mathrm{dP}^n}\right) \overset{\mathrm{P}^n}{\Longrightarrow} (X, V).$$

が成り立つとする. このとき,

$$\mathrm{L} : \mathcal{B}(\mathbb{R}^k) \ni B \mapsto \mathrm{E}[\mathbb{1}_B(X)V] \in [0,1]$$

は確率測度となり, $X_n \overset{\mathrm{Q}^n}{\Longrightarrow} \mathrm{L}$ が成り立つ[a] .

[a] ステートメントをみると, 漸近分布の測度変換をしているというよりは, 「分布収束ごと変換している」といった方が正確かもしれない.

Proof. まず, $V \geq 0$ より, 単調収束定理から L が測度であることがわかる. また, $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ より Lemma 6.2 (iii) が使えて, $\mathrm{E}[V] = 1$ となるから, L は特に確率測度になっている. さらに standard machine によって, 非負であるか L-可積分である任意の $f : \mathbb{R}^k \to \mathbb{R}$ に対して

$$\int f \mathrm{dL} = \mathrm{E}[f(X)V]$$

が成り立つこともわかる.

ここで, 任意の非負連続関数 f を fix する. このとき, $(x, v) \mapsto f(x)v$ は $\mathbb{R}^k \times [0, \infty)$ 上の非負連続関数であるから, Portmanteau(iv) より,

$$\begin{aligned}\liminf_{n\to\infty} \mathrm{E}_{\mathrm{Q}^n}[f(X_n)] &\geq \liminf_{n\to\infty} \int f(X_n) \frac{\mathrm{dQ}^n}{\mathrm{dP}^n} \mathrm{dP}^n \\ &\geq \mathrm{E}[f(X)V] = \int f \mathrm{dL} = \mathrm{E}_{\mathrm{L}}[f(X)].\end{aligned}$$

ふたたび Portmanteau(iv) を, Q^n の X_n による push-forward に適用することで, $X_n \overset{\mathrm{Q}^n}{\Longrightarrow} \mathrm{L}$ を得る. □

Lemma 6.5: Le Cam's third lemma

確率変数列 $X_n : \mathcal{X}^n \to \mathbb{R}^k$ について

$$\left(X_n, \log \frac{\mathrm{dQ}^n}{\mathrm{dP}^n}\right) \overset{\mathrm{P}^n}{\Longrightarrow} N_{k+1}\left(\begin{pmatrix} \mu \\ -\frac{1}{2}\sigma^2 \end{pmatrix}, \begin{pmatrix} \Sigma & \tau \\ \tau^\top & \sigma^2 \end{pmatrix}\right).$$

が成り立つとする. このとき,

$$X_n \overset{\mathrm{Q}^n}{\Longrightarrow} N_k(\mu + \tau, \Sigma).$$

Proof. (X, W) を仮定の正規分布に従う確率変数とする．連続写像定理より，

$$\left(X_n, \frac{\mathrm{dQ}^n}{\mathrm{dP}^n}\right) \xRightarrow{\mathrm{P}^n} (X, e^W).$$

W は $N(-\frac{1}{2}\sigma^2, \sigma^2)$ にしたがうから, Example 6.3 より $\mathrm{Q}^n \triangleleft\triangleright \mathrm{P}^n$ である．特に $\mathrm{Q}^n \triangleleft \mathrm{P}^n$ より, 仮定とあわせて Lemma 6.4 を用いることができ, $L(B) := \mathrm{E}[\mathbb{1}_B(X)e^W]$ として $X_n \xRightarrow{\mathrm{Q}^n} L$ が成り立つ．L の特性関数は

$$\int e^{it^\top x}\mathrm{dL}(x) = \mathrm{E}[e^{it^\top X}e^W] = \mathrm{E}\left[e^{i\left(\begin{smallmatrix} t \\ -i \end{smallmatrix}\right)^\top \left(\begin{smallmatrix} X \\ W \end{smallmatrix}\right)}\right]$$

これは仮定の正規分布の特性関数の $(t, -i)$ における値であるから,

$$\int e^{it^\top x}\mathrm{dL}(x) = e^{it^\top\mu - \frac{1}{2}\sigma^2 - \frac{1}{2}(t^\top, -i)\left(\begin{smallmatrix} \Sigma & \tau \\ \tau^\top & \sigma^2 \end{smallmatrix}\right)\left(\begin{smallmatrix} t \\ -i \end{smallmatrix}\right)} = e^{it^\top(\mu+\tau) - \frac{1}{2}t^\top\Sigma t}.$$

右辺は $N_k(\mu + \tau, \Sigma)$ の特性関数に等しいので, 主張を得る． □

Coffee Break：対数尤度比の分布収束

Lemma 6.5 は, 標語的には次のように整理できる：「P^n の下で漸近正規性をもつ X_n について, もしも Q^n の下での漸近正規性も欲しいならば, X_n と対数尤度比の同時分布について適切な漸近正規性を示せばよい．このとき, 収束先の期待値は尤度比との漸近共分散だけシフトする」．

Lemma 6.5 の仮定にあるような分布収束は一見して奇抜であり, 使いどころが難しい補題であるように思われるかもしれないが, 以降では随所で重要な役割を果たす (大事すぎて, 次章で名前をつける)．本章は数学的にもハードな内容になっているが, 実戦的には, Lemma 6.4 および Lemma 6.5 の内容を理解してきちんと運用することができれば, このあとの話をフォローすること自体は可能と思われる．

7 Local Asymptotic Normality

ゆるい仮定の下で, 統計的実験の列は, 「正規分布 × 一様乱数」から定まる単純な統計的実験によってまるごと近似できる. この事実は, 統計的実験の上に定まる推定量の漸近挙動が強く拘束されることをもって示される.

7.1 Localized Statistical Experiments

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ と, $\mathbb{R}^d$-値 i.i.d. 確率変数列 X_n が与えられたとし, パラメータ空間は $\Theta \subset \mathbb{R}^k$ とする. また, 真値について $\theta_0 \in \operatorname{Int}\Theta$ をつねに仮定する. 本章では, 「統計的実験は真の分布の近傍でなめらかである」という条件を, 対数尤度比の分布収束にもとづいて考察する. 関数のなめらかさが各点ごとに定義されるように, 統計的実験の滑らかさも各点ごとに定義される. このような事情で, まずは統計的実験の「局所化」を考える.

Definition 7.1: 統計的実験の局所化

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ に対して, $h = \sqrt{n}(\theta - \theta_0) \in \mathbb{R}^k$ を局所パラメータといい, 局所パラメータによってもう 1 つの統計的実験

$$(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_{\theta_0 + h/\sqrt{n}}^n\ ;\ h \in \mathbb{R}^k\})$$

を定義する. これを**統計的実験の局所化** (localization of statistical experiments) という. ただし, $\theta = \theta_0 + h/\sqrt{n} \notin \Theta$ であるような n, h においては, $\mathrm{P}_{\theta_0 + h/\sqrt{n}}^n$ は任意に定めることとする.

すなわち, 統計的実験において, 特に真値 $\theta_0 \in \Theta$ を主役とし, あとの分布はすべて θ_0 から $h/\sqrt{n}$ だけズレたものだと考えるのである. 本章では, このような局所化によって, 十分大きな n では

$$(\mathrm{P}_{\theta_0 + h/\sqrt{n}}^n\ ;\ h \in \mathbb{R}^k) \approx (N_k(h, I(\theta_0)^{-1})\ ;\ h \in \mathbb{R}^k)$$

なる「統計的実験の近似」がある意味で成り立つことが示される. 近似先の分布の族は正規分布の族で構成されているから, もとの統計的実験よりも, 近似先の統計的実験の方が統計量の挙動の解析が容易であることが想像されるだろう.

7.2 Local Asymptotic Normality

これより, 上の突飛な議論を厳密に展開していこう. まずは, 対数尤度比の真値まわりでのテイラー展開に注目する. 簡単のためパラメータは 1 次元とする. また, 局所化された統計的実験は μ で dominate されているとする. すなわち, $\{\mathrm{P}_{\theta_0 + h/\sqrt{n}}^n\ ;\ h \in \mathbb{R}^k\} \ll \mu$ とし, P_θ の確率密度関数を p_θ とかく. また, $l_\theta(x) = \log p_\theta(x)$ は任意の $x \in \mathcal{X}$ で θ に関して 2 回微分可能とする. このとき,

2 次までのテイラー展開によって

$$\log \frac{p_{\theta_0+h}}{p_{\theta_0}}(x) = h\dot{l}_{\theta_0}(x) + \frac{1}{2}h^2\ddot{l}_{\theta_0}(x) + o_x(h^2) \quad (h \downarrow 0)$$

が成り立つ[*10]．x として $X_1, \ldots, X_n$ を考え, 足し合わせ, h を $h/\sqrt{n}$ で置き換えれば,

$$\log \prod_{i=1}^{n} \frac{p_{\theta_0+h/\sqrt{n}}}{p_{\theta_0}}(X_i) = \sum_{i=1}^{n} \frac{h}{\sqrt{n}}\dot{l}_{\theta_0}(X_i) + \frac{1}{2}\sum_{i=1}^{n} \frac{h^2}{n}\ddot{l}_{\theta_0}(X) + \sum_{i=1}^{n} o_{X_i}\left(\frac{1}{n}\right) \quad (n \to \infty).$$

スコア関数について, 中心極限定理と大数法則より,

$$\Delta_{n,\theta_0} = \frac{1}{\sqrt{n}}\sum_{i=1}^{n} \dot{l}_{\theta_0}(X_i) \xrightarrow{d} N(0, I(\theta_0)),$$

$$\frac{1}{n}\sum_{i=1}^{n} \ddot{l}_{\theta_0}(X_i) \xrightarrow{p} \mathrm{E}_{\theta_0}[\ddot{l}_{\theta_0}(X)] = -I(\theta_0).$$

剰余項は無視できるとすると,

$$\log \prod_{i=1}^{n} \frac{p_{\theta_0+h/\sqrt{n}}}{p_{\theta_0}}(X_i) = h\Delta_{n,\theta_0} - \frac{1}{2}I(\theta_0)h^2 + o_{\mathrm{P}^n_{\theta_0}}(1) \quad (n \to \infty).$$

このような対数尤度比の収束には名前がついている.

Definition 7.2: LAN (local asymptotic normality)

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_\theta \ ; \ \theta \in \Theta\})$ が $\theta_0 \in \Theta$ において**局所漸近正規性** (LAN; local asymptotic normality) をみたすとは, ある $I(\theta_0)$ が存在して, 任意の $h \in \mathbb{R}^k$ に対して

$$\log \prod_{i=1}^{n} \frac{\mathrm{dP}_{\theta_0+h/\sqrt{n}}}{\mathrm{dP}_{\theta_0}}(X_i) = h^\top \Delta_{n,\theta_0} - \frac{1}{2}h^\top I(\theta_0)h + o_{\mathrm{P}^n_{\theta_0}}(1) \quad (n \to \infty) \tag{7.1}$$

$$\text{with} \quad \Delta_{n,\theta_0} \xRightarrow{\mathrm{P}^n_{\theta_0}} N(0, I(\theta_0))$$

が成り立つこととする[a]．

[a] $I(\theta_0)$ はたいていフィッシャー情報行列になるためこのようなノーテーションにしているが, そうでなくてもよい．むしろ, non-i.i.d. の場合など, 式 (7.1) をみたす $I(\theta_0)$ をフィッシャー情報行列と定義する向きすらある気がする．LAMN や LAQ といった LAN のさらなる一般化も存在する．

先ほどの議論によれば, 密度関数の θ に関する 2 回微分可能性を課せば LAN を導くことができそうである．その一方で, L^2-ノルムを用いた次のような十分条件も知られている．

[*10] 剰余項の添字は x に依存して定まることを明示するためにつけている．

Definition 7.3: DQM (differentiable in quadratic mean)

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ が $\theta_0 \in \Theta$ において**平均二乗微分可能** (DQM; differentiable in quadratic mean) であるとは, ある可測関数のベクトル $\dot{l}_\theta = (\dot{l}_{\theta,1}, \dot{l}_{\theta,2}, \ldots, \dot{l}_{\theta,k})^\top$ が存在して,

$$\int \left[\sqrt{p_{\theta_0+h}} - \sqrt{p_{\theta_0}} - \frac{1}{2} h^\top \dot{l}_{\theta_0} \sqrt{p_{\theta_0}}\right]^2 \mathrm{d}\mu = o(|h|^2), \quad h \to 0 \tag{7.2}$$

が成り立つこととする.

DQM 条件の定義は可測関数 $\dot{l}_\theta$ の実体を明示していないが, ノーテーションから察せられるように, たいていはスコア関数により与えられる. 実際, 各点 x での $\sqrt{p_{\theta_0+h}}$ の微分について考えると,

$$(\sqrt{p_{\theta_0}})' = \frac{(p_{\theta_0})'}{2\sqrt{p_{\theta_0}}} = \frac{1}{2}\frac{(p_{\theta_0})'}{p_{\theta_0}}\sqrt{p_{\theta_0}} = \frac{1}{2}(\log p_{\theta_0})'\sqrt{p_{\theta_0}}.$$

実際には, h に関する方向微分を考え, 各点 x ではなく μ の平均二乗誤差による微分を考えたもとで, Definition 7.3 と形を比較してやれば, $\dot{l}_\theta$ がスコア関数 (がなすベクトルにもとづく線形結合) で与えられそうなことが分かるだろう. この事実はのちに確認する.

まずは, DQM 条件が確かに LAN の十分条件になっていることを確かめよう.

Theorem 7.1: DQM ⇒ LAN

DQM 条件 (7.2) が成り立つならば, $\mathrm{E}_{\theta_0}[\dot{l}_{\theta_0}] = 0$ であり, $I(\theta_0) = \mathrm{E}_{\theta_0}[\dot{l}_{\theta_0}\dot{l}_{\theta_0}^\top]$ が存在し, この $I(\theta_0)$ と $\Delta_{n,\theta_0} = \frac{1}{\sqrt{n}}\sum_{i=1}^n h^\top \dot{l}_{\theta_0}(X_i)$ について LAN(7.1) が成り立つ.

Proof. 次のように略記する:

$$p_n := p_{\theta_0+h/\sqrt{n}},\ p := p_{\theta_0},\ g := h^\top \dot{l}_{\theta_0}.$$

期待値などは p の下でとる. P_{θ_0} も P とかき, 添字は省略する. いま, h を任意に fix して $h/\sqrt{n}$ を考える. DQM 条件 (7.2) の仮定より,

$$\int \left[\sqrt{n}(\sqrt{p_n} - \sqrt{p}) - \frac{1}{2} g\sqrt{p}\right]^2 \mathrm{d}\mu = o(1).$$

したがって, $\frac{1}{2}g\sqrt{p}$ は $L^2(\mu)$ の元の極限となり, $g \in L^2(\mathrm{P})$ を得る. また, 収束列は有界であるから,

$$\|\sqrt{n}(\sqrt{p_n} - \sqrt{p})\|_{L^2(\mu)} = O(1) \quad \text{i.e.} \quad \sqrt{p_n} \xrightarrow{L^2(\mu)} \sqrt{p}.$$

これらと内積の連続性をあわせれば,

$$\begin{aligned}\mathrm{E}[g] &= \int \frac{1}{2} g\sqrt{p}\, 2\sqrt{p}\, \mathrm{d}\mu \\ &= \lim_{n\to\infty} \int \sqrt{n}(\sqrt{p_n} - \sqrt{p})(\sqrt{p_n} + \sqrt{p})\mathrm{d}\mu = \lim_{n\to\infty} \sqrt{n}(1-1) = 0.\end{aligned}$$

h は任意であるから $\mathrm{E}[\dot{l}_{\theta_0}] = 0$ を得る．

さて, $W_{ni} := 2\{\sqrt{p_n/p}(X_i) - 1\}$ なる確率変数を用意する．これは P_{θ_0}-a.s. で well-defined であり, P_{θ_0}-ゼロ集合上での値は任意に定めるものとする．上の評価より

$$
\begin{aligned}
\mathrm{Var}\left[\sum_{i=1}^n W_{ni} - \frac{1}{\sqrt{n}}\sum_{i=1}^n g(X_i)\right] &= n\mathrm{Var}\left[W_{ni} - \frac{1}{\sqrt{n}}g(X_i)\right] \quad (\because \text{i.i.d.}) \\
&\le n\mathrm{E}\left[\left(W_{ni} - \frac{1}{\sqrt{n}}g(X_i)\right)^2\right] \\
&= \mathrm{E}\left[\left(\sqrt{n}W_{ni} - g(X_i)\right)^2\right] \\
&= \int \left\{\sqrt{n}2(\sqrt{p_n/p}(x) - 1) - g(x)\right\}^2 p(x)\mu(\mathrm{d}x) \\
&= \frac{1}{4}\int \left\{\sqrt{n}(\sqrt{p_n} - \sqrt{p}) - \frac{1}{2}g\sqrt{p}\right\}^2 \mathrm{d}\mu \to 0.
\end{aligned}
$$

特に $\mathrm{E}\left[\left(\sqrt{n}W_{ni} - g(X_i)\right)^2\right] \to 0$ であり, $\sqrt{n}W_{ni}$ は $L^2(\mathrm{P})$-有界である．このことはあとで用いる．さらに,

$$
\begin{aligned}
\mathrm{E}\left[\sum_{i=1}^n W_{ni}\right] &= 2n\int (\sqrt{p_n/p}(x) - 1)p(x)\mu(\mathrm{d}x) \\
&= 2n\left(\int \sqrt{p_n}\sqrt{p}\mathrm{d}\mu - 1\right) \\
&= -\int \{\sqrt{n}(\sqrt{p_n} - \sqrt{p})\}^2 \mathrm{d}\mu \\
&\to -\int \left(\frac{1}{2}g\sqrt{p}\right)\mathrm{d}\mu = -\frac{1}{4}\mathrm{E}[g^2].
\end{aligned}
$$

ここで, $\mathrm{E}[g^2] = h^\top I(\theta_0)h$ にも注意する．2 つの評価をあわせると,

$$
\begin{aligned}
\mathrm{E}\left[\sum_{i=1}^n W_{ni} - \frac{1}{\sqrt{n}}\sum_{i=1}^n g(X_i) + \frac{1}{4}\mathrm{E}[g^2]\right] &\to 0, \\
\mathrm{Var}\left[\sum_{i=1}^n W_{ni} - \frac{1}{\sqrt{n}}\sum_{i=1}^n g(X_i) + \frac{1}{4}\mathrm{E}[g^2]\right] &\to 0.
\end{aligned}
$$

すなわち, かっこの中身は $L^2(\mathrm{P})$ で 0 に収束する．したがって,

$$
\sum_{i=1}^n W_{ni} = \frac{1}{\sqrt{n}}\sum_{i=1}^n g(X_i) - \frac{1}{4}\mathrm{E}[g^2] + o_P(1).
$$

さて, $\sum_{i=1}^n W_{ni}$ の漸近挙動についてはよくわかったので, こんどは対数尤度比を W_{ni} のことばで展開できないか考えよう．まず,

$$
\begin{aligned}
\log(1+x) &= 0 + \left.\frac{1}{1+x}\right|_{x=0} x - \frac{1}{2!}\left.\frac{1}{(1+x)^2}\right|_{x=0} x^2 + \frac{1}{3!}\left.\frac{-2}{(1+x)^3}\right|_{x=0} x^3 + o(x^3) \\
&= x - \frac{1}{2}x^2 + x^2 R(x).
\end{aligned}
$$

ただし, $R(x) \downarrow 0\ (x \to 0)$ である. $\sqrt{p_n/p} = 1 + \frac{1}{2}W_{ni}$ であるから,

$$\begin{aligned}
\log \prod_{i=1}^{n} \frac{p_n}{p}(X_i) &= \sum_{i=1}^{n} \log\left(1 + \frac{1}{2}W_{ni}\right)^2 \\
&= 2\sum_{i=1}^{n} \log\left(1 + \frac{1}{2}W_{ni}\right) \\
&= 2\sum_{i=1}^{n} \left(\frac{1}{2}W_{ni} - \frac{1}{2}\cdot\frac{1}{4}W_{ni}^2 + \frac{1}{4}W_{ni}^2 R(W_{ni})\right) \\
&= \sum_{i=1}^{n} W_{ni} - \frac{1}{4}\sum_{i=1}^{n} W_{ni}^2 + \sum_{i=1}^{n} \frac{1}{2}W_{ni}^2 R(W_{ni}).
\end{aligned}$$

第 1 項の漸近挙動はすでに示した. 第 2 項については, $\sqrt{n}W_{ni}$ は $L^2(\mathrm{P})$-有界性と, 上で示した $\mathrm{E}\left[\left(\sqrt{n}W_{ni} - g(X_i)\right)^2\right] \to 0$ を用いると,

$$\begin{aligned}
\mathrm{E}\left[|nW_{ni}^2 - g^2(X_i)|\right] &= \mathrm{E}\left[\left(\sqrt{n}W_{ni} - g(X_i)\right)\left(\sqrt{n}W_{ni} + g(X_i)\right)\right] \\
&\le \|\sqrt{n}W_{ni} - g(X_i)\|_2 \|\sqrt{n}W_{ni} + g(X_i)\|_2 \\
&= o(1) \times O(1) = o(1) \quad (n \to \infty).
\end{aligned}$$

すなわち, $A_{ni} = nW_{ni}^2 - g^2(X_i)$ に関して $\mathrm{E}[|A_{ni}|] \to 0$ が成り立ち, $\frac{1}{n}\sum_{i=1}^{n} A_{ni} \xrightarrow{p} 0$ がしたがう. したがって,

$$\sum_{i=1}^{n} W_{ni}^2 = \frac{1}{n}\sum_{i=1}^{n} g^2(X_i) + \frac{1}{n}\sum_{i=1}^{n} A_{ni} \xrightarrow{p} \mathrm{E}[g^2].$$

第 3 項については, Markov の不等式より, ${}^\forall\varepsilon > 0$ に対して,

$$\begin{aligned}
n\mathrm{P}(|W_{ni}| > \varepsilon\sqrt{2}) &= n\mathrm{P}\left(|A_{ni} + g^2(X_i)| > 2n\varepsilon^2\right) \\
&\le n\mathrm{P}\left(|A_{ni}| > n\varepsilon^2\right) + n\mathrm{P}\left(|g^2(X_i)| > n\varepsilon^2\right) \\
&\le \frac{1}{\varepsilon^2}\mathrm{E}\left[|A_{ni}|\right] + \frac{1}{\varepsilon^2}\mathrm{E}\left[|g^2(X_i)|\,;\,\{g(X_i) > n\varepsilon^2\}\right] \to 0 \quad (n \to \infty).
\end{aligned}$$

劣加法性より左辺は $\mathrm{P}(\max_{1\le i\le n}|W_{ni}| > \varepsilon\sqrt{2})$ を上から抑えるので, $\max_{1\le i\le n}|W_{ni}| \xrightarrow{p} 0$ である. 剰余項の関数 R の性質より, $\max_{1\le i\le n}|R(W_{ni})| \xrightarrow{p} 0$ もわかる. つまり,

$$\sum_{i=1}^{n} W_{ni}^2 R(W_{ni}) \le \max_{1\le i\le n}|R(W_{ni})| \sum_{i=1}^{n} W_{ni}^2 = o_P(1)O_P(1) = o_P(1).$$

以上の各項の評価をまとめると,

$$\begin{aligned}
\log \prod_{i=1}^{n} \frac{p_n}{p}(X_i) &= \left(\frac{1}{\sqrt{n}}\sum_{i=1}^{n} g(X_i) - \frac{1}{4}\mathrm{E}[g^2] + o_P(1)\right) - \frac{1}{4}(\mathrm{E}[g^2] + o_P(1)) + o_P(1) \\
&= \frac{1}{\sqrt{n}}\sum_{i=1}^{n} g(X_i) - \frac{1}{2}\mathrm{E}[g^2] + o_P(1).
\end{aligned}$$

これは LAN の定義であるから, 定理の主張を得る. □

DQM が LAN の十分条件であることが分かったところで, 今度は DQM の十分条件を, 確率密度関数のルートの各点微分を通して与えてみよう.

Lemma 7.2: 確率密度のルートが C^1-級 $+\alpha \Rightarrow$ DQM

任意の $x \in \mathcal{X}$ において $\theta \mapsto s_\theta(x) := \sqrt{p_\theta}$ は C^1-級であるとする. また, 行列 $I(\theta) := \int (\dot{p}_\theta/p_\theta)(\dot{p}_\theta/p_\theta)^\top p_\theta \mathrm{d}\mu$ は well-defined で連続であるとする. このとき, 特に $\theta = \theta_0$ において, $\dot{l}_\theta = \dot{p}_\theta/p_\theta$ について DQM 条件 (7.2) が成り立つ. ただし $p_\theta = 0$ のときには $\dot{l}_\theta$ の値は任意に定める.

Proof. Chain-rule より, $\theta \mapsto p_\theta(x) = s_\theta^2(x)$ は C^1 級であり, 勾配は $\dot{p}_\theta(x) = 2s_\theta(x)\dot{s}_\theta(x)$ となる. また, $s_\theta(x)$ の非負性より, $p_\theta(x) = 0 \;\Leftrightarrow\; s_\theta(x) = 0 \;\Rightarrow\; \dot{s}_\theta(x)$ であるから, s_θ の勾配は

$$\dot{s}_\theta(x) = \frac{1}{2}\frac{\dot{p}_\theta}{p_\theta}\sqrt{p_\theta}$$

と表現できる. ただし, $p_\theta = 0$ のときには $\dot{p}_\theta/p_\theta$ は任意に定めてよい. 仮定より,

$$\theta \mapsto I(\theta) = 4\int (\dot{s}_\theta)(\dot{s}_\theta)^\top \mathrm{d}\mu$$

は θ に関して連続である.

さて, $\theta \mapsto s_\theta(x)$ は C^1-級であると仮定していたから, 平均値の定理より,

$$s_{\theta+h}(x) - s_\theta(x) = \int_0^1 h^\top \dot{s}_{\theta+uh}(x)\mathrm{d}u$$

が成り立つことに注意する. Jensen の不等式と Fubini の定理に注意すると,

$$\begin{aligned}
\int \left(\frac{s_{\theta+th_t} - s_\theta}{t}\right)^2 \mathrm{d}\mu &= \int \left(\int_0^1 h_t^\top \dot{s}_{\theta+uth_t}\mathrm{d}u\right)^2 \mathrm{d}\mu \\
&\leq \int\int_0^1 \left(h_t^\top \dot{s}_{\theta+uth_t}\right)^2 \mathrm{d}u\mathrm{d}\mu \\
&= \frac{1}{4}\int_0^1 h_t^\top I(\theta+uth_t)h_t\mathrm{d}u.
\end{aligned}$$

すなわち,

$$\begin{aligned}
\limsup_{t\to 0,\, h_t\to h} \int \left(\frac{s_{\theta+th_t} - s_\theta}{t}\right)^2 \mathrm{d}\mu &\leq \limsup_{t\to 0,\, h_t\to h} \frac{1}{4}\int_0^1 h_t^\top I(\theta+uth_t)h_t\mathrm{d}u \\
&= \frac{1}{4}h^\top I(\theta)h < \infty.
\end{aligned}$$

その一方で,

$$\int \left(\frac{s_{\theta+th_t} - s_\theta}{t} - h^\top \dot{s}_\theta\right)^2 \mathrm{d}\mu$$

の被積分関数は, $t \to 0,\ h_t \to h$ の極限において, 各点 x で 0 に収束する. したがって, Proposition 2.29 を用いることができ, この積分は 0 に収束する. すなわち,

$$\int \left[\sqrt{p_{\theta_0+th_t}} - \sqrt{p_{\theta_0}} - \frac{1}{2}(th_t)^\top \dot{l}_{\theta_0}\sqrt{p_{\theta_0}}\right]^2 \mathrm{d}\mu = t^2 \int \left(\frac{s_{\theta_0+th_t} - s_{\theta_0}}{t} - h^\top \dot{s}_{\theta_0}\right)^2 \mathrm{d}\mu$$
$$= o(|t|^2), \quad t \to 0,\ h_t \to h.$$

この収束は任意の h で成り立つが, これはまさに DQM の定義であった. □

確率密度のルートが C^1-級という条件は多くのパラメトリックモデルで成り立つ. したがって, LAN もまた様々な統計的実験で成り立つ普遍的な性質といえる.

Example 7.3: 指数型分布族と LAN

先ほどの補題は, 指数型分布族に属するほとんどのモデル

$$p_\theta(x) = d(\theta)h(x)e^{Q(\theta)^\top t(x)}$$

に適用可能である. 実際, $d(\theta), Q(\theta)$ が C^1-級であれば補題の仮定はみたされる[a]. スコア関数とフィッシャー情報行列は次の通り：

$$\dot{l}_\theta(x) = Q'_\theta(t(x) - \mathrm{E}_\theta[t(X)]), \quad I_\theta = Q'_\theta \mathrm{Cov}_\theta[t(X)](Q'_\theta)^\top.$$

[a] Wikipedia などで, よく出会う分布たちについて $d(\theta), Q(\theta)$ の具体形を調べてみるとよい.

Example 7.4: 一様分布は DQM をみたさない

一様分布 $\mathrm{Unif}[0,\theta]$ は DQM 条件をみたさない[a]. これは, 一様分布の確率密度関数のサポートがパラメータに依存しすぎであることに起因している. DQM 条件自体は, 確率密度関数のサポートがパラメータに依存していることを許してはいるものの,

$$\begin{aligned}
\mathrm{P}_{\theta_0+h}(p_{\theta_0}(x) = 0) &= \int_{p_{\theta_0}(x)=0} p_{\theta_0+h}\mathrm{d}\mu \\
&= \int_{p_{\theta_0}(x)=0} \left[\sqrt{p_{\theta_0+h}} - \sqrt{p_{\theta_0}} - \frac{1}{2}h^\top \dot{l}_{\theta_0}\sqrt{p_{\theta_0}}\right]^2 \mathrm{d}\mu \\
&\le \int \left[\sqrt{p_{\theta_0+h}} - \sqrt{p_{\theta_0}} - \frac{1}{2}h^\top \dot{l}_{\theta_0}\sqrt{p_{\theta_0}}\right]^2 \mathrm{d}\mu = o(h^2) \quad (h \to 0)
\end{aligned}$$

となることを要請する. つまり, 分布を摂動させたときのサポートのズレは, 摂動の大きさの 2 乗よりも速く消失しなければならない. しかし, 一様分布はこの DQM の必要条件をみたさない. 実際,

$$\mathrm{P}_{\theta_0+h}(p_{\theta_0}(x) = 0) = \int_{[0,\theta_0]^c} \frac{1}{\theta_0+h}\mathbb{1}_{[0,\theta_0+h]}(x)\mathrm{d}x = \frac{h}{\theta_0+h}.$$

すなわち, サポートのズレは高々 $O(h)$ の速さでしか消失しない.

[a] 実は LAN もみたさない.

7.3 Convergence to a Normal Experiment

LAN とその十分条件について考察してきたが, ここからはその使い方を考えていこう. 一般に, 尤度が似ていれば統計的実験として似ていることに異論はないと思われる. もう一歩踏み出して, 真値の近傍で真の分布に対する尤度「比」が似ていれば, 統計的実験は真値の周りで局所的に似ているといってよいだろう. ここで, 正規分布 $N(h, I(\theta_0)^{-1})$ の尤度比について,

$$\log \frac{\mathrm{d}N(h, I(\theta_0)^{-1})}{\mathrm{d}N(0, I(\theta_0)^{-1})}(X) = h^\top I(\theta_0) X - \frac{1}{2} h^\top I(\theta_0) h$$

が成り立つことに注目しよう. これは LAN における対数尤度比の分布収束先にぴったり等しい! LAN は, 局所的かつ漸近的に, 統計的実験が $X \sim N(h, I(\theta_0)^{-1})$ の観測と h の推定という非常に単純な形式に帰着されることを示唆しているのである. ただしこの近似は, 摂動 h を fix するごとに定まっている点に注意する.

いま, 局所化した統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{\theta_0+h/\sqrt{n}}\ ;\ h \in \mathbb{R}^k\})$ とその上の (h の) 推定量 $T_n : \mathcal{X}^n \to \mathbb{R}^k$ を考える. すなわち, 摂動先 $\mathrm{P}^n_{\theta_0+h/\sqrt{n}}$ ごとにその T_n による push-forward : $\mathrm{P}^{T_n}_{\theta_0+h/\sqrt{n}}$ が, $\mathbb{R}^k$ 上の分布として実現する. ここで, h ごとに $\mathrm{P}^{T_n}_{\theta_0+h/\sqrt{n}}$ がある分布 $\mathrm{L}_{\theta_0,h}$ に弱収束するとしよう. このことを次のようにかく.

$$T_n \overset{h}{\Longrightarrow} \mathrm{L}_{\theta_0,h}, \quad {}^\forall h \in \mathbb{R}^k.$$

この仮定は Hodges の反例をはじくうえで本質的な役割を果たす.

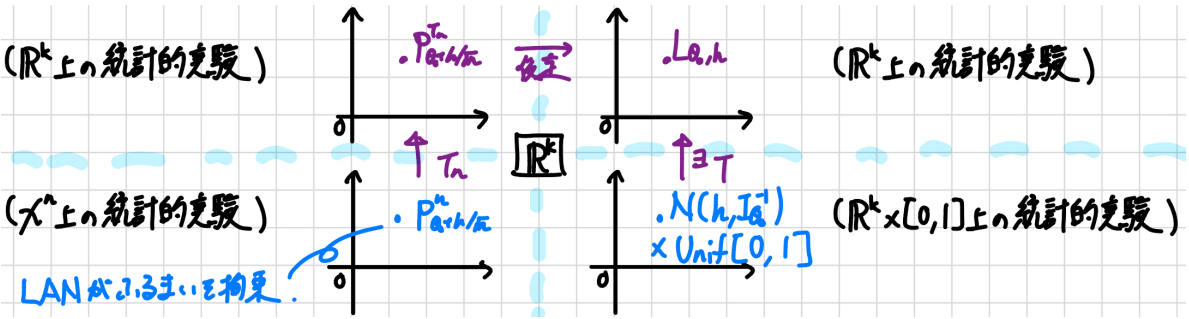

図 2　LAN にもとづく統計的実験のまるごと近似

Coffee Break：LAN のうれしさ

推定量 T_n のよさはその分布によって評価される．つまり，漸近的には，T_n のよさは分布 $\mathrm{L}_{\theta_0,h}$ が h にどれくらい集中しているか（たとえば，$\mathrm{E}_{L_{\theta_0,h}}[|T_n - h|^2]$ がどれくらい小さいか）によって評価されることになる．そのため，具体的に $\mathrm{L}_{\theta_0,h}$ はどんな形の分布になっているかということこそが我々の主たる興味となるわけだが，実は $\mathrm{L}_{\theta_0,h}$ は，ある単純な統計的実験の上の統計量 T の分布としての表現をもつことを示せる．これこそが LAN を課すうれしさである．上図のように，本来分布収束は上側の世界（統計量により push-forward された後の話）で完結していて，もともとどんな確率基を考えていたかに依存しないはずであった．しかし LAN を課すと，左下の分布の n に関する列の漸近挙動が強く制約されるために，右上の収束先の分布を，特別な確率基の下でのある push-forward としてもかけてしまうということである．

以上の話を定理にして示そう．ある意味で，次に示す定理が本稿で最も重要かもしれない．

Definition 7.4: ランダム化統計量

統計量 T が確率変数 X の**ランダム化統計量** (randomized statistic) であるとは，X とは独立に $\mathrm{Unif}[0,1]$ にしたがう確率変数 U について，$T = T(X, U)$ とかけることをいう．

Theorem 7.5: LAN ⇒ ランダム化統計量による漸近分布の表現

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_\theta\,;\,\theta \in \Theta\})$ は $\theta_0 \in \Theta$ において LAN をみたし，LAN の $I(\theta_0)$ は正則行列であるとする．また，θ_0 において局所化した統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{\theta_0+h/\sqrt{n}}\,;\,h \in \mathbb{R}^k\})$ の上の統計量 T_n は，h ごとに，$\mathrm{P}^n_{\theta_0+h/\sqrt{n}}$ の下である分布 $\mathrm{L}_{\theta_0,h}$ に分布収束すると仮定する．このとき，ある可測写像 T が存在して，h ごとに，T は $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量となり，$T_n \overset{h}{\Rightarrow} T$ が成り立つ．

Proof. 次のように略記する．

$$\mathrm{P}_{n,h} := \mathrm{P}^n_{\theta_0+h/\sqrt{n}},\ J := I(\theta_0),\ \Delta_n := \frac{1}{\sqrt{n}}\sum_{i=1}^n \dot{l}_\theta(X_i),\ \mathrm{L}_h := \mathrm{L}_{\theta,h}.$$

仮定より，T_n は特に $h = 0$ の下でも分布収束しているから，$\mathrm{P}_{n,0}$ の下で tight である．また，$h = 0$ での CLT により

$$\Delta_n \overset{0}{\Rightarrow} N(0, J)$$

であり，Δ_n も $\mathrm{P}_{n,0}$ の下で tight である．tightness は同時分布について閉じるから，(T_n, Δ_n) は $\mathrm{P}_{n,0}$ の下で tight であり，Prohorov の定理が適用できる．すなわち，ある部分列 $\{n'\}$ が存在して，ある確率変数 S について

$$(T_{n'}, \Delta_{n'}) \overset{0}{\Rightarrow} (S, \Delta)$$

が成り立つ．周辺分布については $S \sim \mathrm{L}_0$, $\Delta \sim N(0, J)$ であることに注意する．ここで, LAN が成り立っているという仮定から,

$$\left(T_{n'}, \log \frac{\mathrm{dP}_{n',h}}{\mathrm{dP}_{n',0}}\right) = \left(T_{n'}, h^\top \Delta_{n'} - \frac{1}{2} h^\top J h\right) + o_{P_{n',0}}(1) \overset{0}{\Rightarrow} (S, h^\top \Delta - \frac{1}{2} h^\top J h).$$

Example 6.3 より $\mathrm{P}_{n',h}$ と $\mathrm{P}_{n',0}$ は contiguous であるから, Lemma 6.4 を用いて漸近分布の測度変換が可能であることに注意する．つまり, h の下で T_n が分布収束すること自体は仮定していたが, さらにその漸近分布 L_h の表現が

$$\mathrm{L}_h(B) = \mathrm{E}\left[\mathbb{1}_B(S) e^{h^\top \Delta - \frac{1}{2} h^\top J h}\right]$$

でなければならないことも特定される．残るやるべきことは, $\Delta \sim N(0, J)$ であることを活かし, $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量 T を, その分布が L_h に等しくなるように構成することである．

下の補題より, ある Δ のランダム化統計量 $T = T(\Delta, U)$ が存在して,

$$(T(\Delta, U), \Delta) \sim (S, \Delta)$$

とできることに注意する[*11]．Δ の分布は $h = 0$ のときの収束先としてしか分かっていないが, これを工夫して任意の h に関する議論まで運んでいこう．いま, X_h を U と独立に $N(h, J^{-1})$ にしたがう確率変数とすれば, $JX_0 \sim N(0, J)$ であり, 特に $JX_0 \sim \Delta$ となる．したがって, 勝手に作った (X_h, U) の同時分布について, Fubini の定理を用いれば

$$\begin{aligned}
\mathrm{P}_h(T(JX_h, U) \in B) &= \int \mathrm{P}(T(Jx, U) \in B) \mathrm{d}N(h, J^{-1})(x) \\
&= \int \mathrm{P}(T(Jx, U) \in B) e^{-\frac{1}{2}(x-h)^\top J (x-h)} \sqrt{\frac{\det J}{(2\pi)^k}} \mathrm{d}x \\
&= \int \mathrm{P}(T(Jx, U) \in B) e^{h^\top x - \frac{1}{2} h^\top J h} \cdot e^{-\frac{1}{2} x^\top J x} \sqrt{\frac{\det J}{(2\pi)^k}} \mathrm{d}x \\
&= \int \mathrm{P}(T(Jx, U) \in B) e^{h^\top x - \frac{1}{2} h^\top J h} \mathrm{d}N(0, J^{-1})(x) \\
&= \mathrm{E}_{\mathrm{P}_0}\left[\mathbb{1}_{\{T(JX_0, U) \in B\}} e^{h^\top J X_0 - \frac{1}{2} h^\top J h}\right].
\end{aligned}$$

構成の仕方から $(T(JX_0, U), JX_0) \sim (S, \Delta)$ であるから, 先の段落の議論とあわせて

$$^\forall B \in \mathcal{B}(\mathbb{R}^k), \quad \mathrm{L}_h(B) = \mathrm{P}_h(T(JX_h, U) \in B).$$

以上により, h ごとに, T_n の分布収束先 L_h が, 上で構成した $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量 T の分布に等しいことが分かり, 定理の主張を得る． □

[*11] これは条件付き分布の quantile transformation である．一番よくわからない S のランダムネスを, 相方の Δ に一様乱数のランダムネスを付け加えたものとして分解したということ．(S, Δ) 自体は h によらないから, T も h によらずに構成できる．

Lemma 7.6

$\mathbb{R}^d \times \mathbb{R}^k$-値確率変数 (S, Δ) と, それと独立な $U \sim \mathrm{Unif}[0,1]$ があるとき, ある $\mathbb{R}^k \times [0,1]$ 上の可測写像 T が存在して, $(T(\Delta, U), \Delta)$ の分布と (S, Δ) の分布が等しいようにできる. (証明略；本には $d = 2$ のときの証明あり)

これで役者は揃った. 次章ではいよいよ, パラメトリックモデルの有効性理論を完結させる.

8 Efficiency of Estimators

本章でも引き続き, 統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ とその局所化 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_{\theta_0+h/\sqrt{n}}^n\ ;\ h \in \mathbb{R}^k\})$ を考える. いよいよだが, $\theta = \theta_0$(すなわち $h = 0$) の推定量たちのなかで最強はどれなのかを結論したい. 本章では, 5 章で述べた Fisher の予想は条件付きで正当化できることを示す.

繰り返し述べているように, 推定量の良しあしはその分布によって決定するのであった. 一般に, 統計的実験の上に定まる確率変数 T が θ ごとに分布 L_θ に従っているとき, そのゼロへの集中度合いを測る関数

$$\theta \mapsto \int l(x)\mathrm{dL}_\theta(x)$$

を**リスク関数** (risk function) という. l は**損失関数** (loss function) とよばれる. たとえば,

$$\int |x|^2\mathrm{dL}_\theta(x),\ \int |x|\mathrm{dL}_\theta(x),\ \int \mathbb{1}_{\{|x|>a\}}\mathrm{dL}_\theta(x),\ \int (|x| \wedge a)\mathrm{dL}_\theta(x)$$

などが考えられる. この時点で確率変数 T の写像としての個性は捨象されていることに注意しよう. われわれがこれから考えるのは, L_θ がある (中心化された) 推定量の列 $\sqrt{n}(T_n - \theta)$ の漸近分布になっている場合である. T_n が最良であるということは, あるリスク関数の下で L_θ を最小にすることとして定義できる. あるいは, 二次モーメント

$$\int xx^\top \mathrm{dL}_\theta(x)$$

を用いて, それを二次形式の意味で最小にする推定量が最良であると定義することもできる. 本稿では特に後者の定義にもとづいて議論を進める.

8.1 Regularity of Estimators

有効性理論を展開するにあたっては, 先の章で示した Theorem 7.5 が非常に重要な役割を果たす. この定理では, h ごとに $\mathrm{P}_{\theta_0+h/\sqrt{n}}^{T_n}$ がある分布 $\mathrm{L}_{\theta_0,h}$ に弱収束する：

$$T_n \overset{h}{\Longrightarrow} \mathrm{L}_{\theta_0,h} \quad ({}^\forall h \in \mathbb{R}^k)$$

が成り立つことを仮定していた. この条件をもう少し強めて, 「どんな摂動 h を考えたとしても収束先の分布はブレない」という仮定を用意する. ただし, 都合により θ そのものではなく $\psi(\theta) \in \mathbb{R}^p$ なる量が推定対象であるとしておく. これは多少の一般化になっており, $\psi : \mathbb{R}^k \to \mathbb{R}^p$ として $p = k$ の下で恒等写像を考えれば元の設定に一致する. このように定式化しながら議論することで, 有効性理論のセミパラメトリックモデルへの拡張に自然につながっていく.

Definition 8.1: 推定量の正則性

推定量の列 T_n が**正則** (regular) であるとは, ある確率分布 L_{θ_0} が存在して以下が成り立つことをいう.

$$\sqrt{n}\left(T_n - \psi\left(\theta_0 + \frac{h}{\sqrt{n}}\right)\right) \overset{h}{\Longrightarrow} \mathrm{L}_{\theta_0} \quad ({}^\forall h \in \mathbb{R}^k).$$

収束先が h によらないことまで要請している点に注意する.

Example 8.1: Hodges の反例は正則ではない

かんたんのため, 統計的実験として $(\mathbb{R}^n, \mathcal{B}^n, \{N^n(\theta, 1)\ ;\ \theta \in \mathbb{R}\})$ とその局所化を考えよう. この統計的実験は LAN をみたしている. いまわれわれは, i.i.d. データ $X_1, \ldots, X_n$ を用いて真値 $\theta = \theta_0$ を推定したい.
さて, 次の二つの推定量に注目しよう.

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i \ \sim N(\theta_0 + h/\sqrt{n}, 1/n) \quad \text{with} \ \ h,$$
$$\check{\theta}_n = \begin{cases} \alpha\bar{X}_n & (\bar{X}_n \in [-n^{-1/4}, n^{-1/4}]), \\ \bar{X}_n & (\bar{X}_n \notin [-n^{-1/4}, n^{-1/4}]). \end{cases}$$

ただし, $\alpha \in (0, 1)$ である. $\check{\theta}_n$ は 5 章で述べた Hodges の反例であり, 真値がたまたまぴったり $\theta_0 = 0$ のときだけ, $\bar{X}_n$ よりも漸近分散が小さくなるのであった. しかしそのよさは, 0 の近傍における安定性を犠牲にして得られるものなのである.
いま, 真値は $\theta_0 = 0$ であったとしよう. 統計的実験を局所化した下で, h を fix し, 摂動の列 $\theta_n = \frac{h}{\sqrt{n}}$ を考える. $A_n = [-n^{-1/4}, n^{-1/4}]$ とおくと, 任意の閉集合 $F \subset \mathbb{R}$ に対して,

$$\begin{aligned}
&\mathrm{P}^n_{\theta_n}(\sqrt{n}(\check{\theta}_n - \theta_n) \in F) \\
=&\mathrm{P}^n_{\theta_n}(\{\sqrt{n}(\check{\theta}_n - \theta_n) \in F\} \cap \{\bar{X}_n \in A_n\}) + \mathrm{P}^n_{\theta_n}(\{\sqrt{n}(\check{\theta}_n - \theta_n) \in F\} \cap \{\bar{X}_n \notin A_n\}) \\
=&\mathrm{P}^n_{\theta_n}(\{\sqrt{n}(\alpha\bar{X}_n - \theta_n) \in F\} \cap \{\bar{X}_n \in A_n\}) + \mathrm{P}^n_{\theta_n}(\{\sqrt{n}(\bar{X}_n - \theta_n) \in F\} \cap \{\bar{X}_n \notin A_n\}) \\
\leq&\mathrm{P}^n_{\theta_n}\left(\left\{\sqrt{n}\left(\alpha\bar{X}_n - \frac{h}{\sqrt{n}}\right) \in F\right\}\right) + \mathrm{P}^n_{\theta_n}(\{\bar{X}_n \notin A_n\}) \\
=&\mathrm{P}^n_{\theta_n}\left(\{\sqrt{n}\alpha\bar{X}_n - h \in F\}\right) + \mathrm{P}^n_{\theta_n}(\{\sqrt{n}\bar{X}_n \notin [-n^{1/4}, n^{1/4}]\}) \\
=&\mathrm{P}(Z \in F) + o(1).
\end{aligned}$$

ただし, $Z \sim N((\alpha - 1)h, \alpha^2)$ とする. また, $\sqrt{n}\bar{X}_n \sim N(h, 1)$ であることに注意する. 今行った評価について $\limsup$ をとれば, Portmanteau (vi) より

$$\sqrt{n}(\check{\theta}_n - \theta_n) \overset{h}{\Longrightarrow} N((\alpha - 1)h, \alpha^2).$$

したがって, h ごとの分布収束は成り立っているものの, 収束先は h に依存しているから, Hodges の反例 $\check{\theta}_n$ は正則ではない.

Q6. Example 8.1 の結果を, 直接計算ではなく LeCam の第三補題を使って導け.

Coffee Break：推定量の Shrinkage による影響

h ごとの分布収束は成り立っているということから, Theorem 7.5 にもとづき, ランダム化統計量による漸近分布の表現が得られるはずである. 先ほどは統計的実験として正規分布そのものを考えていたので一様乱数を使わずとも構成が可能だ. ぜひ, 少し考えてみよう.
また, 漸近分布の「ズレ方」を観察するのも面白い. まず, Shrinkage 定数 $\alpha \in (0,1)$ を小さくすればするほど平均は 0 から離れていく. また, たとえば摂動を $h > 0$ で与えれば, 漸近分布はマイナス側に振れることになる. このことは, 真の分布を $\theta_0 = 0$ からほんの少しだけ正に動かしたとき, ずらした先の分布からみて, Hodges の推定量は負の方向にバイアスがかかって分布してしまうということを意味している. そのバイアスは, より極端に Shrinkage させるほど大きくなり, あえて Shrinkage させない $\alpha = 1$ の場合を考えれば完全に消えることも分かるだろう.
このような「摂動に対する漸近分布の不安定性」はあまり望ましいとはいえない. 実際, h をどんなふうに固定しようが, $n \to \infty$ の極限においてその摂動は限りなく小さくなっていくのであり, 推定量には, 真の分布の下での漸近挙動と同じふるまいをすることが自然に期待されるはずだ. このことを数学的に書き下したのが Definition 8.1 の正則性である.

Hodges の反例における望ましくない事象は, リスク関数によっても表現することができる. そのことを例示しているのが図 3 である. すなわち, リスク関数として二乗誤差

$$\theta \mapsto n\mathrm{E}_\theta[(\check{\theta}_n - \theta)^2]$$

を採用すると, 真値ゼロにおいてリスクが小さくなる代わりに, その近傍においてリスク関数がスパイクしていることが分かる. スパイクの位置と高さはサンプルサイズによって変化し, サンプルサイズが大きくなるごとにゼロの付近にスパイクが近づきつつ高さが発散していく. このことがまさに, 統計的実験の局所化における摂動の大きさを, n が大きくなるごとに縮小させていかなければならない理由になっている. つまり, 摂動先をある点で固定して考えてしまうと, それがどんなに真値の近くにあったとしても, $n \to \infty$ の極限ではいずれスパイクがそこを通過してしまい, 何事もなかったかのようにリスクの値が元の値に収れんしてしまうのだ.

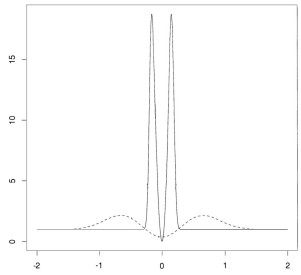

図 3　Hodges の反例のリスク関数: $\theta \mapsto n\mathrm{E}[(\check{\theta}_n - \theta)^2]$.

Coffee Break

なお, スパイクの発散は摂動下における漸近分布のバイアスの二乗に n がかかることによる. つまり, ふつうに $\bar{X}_n$ を使った場合のリスク関数はぺたんこになる. 真値がどんな値であったとしても一様にすぐれたパフォーマンスを発揮する推定量がよいという問題意識を, リスク関数はうまく表現してくれる.

何はともあれ, 推定量に正則性を課しておけば Hodges の反例は「予選落ち」することがわかった. Fisher の予想の正当化に向けて一歩前進である.

8.2 Lower Bound for Experiments

本節では, 7 章の結果と推定量の正則性を組み合わせて, 有効性理論の結論に迫ろう. まずは Theorem 7.5 について, 中心化された推定量に適用できるようにマイナーチェンジを行う.

Theorem 8.2: 推定量の漸近分布表現

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n \ ; \ \theta \in \Theta\})$ が $\theta_0 \in \Theta$ において LAN をみたし, $\psi(\theta)$ は微分可能で, LAN の $I(\theta_0)$ は正則行列とする. また, θ_0 において局所化した統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{\theta_0+h/\sqrt{n}} \ ; \ h \in \mathbb{R}^k\})$ の上の推定量 T_n について, h ごとに,

$$\sqrt{n}\left(T_n - \psi\left(\theta_0 + \frac{h}{\sqrt{n}}\right)\right) \overset{h}{\Longrightarrow} \mathrm{L}_{\theta_0,h}$$

が成り立つと仮定する. このとき, ある可測写像 T が存在して, h ごとに, T は $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量となり, $T - \dot{\psi}_{\theta_0} h$ が $\mathrm{L}_{\theta_0,h}$ にしたがうようにできる.

Proof. Theorem 7.5 を $S_n = \sqrt{n}(T_n - \psi(\theta_0))$ に適用すればよい. 実際, 仮定より任意の $h \in \mathbb{R}^k$ に対して

$$\begin{aligned} S_n &= \sqrt{n}\left(T_n - \psi\left(\theta_0 + \frac{h}{\sqrt{n}}\right)\right) + \sqrt{n}\left(\psi\left(\theta_0 + \frac{h}{\sqrt{n}}\right) - \psi(\theta_0)\right) \\ &\overset{h}{\Longrightarrow} \mathrm{L}_{\theta_0,h} * \delta_{\dot{\psi}_{\theta_0} h}. \end{aligned}$$

ここで, $*\delta_{\dot{\psi}_{\theta_0} h}$ は $\dot{\psi}_{\theta_0} h$ への平行移動をあらわす. Theorem 7.5 よりある可測写像 T が存在して, h ごとに $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量となり, T の分布は $\mathrm{L}_{\theta_0,h} * \delta_{\dot{\psi}_{\theta_0} h}$ に等しくなる. すなわち, $T - \dot{\psi}_{\theta_0} h \sim \mathrm{L}_{\theta_0,h}$ がしたがい, 主張を得る. □

Theorem 8.2 で T_n に対して構成できる T を T_n の**マッチング統計量** (maching statistics) と呼ぶことがある. ただし, T_n と T の写像としての関係は全く重要ではなく, 分布 $\mathrm{L}_{\theta_0,h}$ の再現が T を用いて得られるということが本質的である. 証明を見て,「どうしてわざわざ $S_n = \sqrt{n}(T_n - \psi(\theta_0))$ に Theorem 7.5 を適用するのか」と不思議に思われたかもしれない. しかし実は, 平行移動をふく

む $T - \dot{\psi}_{\theta_0} h$ の形の確率変数の分布で $\mathrm{L}_{\theta_0,h}$ を表現して正則性の仮定と組み合わせることこそが重要なのである．このことは次節の畳み込み定理をフォローすると分かる．

ここが最も重要な議論になるので, 順序だてて整理していこう．

Step 1. 我々は, 真値が定める $\psi(\theta_0)$ を推定するため, 推定量 T_n を構成し, $\sqrt{n}(T_n - \psi(\theta_0))$ の漸近分布が 0 にできるだけ集中するようにしたい．そのためにも, 漸近分布が 0 に集中できる限界はどれくらいか: **効率性限界** (efficiency bound) を調べたい．しかしこのことをナイーブに実行しようとすると, Hodges の反例がその限界を際限なく更新してしまう．

Step 2. そのため, 「推定量は正則性もみたすように構成しなければならない」というルールを追加する．そうすると, このルールをみたさない Hodges の反例は検討対象から除外される．正則性をみたすような推定量は Theorem 8.2 の仮定をみたし, さらにその仮定に現れる漸近分布 $\mathrm{L}_{\theta_0,h}$ は h によらないことまで要請される．したがって, 我々が考えるべきは $\mathrm{L}_{\theta_0,0}$ を最も 0 に集中させる; $\mathrm{L}_{\theta_0,0}$ の二次モーメントやリスクを最小にする正則な T_n はどれかということになる．しかし, 「ある正則な推定量 T_n が存在して Theorem 8.2 の仮定の収束先になれるような $\mathrm{L}_{\theta_0,0}$ のクラス」という確率分布のクラスはあまりにも解析がしづらい．

Step 3. ここで Theorem 8.2 を用いると, そのような確率分布のクラスは「$T - \dot{\psi}_{\theta_0} h$ の分布であって h に依存せず, しかも T は h ごとに $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量である」ような確率分布のクラスに含まれることがわかる．

Step 4. 実は, 後者のクラスはより解析がしやすく, ある畳み込みによるきれいな分解が得られてしまっている．すなわち, 前者のクラスにおいても同じ畳み込みの成立が保証されることになる．そのような畳み込み定理に基づいて効率性限界を導出し, 漸近分散ないしは漸近リスクが効率性限界と等しいような推定量をオリジナルの統計的実験の下で構成できれば, それは我々が欲していた最強の推定量にほかならない！

我々はすでに Step 3 までの正当化を行っているから, 残る仕事は Step 4 の正当化だけだ．まずは効率性限界についてフォローし, それができたら効率性限界に達する推定量を構成しよう．

8.3 Convolution-Based Efficiency Bounds

本節での課題は,

「$T - \dot{\psi}_{\theta_0} h$ の分布であって h に依存せず,
しかも T は h ごとに $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量である」
ような確率分布のクラスにおける畳み込み表現を得る

ことである．このような条件をみたす写像 T には名前がついている．

Definition 8.2: equivariant-in-law な推定量

統計的実験 $(\mathbb{R}^k \times [0,1], \mathcal{B}, \{N(h, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1]\ ;\ h \in \mathbb{R}^k\})$ を考える．すなわち, 真値 h の下でデータは $(X_h, U) \sim N(h, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1]$ である．A は $p \times k$ 行列とする．可測写像 $T : \mathbb{R}^k \times [0,1] \to \mathbb{R}^p$ が Ah の **equivariant-in-law なランダム化推定量**である[a] とは, 任意の h に対して, T は $X_h \sim N(h, I(\theta_0)^{-1})$ のランダム化統計量で,

$$T(X_h, U) - Ah$$

の分布が h に依存しないことをいう[b].

[a] 和訳されているのをみたことがない．直訳するとしたら「分布同変」だろうか.
[b] T は Ah の推定量であるため, T 自身も h に直接依存してはならない点に注意する.

Example 8.3

equivariant-in-law とは「正規分布の期待値 h のシフトがそのまま $T(X_h, U)$ の Ah 方向への平行移動になる」という性質のことである．すなわち,

$$T(X_h, U) = AX_h,\ AX_h + U,\ AX_h + U^2 + 1, \ldots$$

のように, $AX_h + f(U)$ の形でかける推定量は Ah の equivariant-in-law な推定量である．もちろん一般にはもう少し広いクラスになっているはずだが, 直観的には, この条件は T に対して, 正規分布と一様分布から独立に観測される確率変数しか用いてはいけないだけでなく, それらのランダムネスを写像としても混ぜてはならないと要請していると考えられる[a].

[a] ところで, 上記のように分解されるものしか考えてはいけないとき, $f(U)$ の項が Ah の推定に役に立ちそうに見えるだろうか？

ここで本節の課題に対する解答を与えよう．本当に興味があったのは $h = 0$ のときのデータの挙動であったことにも注意されたい.

Theorem 8.4: equivariant-in-law な推定量の畳み込み定理

統計的実験 $(\mathbb{R}^k \times [0,1], \mathcal{B}, \{N(h, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1]\ ;\ h \in \mathbb{R}^k\})$ を考える．ただし真値は $h = 0$ でありデータは $(X_0, U) \sim N(0, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1]$ である．A は $p \times k$ 行列とする．このとき，$Ah = 0$ の equivariant-in-law なランダム化推定量 T の分布 L は，ある確率分布 M を用いて

$$\mathrm{L} = N(0, AI(\theta_0)^{-1}A^\top) * M$$

なる畳み込みでかける．また，M が 0 に退化するのは $T = AX_0$ のときに限られる．

Proof. 簡単のため

$$\Sigma := I(\theta_0)^{-1}, \qquad W := T(X_0, U)$$

とおく．このとき

$$X_0 \sim N(0, \Sigma), \qquad \mathrm{L} = \mathcal{L}(W)$$

である．示すべきことは，ある確率分布 M が存在して

$$\mathcal{L}(W) = N(0, A\Sigma A^\top) * M$$

となること，および $M = \delta_0$ となるのが $W = AX_0$（a.s.）のときに限ること，である．

まず，equivariant-in-law の仮定より，任意の $h \in \mathbb{R}^k$ に対して

$$T(X_h, U) - Ah \overset{d}{=} T(X_0, U) = W$$

が成り立つ．ここで $X_0 + h \sim N(h, \Sigma)$ であるから，X_h と $X_0 + h$ は同分布であり，したがって

$$T(X_0 + h, U) - Ah \overset{d}{=} W$$

でもある．よって，任意の $t \in \mathbb{R}^p$ に対し，W の特性関数

$$\varphi(t) := E\left[e^{it^\top W}\right]$$

を用いると

$$\varphi(t) = E\left[e^{it^\top (T(X_0+h,U)-Ah)}\right] = e^{-it^\top Ah}\, E\left[e^{it^\top T(X_0+h,U)}\right] \tag{1}$$

を得る．

次に，ガウス分布の平行移動の密度比を用いる．任意の有界可測関数 $g : \mathbb{R}^k \times [0,1] \to \mathbb{C}$ に対して

$$E[g(X_0 + h, U)] = E\left[g(X_0, U) \exp\left(h^\top I(\theta_0) X_0 - \frac{1}{2} h^\top I(\theta_0) h\right)\right] \tag{2}$$

が成り立つ．これを

$$g(x, u) = e^{it^\top T(x,u)}$$

に適用し，(1) と合わせると

$$\varphi(t) = e^{-it^\top Ah}\, E\left[e^{it^\top W} \exp\left(h^\top I(\theta_0)X_0 - \frac{1}{2}h^\top I(\theta_0)h\right)\right]$$

すなわち

$$E\left[e^{it^\top W} e^{h^\top I(\theta_0)X_0}\right] = \varphi(t)\exp\left(it^\top Ah + \frac{1}{2}h^\top I(\theta_0)h\right) \qquad (h \in \mathbb{R}^k) \tag{3}$$

を得る．

ここで任意の $s \in \mathbb{R}^k$ を固定し，$r \in \mathbb{R}$ に対して

$$h = r\, I(\theta_0)^{-1}s = r\Sigma s$$

とおくと，(3) より

$$E\left[e^{it^\top W} e^{rs^\top X_0}\right] = \varphi(t)\exp\left(ir\, t^\top A\Sigma s + \frac{1}{2}r^2 s^\top \Sigma s\right) \qquad (r \in \mathbb{R}) \tag{4}$$

が成り立つ．左辺・右辺はいずれも r の解析的関数であり，実軸上で一致するので，一致の定理により複素平面全体で一致する．特に $r = i$ を代入して

$$E\left[e^{it^\top W} e^{is^\top X_0}\right] = \varphi(t)\exp\left(-t^\top A\Sigma s - \frac{1}{2}s^\top \Sigma s\right) \qquad (s \in \mathbb{R}^k,\ t \in \mathbb{R}^p) \tag{5}$$

を得る．

ここで

$$V := W - AX_0 = T(X_0, U) - AX_0$$

とおく．すると任意の $s \in \mathbb{R}^k$, $t \in \mathbb{R}^p$ に対して

$$\begin{aligned} E\left[e^{is^\top X_0 + it^\top V}\right] &= E\left[e^{i(s - A^\top t)^\top X_0 + it^\top W}\right] \\ &= \varphi(t)\exp\left(-t^\top A\Sigma(s - A^\top t) - \frac{1}{2}(s - A^\top t)^\top \Sigma(s - A^\top t)\right) \quad \text{(by (5))} \\ &= \exp\left(-\frac{1}{2}s^\top \Sigma s\right)\, \varphi(t)\exp\left(\frac{1}{2}t^\top A\Sigma A^\top t\right). \end{aligned} \tag{6}$$

(6) の右辺は s の関数と t の関数の積に分解しているので，

$$X_0 \perp\!\!\!\perp V$$

が従う．したがって

$$W = AX_0 + V$$

は独立和の形に分解される．ここで

$$AX_0 \sim N(0, A\Sigma A^\top) = N\big(0, AI(\theta_0)^{-1}A^\top\big)$$

であるから，$M := \mathcal{L}(V)$ とおけば

$$\mathrm{L} = \mathcal{L}(W) = N\bigl(0, AI(\theta_0)^{-1}A^\top\bigr) * M$$

を得る．これで前半が示された．後半の主張は明らか． □

結局, 本節の課題は $A = \dot{\psi}_{\theta_0}$ として解決される．先ほどの結果を使って話を進めると,

「ある確率分布 M を用いて $\mathrm{L}_{\theta_0} = N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top) * M$ とかける」
ような確率分布のクラスにおいて二次モーメントが最も小さいものはどれか

と整理できる．もはやこの問い自体がほとんど答えであるといってよいだろう．畳み込みの二次モーメントは二次モーメントの和なのだから, M が 0 に退化するときが効率性限界を与え, $N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$ にしたがう推定量が $\dot{\psi}_{\theta_0} h = 0$ の最良の推定量ということになる．Theorem 8.4 はさらに強く, そのような推定量のつくり方は $\dot{\psi}_{\theta_0} X_0$ そのもの以外にはありえないことまで導いている．このことは効率性限界に達する正則な推定量の漸近的な一意性を意味している！いままで分布の集中度合いしか考えてこなかったにもかかわらず, 最も 0 に集中する分布を与える推定量を考えたときには, 実はそのバリエーションは写像としてもただひとつに制約されてしまうのである．この事実は 8.5 節で重要な役割を果たす．

それでは, オリジナルの統計的実験に対して Theorem 8.4 の結果を移植しよう．今までの議論を組み合わせることでただちに証明できる．

Theorem 8.5: Hájek–Le Cam の畳み込み定理

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n \,;\, \theta \in \Theta\})$ は $\theta_0 \in \Theta$ において LAN をみたし, LAN の $I(\theta_0)$ は正則行列であるとする．$\mathbb{R}^p$-値関数 $\psi : \theta \mapsto \psi(\theta)$ は微分可能とする．また, $\theta = \theta_0$ の推定量 T_n は正則であり, 収束先は

$$\sqrt{n}(T_n - \psi(\theta_0)) \overset{0}{\Rightarrow} \mathrm{L}_{\theta_0}$$

であるとする．このとき, ある確率分布 M_{θ_0} が存在して,

$$\mathrm{L}_{\theta_0} = N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top) * M_{\theta_0}$$

とかける．$N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$ を漸近分布にもつ正則な推定量は**畳み込み定理の意味で漸近有効である**という．

Proof. これまでに示した 8 章の結果を順に用いればしたがう．すなわち, LAN と正則性の仮定をもとに Theorem 8.2 を使って, equivariant-in-law なランダム化統計量の分布として L_{θ_0} を表現すれば, Theorem 8.4 の畳み込みによって L_{θ_0} がかける． □

8.4 Risk-Based Efficiency Bounds

効率性限界は, リスク関数を用いても与えることができる. 本稿ではこれ以降あまり注目しなくなるが, 重要な結果なので紹介する. 一見するとこちらの効率性限界も Theorem 8.4 からただちに導かれそうなものであるが, 実際には, 「分布が $\mathrm{L} = N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top) * M$ と分解できる推定量だけを考える」ならば「リスクを最小にするのは $N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$ にしたがう推定量である」という主張は, どんなリスク関数に対しても成り立つとは限らない. 本節では少し異なったアプローチをとる.

Definition 8.3: bowl-shaped functions

損失関数 $l : \mathbb{R}^k \to \mathbb{R}$ が **bowl-shaped** であるとは, 原点で点対称かつ $\{x \in \mathbb{R}^k \,;\, l(x) \le c\}$ が任意の $c \in \mathbb{R}$ で凸集合であることをいう.

Lemma 8.6: Anderson の補題

損失関数 l は bowl-shaped であるとする. このとき, $\mathbb{R}^k$ 上の任意の確率測度 M および $k \times k$ 分散共分散行列 Σ に対して,

$$\int l \,\mathrm{d}N(0, \Sigma) \le \int l \,\mathrm{d}\left[N(0, \Sigma) * M\right].$$

つまり, 先の主張は bowl-shaped な損失関数から定まるリスク関数に限って正しい.

次の定理がリスク関数による効率性限界を与える. ただし, 二次モーメントを考えたときとは少し流儀が異なり, T が equivariant-in-law であることは課さず, そのかわりに最大リスク：

$$\sup_h \mathrm{E}_h[l(T - Ah)]$$

を考える. Hodges の反例のリスク関数の挙動を振り返ると, これはこれで Hodges の反例のように真値の近傍で病的なふるまいをする推定量をはじく基準になっていることが分かる.

Theorem 8.7: ランダム化推定量のミニマックスリスク

統計的実験 $(\mathbb{R}^k \times [0,1], \mathcal{B}, \{N(h, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1] \,;\, h \in \mathbb{R}^k\})$ を考える. ただし真値は $h = 0$ でありデータは $(X_0, U) \sim N(0, I(\theta_0)^{-1}) \times \mathrm{Unif}[0,1]$ である. 損失関数 l は bowl-shaped であるとし, A は $p \times k$ 行列とする. このとき, $Ah = 0$ のランダム化推定量 T の最大リスクは

$$\sup_h \mathrm{E}_h[l(T - Ah)] \ge \mathrm{E}_0[l(AX_0)]$$

をみたす. また, $p = 1$ すなわち Ah が実数であり, $\mathrm{E}_0[(AX_0)^2 l(AX_0)] < \infty$ であるとき, $T = AX_0$ は上の不等式を等号で達成する唯一の推定量となる.

Convolution Theorem と同様に, こちらの結果もオリジナルの統計的実験に対して移植される.

Theorem 8.8: 局所漸近ミニマックス定理

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ は $\theta_0 \in \Theta$ において LAN をみたし, LAN の $I(\theta_0)$ は正則行列であるとする. $\mathbb{R}^p$-値関数 $\psi : \theta \mapsto \psi(\theta)$ は微分可能とする. また, $\theta = \theta_0$ の推定量 T_n は正則であるとする. このとき, 任意の bowl-shaped な損失関数 l に対して,

$$\sup_I \liminf_{n\to\infty} \sup_{h\in I} E_{\theta_0+h/\sqrt{n}}\left[l\left(\sqrt{n}\left\{T_n - \psi\left(\theta + \frac{h}{\sqrt{n}}\right)\right\}\right)\right] \geq \int l\ \mathrm{d}N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$$

が成り立つ. ただし, 左辺の最初の sup はすべての有限部分集合 $I \subset \mathbb{R}^k$ にわたってとる. この不等式の等号を達成する推定量は, 損失関数 l について**ミニマックス定理の意味で漸近有効である**という.

8.5 Achieving the Bound

畳み込み定理より, LAN が成り立つときには, $\psi(\theta_0)$ の正則な推定量の中でのベストな漸近分布は $N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$ であることがわかった. では具体的には, この漸近分布に分布収束するような正則な推定量はどうすれば構成できるのだろうか. これが Step 4 における最後の仕事である.

Definition 8.4: 漸近線形な推定量

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ を考える. $\psi(\theta)$ の推定量の列 T_n が $\phi_{\theta_0} \in L_0^2(\mathrm{P}_{\theta_0})$ に関して**漸近線形** (asymptotically linear) であるとは,

$$\sqrt{n}(T_n - \psi(\theta_0)) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \phi_{\theta_0}(X_i) + o_{P_{\theta_0}^n}(1)$$

が成り立つことをいう. 関数 ϕ_{θ_0} を T_n の**影響関数** (influence function) とよぶ. 影響関数は推定量ごとに一意である点に注意する.

いま, DQM が成り立っているとし, DQM の $\dot{l}_{\theta_0}$ と $I(\theta_0)$ について,

$$\phi_{\theta_0}^{\mathrm{eff}}(X) = \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{l}_{\theta_0}(X)$$

なる特別な影響関数を考える. 完全にフライングなのだが, この影響関数を**効率的影響関数** (EIF; efficient influence function) とよぶ. 名前の深い意味などは次章以降で述べるが, とりあえずとても重要な対象だということを抑えてほしい. ここで, DQM の成立を仮定した下で, 効率性限界に達する推定量の特徴づけを行おう.

Theorem 8.9: Best regular ⇔ EIF に関して漸近線形

統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ は $\theta_0 \in \Theta$ において DQM をみたすとする．また, $\mathbb{R}^p$-値関数 $\psi : \theta \mapsto \psi(\theta)$ は微分可能とする．このとき, $\psi(\theta_0)$ の推定量 T_n に関する次の 2 つの命題は同値である．

(i) T_n は正則であり, $\sqrt{n}(T_n - \psi(\theta_0)) \overset{0}{\Rightarrow} N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$.

(ii) T_n は効率的影響関数 $\phi_{\theta_0}^{\mathrm{eff}}(X) = \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{l}_{\theta_0}(X)$ に関して漸近線形.

Proof. (ii) ⇒ (i)：後者の分布収束は中心極限定理よりほとんどただちにしたがうから, 前者の正則性を示せばよい．まず, DQM の仮定より, LAN は $\Delta_{n,\theta_0} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \dot{l}_{\theta_0}(X_i)$ に関して成り立つことに注意する[*12]．中心極限定理より $\Delta_{n,\theta_0} \overset{0}{\Rightarrow} \Delta_{\theta_0} \sim N(0, I(\theta_0))$ である．また,

$$\log \prod_{i=1}^n \frac{\mathrm{dP}_{\theta_0 + h/\sqrt{n}}}{\mathrm{dP}_{\theta_0}}(X_i) = h^\top \Delta_{n,\theta_0} - \frac{1}{2} h^\top I(\theta_0) h + o_{\mathrm{P}_{\theta_0}^n}(1)$$

である．さらに, 漸近線形性より

$$\begin{aligned}\sqrt{n}(T_n - \psi(\theta_0)) &= \frac{1}{\sqrt{n}} \sum_{i=1}^n \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{l}_{\theta_0}(X_i) + o_{P_{\theta_0}}(1) \\ &= \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \Delta_{n,\theta_0} + o_{P_{\theta_0}}(1).\end{aligned}$$

したがって, 連続写像定理と Slutsky の定理を用いれば,

$$\begin{aligned}&\left(\sqrt{n}(T_n - \psi(\theta_0)),\ \log \prod_{i=1}^n \frac{\mathrm{dP}_{\theta_0 + h/\sqrt{n}}}{\mathrm{dP}_{\theta_0}}(X_i)\right) \\ &\quad = \left(\dot{\psi}_{\theta_0} I(\theta_0)^{-1} \Delta_{n,\theta_0},\ h^\top \Delta_{n,\theta_0} - \frac{1}{2} h^\top I(\theta_0) h\right) + o_{P_{\theta_0}}(1) \\ &\quad \overset{0}{\Rightarrow} \left(\dot{\psi}_{\theta_0} I(\theta_0)^{-1} \Delta_{\theta_0},\ h^\top \Delta_{\theta_0} - \frac{1}{2} h^\top I(\theta_0) h\right) \\ &\quad \sim N_{p+1}\left(\begin{pmatrix} 0 \\ -\frac{1}{2} h^\top I(\theta_0) h \end{pmatrix}, \begin{pmatrix} \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top & \dot{\psi}_{\theta_0} h \\ (\dot{\psi}_{\theta_0} h)^\top & h^\top I(\theta_0) h \end{pmatrix}\right).\end{aligned}$$

これにより LeCam の第三補題を用いることができる．すなわち, ψ の微分可能性とあわせて,

$$\begin{aligned}\sqrt{n}(T_n - \psi(\theta_0 + h/\sqrt{n})) &= \sqrt{n}(T_n - \psi(\theta_0)) - \sqrt{n}(\psi(\theta_0 + h/\sqrt{n}) - \psi(\theta_0)) \\ &\overset{h}{\Rightarrow} N_p(\dot{\psi}_{\theta_0} h,\ \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top) - \dot{\psi}_{\theta_0} h \\ &= N_p(0,\ \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top).\end{aligned}$$

したがって, 摂動した確率分布の下での漸近分布は h によらないから, T_n は正則である．

[*12] DQM を課していなくてもこのことが成り立っていれば同じ主張を示せる．あるいは一般に LAN の下で, 推定量が Δ_{n,θ_0} にもとづく漸近線形性をもつと仮定してもよい．ここに non-i.i.d. 拡張の余地がある．

(i) $\Rightarrow$ (ii)：まずは, S_n, T_n はともに (i) の仮定をみたすならば, これらの差は $o_{P^n_{\theta_0}}(1/\sqrt{n})$ になることを示そう．正則性より, $\sqrt{n}(S_n - \psi(\theta_0 + h/\sqrt{n}))$, $\sqrt{n}(T_n - \psi(\theta_0 + h/\sqrt{n}))$ を並べた確率ベクトルの列は摂動先の分布 $\mathrm{P}^n_{\theta_0+h/\sqrt{n}}$ の下で tight であり, Prohorov の定理が適用できる．すなわち, 任意の部分列 $\{n'\}$ に対してさらなるある部分列 $\{n''\}$ が存在して, 同時分布の分布収束

$$\left(\sqrt{n''}\left(S_{n''} - \psi\left(\theta_0 + \frac{h}{\sqrt{n''}}\right)\right), \sqrt{n''}\left(T_{n''} - \psi\left(\theta_0 + \frac{h}{\sqrt{n''}}\right)\right)\right) \overset{h}{\Longrightarrow} (S - \dot{\psi}h,\ T - \dot{\psi}h)$$

が成り立つ．ただし, S, T はそれぞれ, 周辺分布に対する Theorem 8.2 により構成可能な, S_n, T_n のマッチング統計量である．さらに, $\sqrt{n}(S_n - \psi(\theta_0 + h/\sqrt{n}))$, $\sqrt{n}(T_n - \psi(\theta_0 + h/\sqrt{n}))$ はどちらも $N(0, \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \dot{\psi}_{\theta_0}^\top)$ を漸近分布にもつという仮定から, S, T はどちらも Theorem 8.4 の分布 M を退化させるランダム化統計量になっている．したがって, 同定理における一意性を用いると, $S = T$ でなければならない．すなわち, 上記分布収束に対して連続写像定理を適用すれば,

$$\sqrt{n''}(S_{n''} - T_{n''}) \overset{h}{\Longrightarrow} 0.$$

収束先 0 は部分列の取り方によらないから, $\sqrt{n}(S_n - T_n) \overset{h}{\Longrightarrow} 0$ である．とくに $h = 0$ のときに注目すれば, $S_n - T_n = o_{P^n_{\theta_0}}(1/\sqrt{n})$ となる．

したがって, (i) の仮定をみたすどんな 2 つの推定量も, その差は $o_{P^n_{\theta_0}}(1/\sqrt{n})$ である．ところで, (ii) $\Rightarrow$ (i) の証明において, 効率的影響関数に関して漸近線形な推定量 S_n:

$$S_n = \psi(\theta_0) + \frac{1}{\sqrt{n}} \dot{\psi}_{\theta_0} I(\theta_0)^{-1} \Delta_{n,\theta_0} + o_{P^n_{\theta_0}}(1/\sqrt{n})$$

は (i) の仮定をみたすことをすでに示している．つまり, 任意に (i) の仮定をみたす T_n を fix すると, $S_n - T_n = o_{P^n_{\theta_0}}(1/\sqrt{n})$ でなければならないから, 上の式より T_n も効率的影響関数に関して漸近線形になることがわかる．これで (i) $\Rightarrow$ (ii) が示された． □

Theorem 8.9 により, 畳み込み定理の意味で漸近有効な推定量は, 本質的に, 効率的影響関数に関して漸近線形な推定量ただひとつであることがわかった．それでは, 効率的影響関数に関して漸近線形な推定量はどうすれば構成できるのだろうか.

我々はその答えをすでに知っている．**それは最尤法である**．まずは θ そのものを推定する場合, すなわち推定対象の写像 $\psi : \mathbb{R}^k \to \mathbb{R}^k$ が恒等写像の場合を考えよう．このとき $\dot{\psi}_{\theta_0}$ は単位行列になり, 効率的影響関数に関して漸近線形な推定量は

$$\sqrt{n}(T_n - \theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n I(\theta_0)^{-1} \dot{l}_{\theta_0}(X_i) + o_{P^n_{\theta_0}}(1)$$

なる表現をもつ．この表現は, Theorem 4.5: Z-推定量の漸近正規性の証明においてすでに登場している．該当部分を抜き出すと, 最尤推定量を T_n として

$$\sqrt{n}(T_n - \theta_0) = -J_n^{-1} \sqrt{n} \Phi_n(\theta_0) \mathbb{1}_{A_n} + o_{P^n_{\theta_0}}(1)$$

が定理の仮定の下で成り立つことをすでに示している．最尤法は, 推定関数として

$$\Phi_n = \Phi_n(\theta; \mathbf{X}_n) = \frac{1}{n}\sum_{i=1}^{n} \dot{l}_\theta(X_i)$$

を採用した場合に対応している．すなわち,

$$J_n^{-1}\mathbb{1}_{A_n} \xrightarrow{p} \nabla_\theta \Phi(\theta_0)^{-1} = -I(\theta_0)^{-1}$$

が成り立つ．このことを上の式に適用すれば,

$$\begin{aligned}
\sqrt{n}(T_n - \theta_0) &= -J_n^{-1}\sqrt{n}\Phi_n(\theta_0)\mathbb{1}_{A_n} + o_{P_{\theta_0}^n}(1) \\
&= (I(\theta_0)^{-1} + o_{P_{\theta_0}^n}(1))\sqrt{n}\Phi_n(\theta_0) + o_{P_{\theta_0}^n}(1) \\
&= I(\theta_0)^{-1}\sqrt{n}\Phi_n(\theta_0) + o_{P_{\theta_0}^n}(1) \\
&= I(\theta_0)^{-1}\sqrt{n}\frac{1}{n}\sum_{i=1}^{n} \dot{l}_\theta(X_i) + o_{P_{\theta_0}^n}(1) \\
&= \frac{1}{\sqrt{n}}\sum_{i=1}^{n} I(\theta_0)^{-1}\dot{l}_{\theta_0}(X_i) + o_{P_{\theta_0}^n}(1).
\end{aligned}$$

つまり, 最尤推定量は Theorem 4.5 の仮定の下で, 効率的影響関数に関して漸近線形なのである！そしてその一意性から, 畳み込み定理が定める効率性限界に達する正則な推定量は, 必ず最尤推定量と漸近同等になってしまうのだ.

ちなみに, 一般の写像 $\psi : \mathbb{R}^k \to \mathbb{R}^p$ に対しては, まずは θ の最尤推定量 T_n を通常通り構成し, それをプラグインした $\psi(T_n)$ を $\psi(\theta_0)$ の推定量として用いればよい．デルタ法により, $\psi(T_n)$ は $\psi(\theta_0)$ の推定量として畳み込み定理の意味で漸近有効になる (証明略).

【結論】

推定量の効率性限界は畳み込み定理によって与えることができる.

畳み込み定理の意味で漸近有効な推定量の構成の仕方は, 本質的に最尤法しかない.

Coffee Break：有効性理論の結論？

上記の結論は非常に強く, 有用で, その証明の過程も非常に美しいと思う．その一方で,「推定量は正則性をみたすことを議論の前提にすべきだ」というのはひとつの規範でしかない．つまり, Hodges の反例のような縮小推定量を進んで使いたいと思うような人は, この結論にはあまり惹かれないかもしれない．しかし結論の対偶を読めば,「最尤法に漸近分散で勝とうと思ったら, 正則性を破るような病的な漸近挙動を許容する必要がある」となる．この事実はどんな規範意識を持つ人にどっても有益なはずである．また, 実際には尤度関数が非常に複雑であるなど, 最尤法の実装自体が困難である場合も考えられ, 理論的な最善が実践的にも最善であるとは限らないことにも注意する.

Interlude: Statistical Inference × Machine Learning

我々はこれまで, パラメトリックモデルの有効性理論をフォローし, その結論を導き出した. 設定を述べる際はつねに, 「ある統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}_\theta^n\ ;\ \theta \in \Theta\})$ があり...」というように, パラメトリックモデルがすでに与えられている状況下での理論を展開していた. 以降ではより柔軟なモデルに対する有効性理論の拡張に向かって議論が進んでいくため, そのモチベーションについてここで補足しておく.

統計モデルの決定は, 分析がいかなる示唆を提供できるかを左右する重要なステップである. ここでは, 統計的推測のあり方を批判的に語った, van der Laan (2015), Statistics as a Science, Not an Art [*13] というエッセイを紹介しつつ私見を述べたい. Amstat News に掲載されたこのエッセイにおいて, van der Laan は,「統計家は, 我々がもつ知識や目的を真に反映するような統計モデルやターゲットの定式化にこだわるべきだ」と主張する. 統計的推測が, 科学的発見を後押しする手段として役立つことを目指しているとすれば, 誤っていると分かっていながら単純なパラメトリックモデルを用いるのは, 初手で投了しているに等しい.

この主張に反して, George Box による「すべてのモデルは間違っているが, いくつかは有用である」というフレーズは有名である. van der Laan は, よく知られたパラメトリックモデルを決め打ちして単にデータに当てはめただけの分析を, このフレーズを盾にして正当化しようとするのをやめるべきだという. このフレーズが現れたのは 1987 年の論文であり, データ利用可能性やコンピュータの計算能力などの情報技術的な側面からみて, 当時と現在とではデータサイエンスをめぐる状況は大きく異なる. ビッグデータの収集と蓄積はますます進み, それに対する機械学習的な手法も年々進化し続けている. それにもかかわらず, ただ簡単であるためにパラメトリックな分析手法を使い回すことに終始するのは, データ分析に対する誠実な態度とは言いがたいだろう. データの生成過程に関する考察を無視したモデル選択や推測を行うことは, 共にデータ分析に取り組む仲間からの信頼を損なうことにもつながると, van der Laan は指摘する. 仮にすべてのモデルが間違っているとしても, それ自体は, 科学的問いを統計学の言葉で正しく定式化することを目指さなくてもよい理由にはならない.

背後の分布に関して一切仮定を置かないモデリングは必ず正しいのだから, すべてのモデルが間違っているというのは間違っている. いままで扱ってきた古典的なモデルたちが, 現実を正しく反映させるのには単純すぎただけである. 我々はしばしば, データの生成過程について明らかな事実を多少なりとも語ることができる. たとえば, データは無作為抽出されたものであるとか, ある変数の条件付き期待値は下から 0.04 で bound されているとか. このように, データについて明らかな事実のみを反映したモデリングから出発する方が, 正しい科学的知見を導くというゴールに近づくだろう. 現実世界のデータ生成過程は多くの場合に複雑であるから, 有限個の実数で書き下せない統計モデルを自然に考えることになる. このようなモデルを「セミパラメトリックモデル」と呼ぶ.

[*13] *https://magazine.amstat.org/blog/2015/02/01/statscience_feb2015/*

そのうえで我々は, 科学的問いに対する答えとしてふさわしいような推定対象を自ら定義する必要がある. パラメトリックなフレームワークの欠点の一つは, どんなモデルをデータにフィットさせるかを決定するタイミングと, 推定結果がどんな解釈可能性をもつかを決定するタイミングが同時である点にある. 統計モデルのパラメータ自体が知りたい未知の値そのものである保証はどこにもないわけで, とりあえず当てはめればよいというフィッティング偏重の思想では, 元々問うべきだったことを捻じ曲げてしまうおそれがある. 実際, 現実のランダムネスが複雑であればあるほど, それを正確にモデリングするのに適切なパラメトリックモデルを同定するのは難しくなり, 試行錯誤の最中には, どのモデルを用いているかによって推定結果に対する解釈が変わってしまうことになる. セミパラメトリックなモデリングは, 単に柔軟なモデリング手法であるというだけでなく, 科学的問いの答えとして適切な推定対象を定義するためにも役立つ. つまり, パラメトリックな場合とは異なり, 先に正しいモデリングをしてから, モデルのそれぞれの元に実数を対応させることで推定対象を定義することを志向するのである.

もちろん, セミパラメトリックモデルを考えるということは, 分布についてわからないことがずっと多い状態から統計的推測を行わなければならないことを意味する. 実は, 機械学習的なフィッティング手法がこの課題の解決に役立つことがわかってきている. たとえば, 条件付き期待値構造を推定のために用いざるを得ない場合には, それをパラメトリックにモデリングするのではなく, 条件付き期待値関数をまるごと機械学習的にフィッティングさせる手筋が有効かもしれないのである. 近年, 数理統計学は, 未知関数に対する機械学習的な (適応的な) フィッティング手法を取り入れながらも, 推定量の漸近挙動に関する数理統計学的基礎づけをもち, 推定に伴う不確実性を併せて報告できる, 新たなフレームワークの開発と応用に取り組んできた. そのようなフレームワークを, 本稿では Debiaced Inference とよぶ. 続く 9 章と 10 章では, Debiaced Inference の理論と方法論について述べる.

散々パラメトリックモデルのことをこき下ろしてしまったため, いくつか補足事項を述べる. まず, データについて明らかな事実のみを反映するモデリングという文脈でセミパラメトリックモデルを紹介したが, この見方は比較的新しいものかもしれない. 歴史的にはむしろ, パラメトリックモデルから出発して, 有限次元のパラメータで書き下せない部分を未知関数としてモデルの一部に組み込んだものが, 文字通りセミパラメトリックモデルとして提案された (と本稿の著者は認識している). このようなクラシックなセミパラメトリックモデルもまた, モデルの誤特定のおそれが比較的少なく, 盛んに研究されているが, 推定対象そのものでパラメトライズするというスタンスはパラメトリックモデルと変わらない (そのため先述した欠点も共有する) 点に注意する. 次に, van der Laan もパラメトリックモデルが全く役立たずだと書いているわけではないことに留意されたい. 統計的推測が科学的問いに答えるための正しい基礎付けをもつためには, 多くの場合にそれでは単純すぎるというのが彼の主張である. 最後に, 8 章までのパラメトリックモデルにおける有効性理論は, 徒労どころか, セミパラメトリックモデルにおける有効性理論を展開するために必要不可欠な財産でもある. 胸を張って, 統計的推測の有効性理論と機械学習的手法が交差するエキサイティングな領域へと踏み出そう.

9 Debiased Inference: Efficiency Theory

本章では, 8 章までの有効性理論をセミパラメトリックモデルに拡張する. すなわち, 統計モデルが有限個の実数で書き下せないという設定において, 効率性限界をふたたび導出し, その限界に達する推定量の特徴づけを行う. 先ほどは最尤推定量が方法論として最強だという結論に至ったが, セミパラメトリックモデルにおいては事情が異なる. 具体的な推定量の構成方法については次章で述べる.

9.1 Data · Model · Target

われわれがしたいことは変わらない. すなわち, ある $\mathcal{X}$-値のデータ $X_1, X_2, \ldots, X_n$ を用いて, それらがしたがう確率分布の特徴量を推定したい. 8 章までは, パラメトリックモデル $\{\mathrm{P}_\theta\,;\,\theta \in \Theta \subset \mathbb{R}^k\}$ を考え, 真値 θ_0 を i.i.d. データ $X_1, X_2, \ldots, X_n \sim \mathrm{P}_{\theta_0}$ から推定する問題を考えていた. しかし, このような設定には先ほど Interlude で述べたような問題が存在する.

したがって, ここからはパラメトリックとは限らない (ユークリッド空間の部分集合で添字づけられるとは限らない) 統計モデル $\mathcal{P}$ を考えることにしよう. そのようなモデルを一般に**セミパラメトリックモデル** (semiparametric model) という. セミパラメトリックモデル $\mathcal{P}$ として最も広いのは, $\mathcal{X}$ 上に定まるすべての確率分布からなる集合であり, **ノンパラメトリックモデル** (nonparametric model) とよばれる. そのほかにもさまざまなセミパラメトリックモデルが提案されているので, いくつか例を挙げておく. データのノーテーションとして, Y は結果変数, X は説明変数, e はノイズを表すことが多い. 確率変数の次元は整合的に定まっているものとする.

Example 9.1: 回帰モデル

確率変数 (X, Y) と e について,

$$Y = \mu_\theta(X) + \sigma_\theta(X)e$$

なる関係が成り立つとする. ただし, $(x, \theta) \mapsto \mu_\theta(x), \sigma_\theta(x)$ の関数形は既知であるとする. データは (X_i, Y_i) $(i = 1, 2, \ldots, n)$ である. もしも $\sigma_\theta(X) = \sigma$ が定数で $e \sim N(0, 1)$ のときには古典的な回帰モデルに一致する. たとえば e の分布を「原点対称な分布のすべて」の中で動かすときにはセミパラメトリックモデルとなる. つまり,

$$\mathcal{P} = \{\mathrm{P}_{\theta,e}\,;\,\theta \in \Theta,\ e \text{ の分布は原点対称},\ X \text{ の分布は任意}\}.$$

Example 9.2: シングルインデックスモデル

確率変数 (X, Y) と e について,

$$Y = \eta(\theta^\top X) + e$$

なる関係が成り立つとする．データは (X_i, Y_i) $(i = 1, 2, \ldots, n)$ である．関数 $\eta : \mathbb{R} \to \mathbb{R}$ は任意とし, $e \sim N(0, \sigma^2)$ を仮定する．つまり,

$$\mathcal{P} = \{\mathrm{P}_{\theta,\eta}\ ;\ \theta \in \Theta,\ \eta \text{ はある関数},\ X \text{ の分布は任意}\ \}.$$

$\|\theta\| = 1$ などと正規化することでモデルは識別可能条件をみたす．このモデルは**シングルインデックスモデル** (single-index model) とよばれる．e の分布をノンパラメトリックにする拡張も考えることができる．

Example 9.3: ロジスティック回帰

確率変数 (X, Y, Z) を考える．ただし, $Y \in \{0, 1\}$ で,

$$\mathrm{P}(Y = 1 \mid X, Z) = \frac{1}{1 + e^{\theta^\top X + \eta(Z)}}$$

なる関係が成り立つとする．データは (X_i, Y_i, Z_i) $(i = 1, 2, \ldots, n)$ である．関数 $\eta : \mathbb{R} \to \mathbb{R}$ は任意とする．つまり,

$$\mathcal{P} = \{\mathrm{P}_{\theta,\eta}\ ;\ \theta \in \Theta,\ \eta \text{ はある関数},\ X, Z \text{ の分布は任意}\ \}.$$

このモデルは**ロジスティック回帰** (logistic regression) のセミパラメトリックバージョンになっている．

上に挙げたどのモデルも, ありうる確率分布の全体を書き下そうとしたとき, 実数のパラメータ θ のほかに未知関数に依存してしまうことに注意しよう．モデリングにおいては, 真値 $\theta = \theta_0$ が解釈可能な量であるかどうかも重要である．

ノンパラメトリックモデルの場合を含め, 推定対象 (estimand) は, 統計モデル上の関数

$$\psi\ :\ \mathcal{P} \to \mathbb{R}^p$$

によってかくことができる．真の分布 $\mathrm{P}_0 \in \mathcal{P}$ における値 $\psi(\mathrm{P}_0)$ が推定対象となるが, これは**ターゲット** (target) ともよばれる．写像 ψ を**ターゲット写像** (target map) という．ターゲットの例についてもいくつかみておこう．もしも上のように具体的なパラメトライズの仕方を考えている場合には, θ をそのまま返すような写像がターゲット写像としてふさわしいだろう．

Example 9.4: パラメトライズされたターゲット

セミパラメトリックモデルが $\mathcal{P} = \{\mathrm{P}_{\theta,\eta}\,;\,\theta \in \Theta, \eta \in \Xi\}$ と定義されているとする．このとき，ターゲット写像は

$$\psi\ :\ \mathcal{P} \ni \mathrm{P}_{\theta,\eta} \mapsto \theta \in \Theta \subset \mathbb{R}^k$$

として定義できる．

その一方で，ノンパラメトリックモデルは，解釈可能な未知量 θ によって直接パラメトライズされているわけではないため，ターゲット写像の定義を工夫する必要がある．

Example 9.5: ノンパラメトリックなターゲット

確率変数 (X, Y, A) を考える．

1. モーメント：ある $k \in \mathbb{N}$ に対して，

$$\psi\ :\ \mathcal{P} \ni \mathrm{P} \mapsto \mathrm{E}_{\mathrm{P}}[Y^k] \in \mathbb{R}.$$

2. 分位点：P_Y の累積分布関数 F_Y とある $\tau \in (0,1)$ について，

$$\psi\ :\ \mathcal{P} \ni \mathrm{P} \mapsto F_Y^{-1}(\tau) \in \mathbb{R}.$$

3. 裾に関連した条件付き期待値：ある $\tau \in (0,1)$ について，

$$\psi\ :\ \mathcal{P} \ni \mathrm{P} \mapsto \mathrm{E}_{\mathrm{P}}[Y|Y \leq \tau] \in \mathbb{R}.$$

4. **平均処置効果** (ATE; average treatment effect)：A を処置変数として，

$$\psi\ :\ \mathcal{P} \ni \mathrm{P} \mapsto \mathrm{E}_{\mathrm{P}}[\mu_1(X) - \mu_0(X)] \in \mathbb{R},\ \ \mu_a(X) := \mathrm{E}_{\mathrm{P}}[Y|X, A = a].$$

これら以外にもいろいろなターゲットが提案されているが，いずれにせよ (条件付き) モーメントや分位点の組み合わせでかけることが多い．

さて，これで設定を述べるための道具は揃った．すなわち，統計モデルの n 直積 $\mathcal{P}^n = \{\mathrm{P}^n\}$ によって，統計的実験は $(\mathcal{X}^n, \mathcal{B}^n, \mathcal{P}^n)$ とかける．データは $X_1, X_2, \ldots, X_n \sim \mathrm{P}_0$ なる i.i.d. サンプルとして得られ，それを用いてターゲット $\psi(\mathrm{P}_0)$ を推定したい．特にわれわれは，今まで述べてきたような推定量の漸近理論を，現在の一般化された設定の下で再び構築したい．つまりゴールは，

$$\sqrt{n}(T_n - \psi(\mathrm{P}_0)) \xrightarrow{\mathrm{P}_0^n} \mathrm{L}$$

なる分布収束をみたす推定量の中で，最も 0 に集中する L をもつ T_n を見つけ出すことである．ただし，このことをナイーブに実行しようとすると，Hodges の反例によって推定量の最良性の基準を破壊されてしまい，やはりうまくいかない．

したがってここでも，8 章で行ったような，推定量の正則性やたたみこみ定理を用いた議論が必要

になる．推定量の正則性は, 統計的実験の局所化や LAN の成立 (7 章) とあわせた上ではじめてうまく活用できたことを思い出そう．いま考えているセミパラメトリックモデルにおいて, LAN はどのように定義されるべきだろうか．パラメトリックモデルのときとは異なり, 摂動を $\theta_0 + h/\sqrt{n}$ で直接定義するだけでは不十分であり, 関数自由度をもつパラメータ η に関する摂動も考慮する必要がある．したがって, そもそも「スコア関数」とは何なのかもよくわからない．まずはこれらの概念を整理することから始めてみよう．

9.2 Tangent Space and LAN

統計モデル $\mathcal{P}$ はある測度 μ によって dominate されているとし, 確率密度関数を $p = \mathrm{dP}/\mathrm{d}\mu$ とかく．

Definition 9.1: 統計モデル上のパス

ある $\varepsilon > 0$ に対して定まるモデルの部分集合 $\{\mathrm{P}_t \in \mathcal{P}\ ;\ t \in (-\varepsilon, \varepsilon), \mathrm{P}_0 = \mathrm{P}\}$ を, かんたんに $t \mapsto \mathrm{P}_t$ とかく．これを統計モデル $\mathcal{P}$ 上の**パス** (path) あるいは**パラメトリックサブモデル** (parametric submodel) という．

Definition 9.2: 滑らかなパス

$t \mapsto \mathrm{P}_t$ が**滑らかなパス** (smooth path) であるとは, ある可測関数 $g : \mathcal{X} \to \mathbb{R}$ が存在して, DQM 条件

$$\int \left[\sqrt{p_t} - \sqrt{p_0} - \frac{1}{2} g \sqrt{p_0}\right]^2 \mathrm{d}\mu = o(|t|^2), \quad t \to 0 \tag{9.1}$$

が成り立つこととする．このとき, g をパス $t \mapsto \mathrm{P}_t$ の $\mathrm{P}_0 \in \mathcal{P}$ における**スコア関数** (score function) あるいは**接ベクトル** (tangent) という．Theorem 7.1 より $g \in \mathrm{L}_0^2(\mathrm{P}_0)$ である点に注意する．接ベクトル g に対応する滑らかなパスを特に $t \mapsto \mathrm{P}_{t,g}$ とかく．

すなわち滑らかなパスとは, $t = 0$ で接ベクトル g に関して平均二乗微分可能なパス $t \mapsto \mathrm{P}_{t,g}$ のことである．滑らかなパスの全体を考えることにより, 接ベクトルの全体が定まる．

Definition 9.3: 接空間

モデルの部分集合

$$\{g \in \mathrm{L}_0^2(\mathrm{P}_0)\ ;\ g \text{ はある滑らかなパス } t \mapsto \mathrm{P}_{t,g} \text{ の接ベクトル}\}$$

を**接集合** (tangent set) といい, $\dot{\mathcal{P}}_{\mathrm{P}_0}$ とかく．また, 接集合 $\dot{\mathcal{P}}_{\mathrm{P}_0}$ の closed linear span $\overline{\mathrm{lin}}\dot{\mathcal{P}}_{\mathrm{P}_0}$ を**接空間** (tangent space) といい, $\mathcal{H}_{\mathrm{P}_0}$ とかく．したがって, ヒルベルト空間 $\mathrm{L}^2(\mathrm{P}_0)$ の閉部分空間として, $\mathcal{H}_{\mathrm{P}_0}$ はヒルベルト空間になる．

Remark 9.6

接集合は錐である．実際，g を接ベクトルに持つ滑らかなパスを $t \mapsto \mathrm{P}_{t,g}$ とすれば，$t \mapsto \mathrm{P}_{at,g}$ は接ベクトル ag をもつ滑らかなパスになる．多くの場合には，$\dot{\mathcal{P}}_{\mathrm{P}_0}$ はさらに線形空間になっており，このとき接空間 $\mathcal{H}_{\mathrm{P}_0}$ は $\dot{\mathcal{P}}_{\mathrm{P}_0}$ の閉包になる．

ある滑らかなパスの接ベクトルとなるような関数 g の構成は，パス $t \mapsto \mathrm{P}_t$ に対して

$$g(x) = \left.\frac{\partial}{\partial t}\right|_{t=0} \log p_t(x) \quad (x \in \mathcal{X}) \tag{9.2}$$

とおくとうまくいくことが多い．各点 x での t に関する微分可能性から平均二乗微分可能性を導くにあたっては，次の補題が便利である．

Lemma 9.7

パス $t \mapsto \mathrm{P}_t$ を考える．任意の $x \in \mathcal{X}$ において $t \mapsto s_t(x) := \sqrt{p_t}$ は C^1-級であるとする．また，行列 $I(t) := \int (\dot{p}_t/p_t)^2 p_t \mathrm{d}\mu$ は well-defined で連続であるとする．このとき，特に $t = 0$ において，

$$g(x) = \left.\frac{\partial}{\partial t}\right|_{t=0} \log p_t(x) \quad (x \in \mathcal{X}).$$

について DQM 条件 (9.1) が成り立つ．

Proof. Lemma 7.2 をパス $t \mapsto \mathrm{P}_t$ に適用すればただちにしたがう． □

Definition 9.4: LAN

Theorem 7.1 と (9.1) の微分可能性は，$I_0 = \mathrm{E}_{\mathrm{P}_0}[g^2]$ について，

$$\log \prod_{i=1}^{n} \frac{\mathrm{dP}_{1/\sqrt{n},g}}{\mathrm{dP}_0}(X_i) = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} g(X_i) - \frac{1}{2} I_0 + o_{\mathrm{P}_0}(1) \tag{9.3}$$

を導く．任意の滑らかなパス $t \mapsto \mathrm{P}_{t,g}$ に対して (9.3) が成り立つとき，モデル $\mathcal{P}$ は $\mathrm{P}_0 \in \mathcal{P}$ において LAN をみたすという．

Example 9.8: パラメトリックモデルの接空間

パラメトリックモデル $\mathcal{P} = \{\mathrm{P}_\theta \,;\, \theta \in \Theta \subset \mathbb{R}^k\}$ の $\mathrm{P}_{\theta_0} \in \mathcal{P}$ における接空間は，

$$\mathcal{H}_{\mathrm{P}_0} = \dot{\mathcal{P}}_{\mathrm{P}_0} = \mathrm{lin}\left\{ \frac{\partial}{\partial \theta^1} \log p(x;\theta_0^1), \frac{\partial}{\partial \theta^2} \log p(x;\theta_0^2), \ldots, \frac{\partial}{\partial \theta^k} \log p(x;\theta_0^k) \right\}.$$

ただし，対応する滑らかなパスが Lemma 9.7 の仮定をみたすように取れるとする．これはパスごとに chain rule を考えることによりわかる．すなわち，パラメトリックモデルの接空間の次元はパラメータの次元に等しい．

Example 9.9: ノンパラメトリックモデルの接空間

ノンパラメトリックモデル $\mathcal{P} = \{\mathrm{P}\ ;\ \mathrm{P}$ は $\mathcal{X}$ 上に定まる確率分布 $\}$ の $\mathrm{P}_0 \in \mathcal{P}$ における接集合は

$$\dot{\mathcal{P}}_{\mathrm{P}_0} = \mathcal{H}_{\mathrm{P}_0} = \mathrm{L}_0^2(\mathrm{P}_0)$$

となる．このことは, 任意の $g \in \mathrm{L}_0^2(\mathrm{P}_0)$ に対して, 滑らかなパス $t \mapsto \mathrm{P}_{t,g}$ を構成すれば示されるが, たとえば

$$p_t(x) = c(t)k(tg(x))p_0(x)$$

を考えればよい．ただし, $c(t)$ は t ごとの正規化定数

$$c(t) = 1/\int_{\mathcal{X}} k(tg(x))p_0(x)\mathrm{d}x$$

で, $k(u)$ は非負かつ $k(0) = k'(0) = 1$ をみたす関数である．k としては, たとえば

$$k(u) = 2(1 + e^{-2u})^{-1}$$

とすればよい．k が有界でもある点に注意する．
いま定めた p_t についてスコア関数を計算すると,

$$\begin{aligned}
\left.\frac{\partial}{\partial t}\right|_{t=0} \log p_t(x) &= \left.\frac{\partial}{\partial t}\right|_{t=0} (\log c(t) + \log k(tg(x)) + \log p_0(x)) \\
&= \left.\frac{c'(t)}{c(t)} + \frac{1}{k(tg(x))}k'(tg(x))g(x) + 0\right|_{t=0} \\
&= \frac{c'(0)}{c(0)} + \frac{1}{k(0)}k'(0)g(x) \\
&= c'(0) + g(x).
\end{aligned}$$

$c'(0)$ については, 上の k を採用すれば, k の有界性にもとづき積分記号下での微分を行うことで,

$$c'(0) = -\left.\frac{\int_{\mathcal{X}} k'(tg(x))g(x)p_0(x)\mathrm{d}x}{\{\int_{\mathcal{X}} k(tg(x))p_0(x)\mathrm{d}x\}^2}\right|_{t=0} = -\int_{\mathcal{X}} g(x)p_0(x)\mathrm{d}x = 0.$$

したがって,

$$\left.\frac{\partial}{\partial t}\right|_{t=0} \log p_t(x) = g(x)$$

がしたがう．この $g(x)$ の下で DQM も成り立つことも Lemma 9.7 を用いればわかる (証明略).

定義より, ひとつの滑らかなパスに注目すれば, それは DQM が成り立つようなパラメトリックモデルになっているので, 8 章の結果を適用することが可能である．フィッシャー情報量は

$I_0 = \mathrm{E}_{\mathrm{P}_0}[g^2]$ によって与えられているから, Theorem 8.5 の効率性下限は

$$\left(\left.\frac{\partial}{\partial t}\right|_{t=0}\psi(\mathrm{P}_{t,g})\right)\mathrm{E}_{\mathrm{P}_0}[g^2]^{-1}\left(\left.\frac{\partial}{\partial t}\right|_{t=0}\psi(\mathrm{P}_{t,g})\right)^{\top}$$

となる. この形の効率性下限が滑らかなパス $t \mapsto \mathrm{P}_{t,g}$ を固定するごとに得られるわけだが, そうなると, どの効率性下限が「本当の」効率性下限なのだろうか. 滑らかなパスは統計モデルの部分集合なので, 直観的には, 滑らかなパス上での統計的推測はもとの統計的推測よりも簡単になっていてほしい. すなわち, 滑らかなパスごとの効率性下限はどれも, もとのセミパラメトリックモデルに対して定義すべき効率性下限よりも小さくなっているべきだろう. この点を鑑みて, 滑らかなパスごとの効率性下限の sup を「本当の」効率性下限とみなすのは一つの手であるように思われる. つまり,

$$\sup_{t\mapsto \mathrm{P}_{t,g}}\left(\left.\frac{\partial}{\partial t}\right|_{t=0}\psi(\mathrm{P}_{t,g})\right)\mathrm{E}_{\mathrm{P}_0}[g^2]^{-1}\left(\left.\frac{\partial}{\partial t}\right|_{t=0}\psi(\mathrm{P}_{t,g})\right)^{\top}$$

のような値に興味が移る. ただし, sup は正定値対称行列の集合に二次形式で順序を入れる場合には存在するとは限らないことに注意する (ターゲットが 1 次元ならば問題なく定まる). われわれがしたいのは, 厳密な意味で上記の sup を定式化するというよりは, 二次形式の意味で個々の滑らかなパスの効率性下限よりも大きいという条件を手掛かりに, 二次形式の意味であらゆる正則な推定量の漸近分散を下から抑えるような行列を特定することである.

9.3 Pathwise-Differentiability

滑らかなパスごとの効率性下限はターゲット写像の導関数を含んでいる. さらなる解析のためには, $\psi(\mathrm{P}_t)$ の微分の挙動をより明快に書き下す必要がありそうだ. そのため, 上で定義した接集合の概念を用いて, ターゲット ψ に関するある種の滑らかさを定義したい. すなわち, 背後の分布をモデル上でわずかに摂動したときのターゲットの微小変化率を, 接ベクトルにもとづく方向微分として定式化したい. ここにおける分布の摂動を, 滑らかなパスに沿って行うことにより, 接空間上の汎函数としてターゲットの導関数を定義する.

Definition 9.5: pathwise 微分

ターゲット $\psi : \mathcal{P} \to \mathbb{R}^k$ が接集合 $\dot{\mathcal{P}}_{\mathrm{P}_0}$ 上で $\mathrm{P}_0 \in \mathcal{P}$ において **pathwise 微分可能** (pathwise differentiable) であるとは, ある有界線形汎関数 $\dot{\psi}_{\mathrm{P}_0} : \mathcal{H}_{\mathrm{P}_0} \to \mathbb{R}^k$ が存在して, 任意の接ベクトル $g \in \dot{\mathcal{P}}_{\mathrm{P}_0}$ と, g を接ベクトルにもつ滑らかなパス $t \mapsto \mathrm{P}_t$ に対して,

$$\frac{\psi(\mathrm{P}_t) - \psi(\mathrm{P}_0)}{t} \longrightarrow \dot{\psi}_{\mathrm{P}_0} g \quad (t \to 0) \tag{9.4}$$

であることとする. $\dot{\psi}_{\mathrm{P}_0}$ をターゲット写像 ψ の **pathwise 導関数** (pathwise derivative) という.

ψ が pathwise 微分可能なとき, Riesz の表現定理より, pathwise 導関数 $\dot{\psi}_{\mathrm{P}_0}$ を $\mathcal{H}_{\mathrm{P}_0}$ において成分ごとに内積表現できる. つまり, ある $\tilde{\psi}_{\mathrm{P}_0} : \mathcal{X} \to \mathbb{R}^k$ が存在して,

$$\dot{\psi}_{\mathrm{P}_0} g = \langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}} = \int \tilde{\psi}_{\mathrm{P}_0} g \, \mathrm{dP}_0 \quad (g \in \mathcal{H}_{\mathrm{P}_0}) \tag{9.5}$$

が成り立つ. ただし内積は成分ごとに計算するものとする.

Definition 9.6: 効率的影響関数

ターゲット写像 ψ の pathwise 微分 $\dot{\psi}_{\mathrm{P}_0} : \mathcal{H}_{\mathrm{P}_0} \to \mathbb{R}^k$ は, 各成分で Riesz representer による表現をもつ. (9.5) にもとづき与えられる Riesz representer $\tilde{\psi}_{\mathrm{P}_0} \in \mathcal{H}_{\mathrm{P}_0}$ を**効率的影響関数** (EIF; efficient influence function) という.

Example 9.10: パラメトリックモデルの EIF

パラメトリックモデル $\mathcal{P} = \{\mathrm{P}_\theta \,;\, \theta \in \Theta \subset \mathbb{R}^k\}$ の上のターゲット写像を, ユークリッド空間上の微分可能な関数 $\chi : \mathbb{R}^k \to \mathbb{R}^p$ を用いて

$$\psi \;:\; \mathcal{P} \ni \mathrm{P}_\theta \mapsto \chi(\theta) \in \mathbb{R}^p$$

で定める. また, フィッシャー情報行列 $I_{\theta_0} = \mathrm{E}_{\theta_0}[\dot{l}_{\theta_0} \dot{l}_{\theta_0}^\top]$ は正則行列であるとする. このとき, ターゲット写像の勾配について

$$\left.\frac{\partial}{\partial t}\right|_{t=0} \chi(\theta_0 + th) = \dot{\chi}_{\theta_0} h = \mathrm{E}_{\theta_0}[(\dot{\chi}_{\theta_0} I_{\theta_0}^{-1} \dot{l}_{\theta_0}) h^\top \dot{l}_{\theta_0}]$$

が任意の局所パラメータ $h \in \mathbb{R}^k$ に対して成り立つ. つまり, $\chi(\theta)$ が微分可能で I_{θ_0} が正則行列ならば ψ の pathwise 微分可能性がしたがう. 局所パラメータ h に対応するスコアは $h^\top \dot{l}_{\theta_0}$ であったから, ψ の P_{θ_0} における EIF は, (9.5) 式より

$$\tilde{\psi}_{\mathrm{P}_{\theta_0}} = \dot{\chi}_{\theta_0} I_{\theta_0}^{-1} \dot{l}_{\theta_0}$$

で与えられることがわかる. これは 8.5 節でヒューリスティックに定義された関数そのものである！

証明は次章に回すが, ノンパラメトリックモデルに対するターゲットの EIF についても具体形の例を見てみよう.

Example 9.11: ノンパラメトリックなターゲットの EIF

$Z = (X, Y, A)$ とおく. 期待値 $\mathrm{E}_{\mathrm{P}_0}[Y]$ の EIF は,

$$\tilde{\psi}_{\mathrm{P}_0}(Z) = Y - \mathrm{E}_{\mathrm{P}_0}[Y].$$

また, 平均処置効果については,

$$\psi(\mathrm{P}_0) = \mathbb{E}_{\mathrm{P}_0}\big[\mu_1(X) - \mu_0(X)\big],$$
$$\mu_a(x) = \mathbb{E}_{\mathrm{P}_0}[Y \mid X = x, A = a], \quad e(x) = \mathrm{P}_0(A = 1 \mid X = x)$$

とすると, EIF は

$$\tilde{\psi}_{\mathrm{P}_0}(Z) = \frac{A}{e(X)}\big(Y - \mu_1(X)\big) - \frac{1-A}{1-e(X)}\big(Y - \mu_0(X)\big) + \mu_1(X) - \mu_0(X) - \psi(\mathrm{P}_0).$$

一般に, セミパラメトリックモデルにおいては, EIF の導出はターゲットごとにケースバイケースで行うもので, 陽に求められるとも限らない. 導出方法などの詳細は次章で扱う.

さて, ターゲット写像 ψ が pathwise 微分可能であるときには, 前節最後に述べた効率性下限についてより明快な表現を与えることができる. すなわち, 滑らかなパス $t \mapsto \mathrm{P}_t$ とその接ベクトル g を固定すると,

$$\left.\frac{\partial}{\partial t}\right|_{t=0} \psi(\mathrm{P}_t) = \dot{\psi}_{\mathrm{P}_0} g = \langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}}$$

が成り立つ. さらにフィッシャー情報量が $I_0 = \mathrm{E}_{\mathrm{P}_0}[g^2]$ で与えられていたことに注意すれば,

$$\left(\left.\frac{\partial}{\partial t}\right|_{t=0} \psi(\mathrm{P}_t)\right) I_0^{-1} \left(\left.\frac{\partial}{\partial t}\right|_{t=0} \psi(\mathrm{P}_t)\right)^\top = (\langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}})(\langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}})^\top / \langle g, g \rangle_{\mathcal{H}_{\mathrm{P}_0}}$$

となる. 分子は行列, 分母はスカラーになっている. 2 次形式の意味での上界は, Cauchy-Schwarz の不等式より次のようにして与えられる.

Proposition 9.12: 最も不利なパラメトリックサブモデル

行列 $\Sigma(g)$ を

$$\Sigma(g) := (\langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}})(\langle \tilde{\psi}_{\mathrm{P}_0}, g \rangle_{\mathcal{H}_{\mathrm{P}_0}})^\top / \langle g, g \rangle_{\mathcal{H}_{\mathrm{P}_0}}$$

とおく. このとき, 任意の $g \in \mathcal{H}_{\mathrm{P}_0}$ に対して, 二次形式の意味で

$$\Sigma(g) \leq \mathrm{E}[\tilde{\psi}_{\mathrm{P}_0} \tilde{\psi}_{\mathrm{P}_0}^\top]$$

が成り立つ. [a]

[a] このことから, 特に 1 次元のターゲットについて滑らかなパス $t \mapsto \mathrm{P}_{t,\tilde{\psi}_{\mathrm{P}_0}}$ がとれるならば, これを**最も不利なパラメトリックサブモデル** (least favorable submodel) とよぶ.

Proof. 二次形式をひとつ固定するごとに Cauchy-Schwarz の不等式を適用すればしたがう. □

この命題を直接使って何か議論をするわけではないが, $\mathrm{E}[\tilde{\psi}_{\mathrm{P}_0} \tilde{\psi}_{\mathrm{P}_0}^\top]$ がもとのセミパラメトリックモデルに対する効率性下限としての最有力候補であることを示唆する点で, 重要な命題といえる.

9.4 Efficiency Bounds for Regular Estimators

セミパラメトリックモデルに対する効率性下限を導出するため, まずは推定量の正則性をふさわしい形で定義しなおそう. 滑らかなパス $t \mapsto \mathrm{P}_{t,g}$ に沿った分布収束 $X_n \xRightarrow{\mathrm{P}_{1/\sqrt{n},g}} X$ を

$$X_n \overset{g}{\Rightarrow} X$$

とかく.

Definition 9.7: 推定量の正則性

$\psi(\mathrm{P}_0)$ の推定量の列 T_n が**正則** (regular) であるとは, ある確率分布 L_0 が存在して以下が成り立つことをいう.

$$\sqrt{n}(T_n - \psi(\mathrm{P}_{1/\sqrt{n},g})) \overset{g}{\Rightarrow} \mathrm{L}_0 \quad ({}^\forall t \mapsto \mathrm{P}_{t,g}).$$

収束先が g によらないことまで要請している点に注意する.

Coffee Break : 分布の摂動を特徴づけるもの

ここまでで, LAN や pathwise 微分, 推定量の正則性といった重要概念の定義ができた. 8 章までを振り返ると, パラメトリックモデルにおける分布の摂動は局所パラメータ $h \in \mathbb{R}^k$ で定義されていた. Chain rule により, 局所パラメータ $h \in \mathbb{R}^k$ に対応するスコア関数が $g = h^\top \dot{l}_{\theta_0}$ であることはすでに述べたが, ここではスコア関数を直接考える方が筋が良い. すなわち, パラメトリックなモデリングに依存したユークリッド空間上の摂動を考えるのではなく, 各々の局所パラメータに対応する**スコア関数で摂動を考えている**のである. 接空間の元を接ベクトルと呼ぶのは, ターゲット写像の方向微分を与える方向ベクトルであるというだけではなく, 分布の摂動を特徴づけるベクトルであることにも拠っている. 関数空間上の摂動への議論の転換は有効性理論の拡張において本質的であり, このことを理解するとさらに見通しが良くなる.

8 章までの議論, とくに畳み込み定理を援用することで, 正則な推定量の効率性限界を導出することが可能になる.

Theorem 9.13: Hájek–Le Cam の畳み込み定理

統計モデル $\mathcal{P}$ とその接空間 $\mathcal{H}_{\mathrm{P}_0}$ を考える. ただし接集合は凸であるとする. ターゲット写像 $\psi : \mathcal{P} \to \mathbb{R}^p$ は $\mathrm{P}_0 \in \mathcal{P}$ において pathwise 微分可能であるとし, EIF を $\tilde{\psi}_{\mathrm{P}_0}$ とかく. また, $\psi(\mathrm{P}_0)$ の推定量 T_n は正則であり, 収束先は

$$\sqrt{n}(T_n - \psi(\mathrm{P}_0)) \overset{0}{\Rightarrow} \mathrm{L}_0$$

であるとする．このとき, ある確率分布 M_0 が存在して,

$$\mathrm{L}_0 = N_p(0, \Sigma_0) * M_0, \quad \Sigma_0 = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\tilde{\psi}_{\mathrm{P}_0}^\top]$$

とかける．$N(0, \Sigma_0)$ を漸近分布にもつ正則な推定量は**畳み込み定理の意味で漸近有効である**という．

Proof. 接集合が線形空間である場合のみ証明する．接集合が凸であるが線形空間であるとは限らない場合への拡張は vdV Theorem 25.20 を参照.

まず, 接集合の正規直交系 $\boldsymbol{g} = (g^1, g^2, \ldots, g^k)$ を任意に固定する．このとき, 局所パラメータ $h \in \mathbb{R}^k$ に関する統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{1/\sqrt{n}, h^\top \boldsymbol{g}}\ ;\ h \in \mathbb{R}^k\})$ は DQM をみたしている．また, 滑らかなパス $t \mapsto \mathrm{P}_{t, h^\top \boldsymbol{g}}$ に対する pathwise 微分可能性より,

$$\sqrt{n}(\psi(\mathrm{P}_{1/\sqrt{n}, h^\top \boldsymbol{g}}) - \psi(\mathrm{P}_0)) \to \dot{\psi}(h^\top \boldsymbol{g}) = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\boldsymbol{g}^\top]h =: Ah.$$

$A = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\boldsymbol{g}^\top]$ は $p \times k$ 行列である．これにより, 統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{1/\sqrt{n}, h^\top \boldsymbol{g}}\ ;\ h \in \mathbb{R}^k\})$ に対応する畳み込み表現が得られる．すなわち, ある確率分布 M_g が存在して,

$$\mathrm{L}_0 = N_p(0, AA^\top) * M_{\boldsymbol{g}}.$$

ただし, フィッシャー情報行列が単位行列になっていることを用いた．さて, 接集合が線形空間であるため, 接空間はその閉包になっている．すなわち, 次元 $k = k(m)$ も可変であるとした下で正規直交系 $\boldsymbol{g}_m = (g^1_m, g^2_m, \ldots, g^k_m)$ の列を適当にとれば, EIF $\tilde{\psi}_{\mathrm{P}_0}$ の各成分における $\overline{\mathrm{lin}}\ \boldsymbol{g}_m$ への射影

$$\Pi_{\overline{\mathrm{lin}}\ \boldsymbol{g}_m}\tilde{\psi}_{\mathrm{P}_0} = A_m \boldsymbol{g}_m, \quad A_m = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\boldsymbol{g}_m^\top]$$

の列は $\tilde{\psi}_{\mathrm{P}_0}$ 自身にいくらでも近づく．したがって,

$$A_m A_m^\top = \mathrm{E}_{\mathrm{P}_0}[A_m \boldsymbol{g}_m \boldsymbol{g}_m^\top A_m^\top] = \mathrm{E}_{\mathrm{P}_0}[A_m \boldsymbol{g}_m (A_m \boldsymbol{g}_m)^\top] \to \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\tilde{\psi}_{\mathrm{P}_0}^\top] = \Sigma_0$$

となるようにできる．

いままでに分かったことをまとめると,

$$\mathrm{L}_0 = N_p\left(0, A_m A_m^\top\right) * M_{\boldsymbol{g}_m} \ \ (m \in \mathbb{N}), \quad A_m A_m^\top \to \Sigma_0.$$

このとき, $M_{\boldsymbol{g}_m}$ の tightness と Prohorov の定理より, ある確率分布 M_0 が存在して

$$\mathrm{L}_0 = N(0, \Sigma_0) * M_0$$

が成り立つ．以上で証明が終わる． □

Q7. Theorem 9.13 の証明について, $A_m \boldsymbol{g}_m \to \tilde{\psi}_{\mathrm{P}_0}$ in $\mathcal{H}_{\mathrm{P}_0}^{\otimes p}$ をみたすように, 接集合の正規直交系の列 $\boldsymbol{g}_m$ を構成せよ．(関数解析をまじめにやる.)

Q8. Theorem 9.13 の証明について, 最後の議論を補完せよ．(畳み込みが周辺分布の弱収束について「連続」であることに注目する.)

Coffee Break

上の証明では, パラメトリックモデルに対する効率性下限 (Theorem 8.5) をフル活用した. 少し手間があるのは, EIF が接集合の元であるとは限らないことによっていて, 接空間の適当な部分空間を拡大していきながら, 内積構造を利用して EIF を近似する必要があった. もしも EIF が接集合の元でもあるならば証明がどうなるかも考えてみよう.

9.5 Achieving the Bounds

効率性下限が導出できたら, こんどはその下限に達する推定量の構成を考える. という流れも 8 章と同様である.

Theorem 9.14: Best regular ⇔ EIF に関して漸近線形

統計モデル $\mathcal{P}$ とその接空間 $\mathcal{H}_{\mathrm{P}_0}$ を考える. ターゲット写像 $\psi : \mathcal{P} \to \mathbb{R}^p$ は $\mathrm{P}_0 \in \mathcal{P}$ において pathwise 微分可能であるとし, EIF を $\tilde{\psi}_{\mathrm{P}_0}$ とかく. このとき, $\psi(\mathrm{P}_0)$ の推定量 T_n に関する次の 2 つの命題は同値である.

(i) T_n は正則であり, $\sqrt{n}(T_n - \psi(\mathrm{P}_0)) \overset{0}{\Rightarrow} N(0, \Sigma_0)$, $\Sigma_0 = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\tilde{\psi}_{\mathrm{P}_0}^\top]$.

(ii) T_n は EIF $\tilde{\psi}_{\mathrm{P}_0}(X)$ に関して漸近線形：

$$\sqrt{n}(T_n - \psi(\mathrm{P}_0)) = \frac{1}{\sqrt{n}}\sum_{i=1}^{n}\tilde{\psi}_{\mathrm{P}_0}(X_i) + o_{\mathrm{P}_0^n}(1).$$

Proof. 接集合が線形空間である場合のみ証明する.

(ii) ⇒ (i)：後者の分布収束は中心極限定理よりただちにしたがうから, 前者の正則性を示せばよいが, これも Theorem 8.9 の証明とほとんど同様である.

(i) ⇒ (ii)：Theorem 8.9 の証明と方針は同様であり, S_n, T_n がともに (i) の仮定をみたすならば, これらの差は $o_{\mathrm{P}_0^n}(1/\sqrt{n})$ になることを示せばよい. まず, 各推定量について

$$\sqrt{n}(S_n - \psi(\mathrm{P}_0)) \overset{0}{\Rightarrow} N(0, \Sigma_0), \quad \sqrt{n}(T_n - \psi(\mathrm{P}_0)) \overset{0}{\Rightarrow} N(0, \Sigma_0).$$

いま, 接集合の正規直交系 $\boldsymbol{g} = (g^1, g^2, \ldots, g^k)$ を任意に固定する. このとき, 局所パラメータ $h \in \mathbb{R}^k$ に関する統計的実験 $(\mathcal{X}^n, \mathcal{B}^n, \{\mathrm{P}^n_{1/\sqrt{n}, h^\top \boldsymbol{g}} ; h \in \mathbb{R}^k\})$ は DQM をみたしている. 推定量の正則性と Prohorov の定理を合わせれば, 任意の部分列 $\{n'\} \subset \{n\}$ に対してさらにある部分列 $\{n''\} \subset \{n'\}$ が存在して,

$$\left(\sqrt{n''}\left(S_{n''} - \psi\left(\mathrm{P}^{n''}_{1/\sqrt{n''}, h^\top \boldsymbol{g}}\right)\right), \sqrt{n''}\left(T_{n''} - \psi\left(\mathrm{P}^{n''}_{1/\sqrt{n''}, h^\top \boldsymbol{g}}\right)\right)\right) \overset{h}{\Rightarrow} (S - Ah,\ T - Ah)$$

$$\text{where} \quad X_h \sim N_k(h, E_p), \ \ S(X_h, U) - Ah, T(X_h, U) - Ah \sim N_p(0, AA^\top), \ A = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}\boldsymbol{g}^\top].$$

したがって,

$$\mathrm{E}_h[S] = \mathrm{E}_h[T] = Ah$$

となる．ただし, 添字の h は $N_k(h, E_p) \times \mathrm{Unif}[0,1]$ に関する期待値を表す．両辺の h による微分を考えれば, 正規分布のスコア関数の形に注意して

$$\left.\frac{\partial}{\partial h}\right|_{h=0} \mathrm{E}_h[S] = \mathrm{E}_0[SX_0] = A, \quad \left.\frac{\partial}{\partial h}\right|_{h=0} \mathrm{E}_h[T] = \mathrm{E}_0[TX_0] = A.$$

したがって, S, T の X_0 への射影

$$\Pi S = \mathrm{E}_0[SX_0]X_0, \quad \Pi T = \mathrm{E}_0[TX_0]X_0$$

について,

$$\Pi S = \Pi T = AX.$$

すなわち,

$$\mathrm{Cov}_0[S - T] = \mathrm{Cov}_0[\Pi^\top S - \Pi^\top T] \leq 2\mathrm{Cov}_0[\Pi^\top S] + 2\mathrm{Cov}_0[\Pi^\top T].$$

さきほど畳み込み定理の証明で行ったのと同様に, $AA^\top$ の列が Σ_0 に収束するように正規直交系 $\boldsymbol{g}$ の列を接集合から構成できるので,

$$\mathrm{Cov}_0[\Pi^\top S] = \mathrm{Cov}_0[S] - \mathrm{Cov}_0[\Pi S] = \Sigma_0 - AA^\top \to 0.$$

$\mathrm{Cov}_0[\Pi^\top T]$ についても同様である．すなわち,

$$\mathrm{Cov}_0[S - T] = 0 \quad \text{i.e.} \;\; S = T \;\; (\text{a.s.}).$$

これより, 上でみた分布収束に対して連続写像定理を適用すれば,

$$\sqrt{n''}(S_{n''} - T_{n''}) \overset{h}{\Longrightarrow} S - T = 0.$$

収束先 0 は部分列の取り方によらないから, $\sqrt{n}(S_n - T_n) \overset{h}{\Longrightarrow} 0$ である．とくに $h = 0$ のときに注目すれば, $S_n - T_n = o_{\mathrm{P}_0^n}(1/\sqrt{n})$ となる． □

したがって, 畳み込み定理の意味で漸近有効な推定量は, EIF に関して漸近線形な推定量のみに限られる．さて, それではどうやって EIF に関して漸近線形な推定量を構成すればよいのだろうか．パラメトリックな場合には, EIF の形が対数尤度にもとづいて統一的に表現できることが分かっていて, 最尤法が最良の推定量を与えることも調べられた．今回のケースではモデルが未知関数に依存しているなどの理由で, 最尤法に基づく方法論を単純に適用することはできない．次章では, EIF の導出方法や, EIF に関して漸近線形な推定量の構成方法について考えよう．

10 Debiased Inference: Methodology

10.1 Plug-in Estimation

9 章では, セミパラメトリックモデルにおいて pathwise 微分可能なターゲットを考えるとき, 畳み込み定理の意味で漸近有効な推定量は EIF に関して漸近線形でなければならないことをみた. したがって本章での目標は, そのような推定量を具体的に構成することである. 以下では話を簡単にするため, 具体例を扱う際には, ノンパラメトリックモデルの下で, 平均処置効果

$$\psi(\mathrm{P}_0) = \mathrm{E}_{\mathrm{P}_0}\big[\mu_1(X) - \mu_0(X)\big], \qquad \mu_a(x) := \mathrm{E}_{\mathrm{P}_0}[Y \mid X = x, A = a]$$

の推定問題に注目する.

もっとも, パラメトリックモデルのときのように, 対数尤度を最大化すれば自動的に最良の推定量が得られる, という状況はもはや期待できない. ノンパラメトリックモデルではモデルが直接実数でパラメトライズされているわけではなく, 最尤法にもとづく方法論をそのまま適用することは一般に不可能だ. したがって, いきなり EIF に関して漸近線形な推定量を直接作ろうとしても, 方針に迷ってしまうだろう.

そこでまずは, ターゲットの形そのものに注目してみよう. セミパラメトリックモデルにおけるターゲットは, 未知関数や条件付き期待値といった無限次元の対象を含んだ量として書かれることが多い. そのような場合には, まずそれらの未知部分をデータから推定し, その後でターゲット写像の中に代入する, というのが最も自然な発想に思われる. この発想の利点は, 未知関数の推定に機械学習的な手法をそのまま流用できる点にある. 線形回帰やロジスティック回帰のような有限次元モデルをあらかじめ仮定しなくても, ランダムフォレストやニューラルネットなどを用いて未知関数を直接フィッティングすることができる. その結果, モデルの誤特定を避けながら柔軟な推定量を構成できそうである.

Definition 10.1: plug-in estimator

ターゲット写像 $\psi : \mathcal{P} \to \mathbb{R}^p$ を考える. P_0 の推定量 $\hat{\mathrm{P}}_n$ が与えられているとき, $\psi(\hat{\mathrm{P}}_n)$ を $\psi(\mathrm{P}_0)$ の**プラグイン推定量** (plug-in estimator) という.

すなわち, プラグイン推定量とは, ターゲット写像の中に現れる未知の分布あるいは未知関数をその推定量でそのまま置き換えて得られる推定量のことである.

ATE の場合には, ターゲット写像

$$\mathrm{P} \mapsto \mathrm{E}_{\mathrm{P}}\big[\mu_1(X) - \mu_0(X)\big]$$

に含まれる未知関数 μ_a をその推定量 $\hat{\mu}_a$ で置き換え, さらに期待値を経験平均で置き換えることにより,

$$\hat{\mathrm{P}}_n := \frac{1}{n}\sum_{i=1}^{n}\big\{\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)\big\}$$

という具体的な推定量が得られる．

Coffee Break

$\hat{\mathrm{P}}_n$ の実体に気を遣いすぎる必要はない．ATE の場合にあえて正確な定義を与えるならば，データへのフィッティングにより得られたランダムな関数と条件付き期待値構造が等しく，X の期待値がデータに基づく標本平均に等しいような分布のひとつを $\hat{\mathrm{P}}_n$ と定めたということになる．しかし普段は，単にある推定量を構成した結果を，確率変数としてまるごと $\psi(\hat{\mathrm{P}}_n)$ と書いているだけだと思った方が見通しが良いかもしれない．

しかし，実はこの推定量は一般には $\sqrt{n}$-consistent になるとは限らない．つまり，漸近有効性どころか，漸近正規性

$$\sqrt{n}\Big(\psi(\hat{\mathrm{P}}_n) - \psi(\mathrm{P}_0)\Big) \xrightarrow{\mathrm{P}_0^n} N(0, \Sigma)$$

の成立すら保証できないのだ．本質的な原因は，一般に未知関数を機械学習的なフィッティングによって推定した際には，有限次元パラメータ推定のような $\sqrt{n}$ レートをもたないことにある．パラメトリックなモデルを仮定しないことでモデルの誤特定を防ぐことができるのはよいのだが，その代償として，広いクラスの関数に対して適応的にフィッティングを行うための，収束レートの低下が起きてしまう．したがって，plug-in estimator をそのまま用いるだけでは，推定誤差の影響を十分に小さくできない．

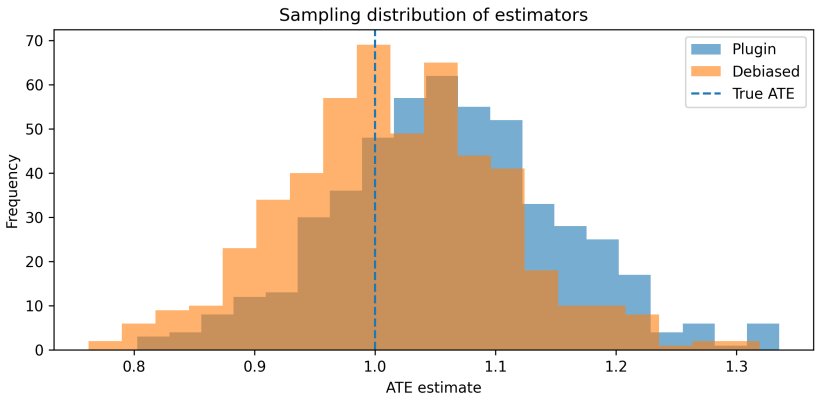

図 4　プラグイン推定量 (青) はバイアスしている．バイアス補正を行った推定量 (橙) は意図した挙動を示す．

さて，具体的にはこのバイアスはどのように現れ，どうすれば補正できるのだろうか．その問いに対する答えを与えるのが，9 章で導入した EIF である．ATE をターゲットとしたときの EIF の具体形は 9 章で紹介したが，肝心の導出方法はまだ扱っていない．次節では，EIF の導出方法について考えよう．

10.2 Deriving the EIF

9 章では, EIF を pathwise 導関数の Riesz representer として定義した. したがって厳密には, 任意の滑らかなパスに沿ったターゲットの微分を調べ, その線形汎関数を内積表示することで EIF を求めることになる. 最も簡単な例として, 期待値

$$\psi(\mathrm{P}) = \mathrm{E}_{\mathrm{P}}[h(Z)]$$

をターゲットとする場合を考えよう. 任意の滑らかなパス $t \mapsto \mathrm{P}_t$ をとり, その P_0 におけるスコア関数を g とかく. このとき, 支配測度に関する密度 p_t を用いれば,

$$\begin{aligned}
\frac{\partial}{\partial t}\psi(\mathrm{P}_t)\bigg|_{t=0} &= \frac{\partial}{\partial t}\int h(z)p_t(z)\,\mathrm{d}z\bigg|_{t=0} \\
&= \int h(z)\dot{p}_0(z)\,\mathrm{d}z \\
&= \int h(z)g(z)p_0(z)\,\mathrm{d}z \\
&= \mathrm{E}_{\mathrm{P}_0}[h(Z)g(Z)] \\
&= \mathrm{E}_{\mathrm{P}_0}\Big[\big\{h(Z) - \mathrm{E}_{\mathrm{P}_0}[h(Z)]\big\}g(Z)\Big].
\end{aligned}$$

ただし最後の等号では $\mathrm{E}_{\mathrm{P}_0}[g(Z)] = 0$ を用いた. したがって, 定義より EIF は

$$\tilde{\psi}_{\mathrm{P}_0}(Z) = h(Z) - \mathrm{E}_{\mathrm{P}_0}[h(Z)]$$

である. この例では, pathwise 導関数の積分方程式をそのまま解くことが容易である.

しかし一般のターゲットでは, 同じことを直接実行するのは煩雑になりやすい. そこでノンパラメトリックモデルでは, **point mass contamination** によって EIF の候補を先に当てる方法が便利である. アイデアは単純で, 真の分布 P_0 に, ある一点 z へごくわずかな質量を混ぜた分布

$$\mathrm{P}_{\varepsilon,z} := (1-\varepsilon)\mathrm{P}_0 + \varepsilon\delta_z$$

を考え, そのときのターゲットの微分

$$\phi(z) := \frac{\partial}{\partial\varepsilon}\psi(\mathrm{P}_{\varepsilon,z})\bigg|_{\varepsilon=0}$$

を計算する. この $\phi(z)$ が EIF の候補になる.

この方法がうまくいく理由について直観的に述べる. 任意の滑らかなパス $t \mapsto \mathrm{P}_t$ をとり, その P_0 におけるスコア関数を g とかく. このとき, 滑らかなパスは次をみたすように (一般には形式的に) とれる.

$$\mathrm{dP}_t(z) = \{1 + tg(z)\}\mathrm{dP}_0(z) + o(t).$$

したがって, $\mathrm{P}_t - \mathrm{P}_0$ の 1 次の項は

$$t\,g(z)\,\mathrm{dP}_0(z)$$

である．ただし $g \in \mathrm{L}_0^2(\mathrm{P}_0)$ なので $\mathrm{E}_{\mathrm{P}_0}[g(Z)] = 0$ であり, 接ベクトル g はこの摂動について, 全体の質量を変えずに各点でどれだけ質量を移動させるかを表している．

その一方で, point mass contamination による微分

$$\phi(z) = \frac{\partial}{\partial \varepsilon} \psi\big((1-\varepsilon)\mathrm{P}_0 + \varepsilon \delta_z\big)\Big|_{\varepsilon=0}$$

は, 点 z の重みを微小に変化させたときのターゲットの局所的な一階変化率を表している．したがって, 一般のパス $t \mapsto \mathrm{P}_t$ において各点 z で生じる一次の質量変化

$$t\, g(z)\, \mathrm{dP}_0(z)$$

に対して, ターゲットの全体の一階変化は, 各点での寄与

$$\phi(z)\, t\, g(z)\, \mathrm{dP}_0(z)$$

を全体で足し合わせたものとして与えられるはずである．すなわち, 形式的には

$$\psi(\mathrm{P}_t) - \psi(\mathrm{P}_0) \approx t \int \phi(z) g(z)\, \mathrm{dP}_0(z),$$

したがって

$$\frac{\partial}{\partial t} \psi(\mathrm{P}_t)\Big|_{t=0} = \int \phi(z) g(z)\, \mathrm{dP}_0(z) = \mathrm{E}_{\mathrm{P}_0}[\phi(Z) g(Z)].$$

これはまさに 9 章で定義した pathwise 導関数の積分方程式である．EIF は一意であったから, 以上の方法で ϕ を導いて EIF の候補が得られれば, あとはそれが EIF の定義をみたすことを確かめれば十分である, というわけだ．

以下では, この方法を ATE に適用してみよう．$Z = (X, A, Y)$ とし,

$$e(x) := \mathrm{P}_0(A = 1 \mid X = x), \qquad \mu_a(x) := \mathrm{E}_{\mathrm{P}_0}[Y \mid X = x, A = a]$$

とかく．ATE は

$$\psi(\mathrm{P}_0) = \mathrm{E}_{\mathrm{P}_0}\big[\mu_1(X) - \mu_0(X)\big]$$

で与えられる．議論の見通しをよくするため,

$$\psi_1(\mathrm{P}_0) := \mathrm{E}_{\mathrm{P}_0}[\mu_1(X)], \qquad \psi_0(\mathrm{P}_0) := \mathrm{E}_{\mathrm{P}_0}[\mu_0(X)],$$
$$\psi(\mathrm{P}_0) = \psi_1(\mathrm{P}_0) - \psi_0(\mathrm{P}_0)$$

とおき, ぞれぞれの EIF を導出して最後に引き算する．

いま, 摂動に用いる汚染点を $z^\star = (x^\star, a^\star, y^\star)$ とし,

$$\mathrm{P}_{\varepsilon, z^\star} = (1-\varepsilon)\mathrm{P}_0 + \varepsilon \delta_{z^\star}$$

を考える．対応する密度を形式的に

$$p_\varepsilon(y, a, x) = (1-\varepsilon) p_0(y, a, x) + \varepsilon \delta_{y^\star}(y) \delta_{a^\star}(a) \delta_{x^\star}(x)$$

とかく.

まず, $\psi_1(\mathrm{P}_0) = \int \mu_1(x) p_0(x)\,\mathrm{d}x$ に対応する汚染後の量は

$$\psi_1(\mathrm{P}_{\varepsilon,z^\star}) = \int \mu_{1,\varepsilon}(x) p_\varepsilon(x)\,\mathrm{d}x, \qquad \mu_{1,\varepsilon}(x) = \frac{\int y\, p_\varepsilon(y,1,x)\,\mathrm{d}y}{\int p_\varepsilon(y,1,x)\,\mathrm{d}y}.$$

ここで

$$p_\varepsilon(x) = (1-\varepsilon)p_0(x) + \varepsilon\delta_{x^\star}(x)$$

だから,

$$\frac{\partial}{\partial\varepsilon} p_\varepsilon(x)\bigg|_{\varepsilon=0} = \delta_{x^\star}(x) - p_0(x).$$

また, 商の微分法より

$$\begin{aligned}
\frac{\partial}{\partial\varepsilon}\mu_{1,\varepsilon}(x)\bigg|_{\varepsilon=0} &= \frac{\int y\,\frac{\partial}{\partial\varepsilon}p_\varepsilon(y,1,x)\,\mathrm{d}y}{\int p_\varepsilon(y,1,x)\,\mathrm{d}y}\bigg|_{\varepsilon=0} - \frac{\int y\, p_\varepsilon(y,1,x)\,\mathrm{d}y}{\int p_\varepsilon(y,1,x)\,\mathrm{d}y}\cdot\frac{\int \frac{\partial}{\partial\varepsilon}p_\varepsilon(y,1,x)\,\mathrm{d}y}{\int p_\varepsilon(y,1,x)\,\mathrm{d}y}\bigg|_{\varepsilon=0} \\
&= \frac{\delta_{x^\star}(x)\mathbb{1}(a^\star=1)}{e(x)p_0(x)}\big\{y^\star - \mu_1(x)\big\}.
\end{aligned}$$

したがって,

$$\begin{aligned}
\frac{\partial}{\partial\varepsilon}\psi_1(\mathrm{P}_{\varepsilon,z^\star})\bigg|_{\varepsilon=0} &= \int \frac{\partial}{\partial\varepsilon}\mu_{1,\varepsilon}(x)\bigg|_{\varepsilon=0} p_0(x)\,\mathrm{d}x + \int \mu_1(x)\,\frac{\partial}{\partial\varepsilon}p_\varepsilon(x)\bigg|_{\varepsilon=0}\mathrm{d}x \\
&= \int \frac{\delta_{x^\star}(x)\mathbb{1}(a^\star=1)}{e(x)}\big\{y^\star - \mu_1(x)\big\}\,\mathrm{d}x + \int \mu_1(x)\{\delta_{x^\star}(x) - p_0(x)\}\,\mathrm{d}x \\
&= \frac{a^\star}{e(x^\star)}\big\{y^\star - \mu_1(x^\star)\big\} + \mu_1(x^\star) - \psi_1(\mathrm{P}_0).
\end{aligned}$$

よって,

$$\phi_1(z) = \frac{a}{e(x)}\big\{y - \mu_1(x)\big\} + \mu_1(x) - \psi_1(\mathrm{P}_0)$$

が ψ_1 に対応する EIF の候補になる.

$\psi_0(\mathrm{P}_0) = \int \mu_0(x)p_0(x)\,\mathrm{d}x$ についても同様に計算すれば,

$$\phi_0(z) = \frac{1-a}{1-e(x)}\big\{y - \mu_0(x)\big\} + \mu_0(x) - \psi_0(\mathrm{P}_0)$$

を得る. したがって ATE の EIF の候補は

$$\tilde{\psi}_{\mathrm{P}_0}(Z) = \phi_1(Z) - \phi_0(Z)$$

すなわち

$$\tilde{\psi}_{\mathrm{P}_0}(Z) = \frac{A}{e(X)}\big\{Y - \mu_1(X)\big\} - \frac{1-A}{1-e(X)}\big\{Y - \mu_0(X)\big\} + \mu_1(X) - \mu_0(X) - \psi(\mathrm{P}_0)$$

で与えられる.

実はこの候補は, 任意の滑らかなパス $t \mapsto \mathrm{P}_t$ とそのスコア関数 g に対して

$$\frac{\partial}{\partial t}\psi(\mathrm{P}_t)\bigg|_{t=0} = \mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}(Z)g(Z)]$$

をみたす. さらに

$$\mathrm{E}_{\mathrm{P}_0}\left[\frac{A}{e(X)}\{Y-\mu_1(X)\}\,\middle|\,X\right] = \mathrm{E}_{\mathrm{P}_0}\left[\frac{1-A}{1-e(X)}\{Y-\mu_0(X)\}\,\middle|\,X\right] = 0$$

より $\mathrm{E}_{\mathrm{P}_0}[\tilde{\psi}_{\mathrm{P}_0}(Z)] = 0$ でもあるから, 標準的な正則条件の下で $\tilde{\psi}_{\mathrm{P}_0} \in \mathrm{L}_0^2(\mathrm{P}_0)$ が確認できれば, これが ATE の EIF である.

10.3 One-Step Estimation

前節でみた EIF は, 単に効率性下限を記述するための道具ではない. 実は, plug-in 推定量のバイアスがなぜ生じるのか, そしてそれをどのように補正すべきかを説明するのが EIF なのである.

このことをみるため, まず $\hat{\mathrm{P}}_n$ の値をひとまず固定して考える. $\hat{\mathrm{P}}_n$ から P_0 へ向かうパスとして

$$\mathrm{P}_t := (1-t)\hat{\mathrm{P}}_n + t\mathrm{P}_0, \qquad 0 \le t \le 1$$

を考えよう. $\mathrm{P}_0 \ll \hat{\mathrm{P}}_n$ であるとすると, $t=0$ におけるこのパスのスコアは

$$g_n(z) := \frac{\mathrm{dP}_0}{\mathrm{d}\hat{\mathrm{P}}_n}(z) - 1$$

で与えられる. 実際,

$$\mathrm{dP}_t(z) = \{1 + tg_n(z)\}\mathrm{d}\hat{\mathrm{P}}_n(z)$$

であるから, $t=0$ における接ベクトルは g_n である.

したがって, 9 章の pathwise 微分可能性を $\hat{\mathrm{P}}_n$ のまわりで適用すれば,

$$\frac{\partial}{\partial t}\psi(\mathrm{P}_t)\bigg|_{t=0} = \int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)g_n(z)\,\mathrm{d}\hat{\mathrm{P}}_n(z) = \int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z)$$

となる. ただし最後の等号では

$$\int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{d}\hat{\mathrm{P}}_n(z) = 0$$

を用いた. ゆえに, $t=0$ のまわりでは

$$\psi(\mathrm{P}_t) - \psi(\hat{\mathrm{P}}_n) = t\int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z) + R(t,n)$$

という一階近似が成り立つはずである.

ここで $t=1$ としても, 十分大きな n では $\hat{\mathrm{P}}_n$ が P_0 に十分近いと期待されるから, 同様の近似が

$$\psi(\mathrm{P}_0) - \psi(\hat{\mathrm{P}}_n) = \int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z) + R(n)$$

の形で成り立つと考えてみよう．すなわち，

$$\psi(\hat{\mathrm{P}}_n) - \psi(\mathrm{P}_0) = -\int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z) + R(n).$$

このことは, plug-in 推定量のバイアスが

$$-\int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z)$$

によって一次のオーダーで記述されることを意味している．したがって, この項を標本から推定して足し戻せば, 先ほど生じてしまった, plug-in 推定量のバイアスを補正できそうである．

上の議論を一般化したものが **von Mises 展開**である．

Definition 10.2: von Mises 展開

ターゲット写像 $\psi : \mathcal{P} \to \mathbb{R}$ が, ある関数 $\tilde{\psi}_{\mathrm{P}}$ と剰余項 $R_2(\mathrm{P}, \mathrm{Q})$ を用いて

$$\psi(\mathrm{P}) - \psi(\mathrm{Q}) = -\int \tilde{\psi}_{\mathrm{P}}(z)\,\mathrm{dQ}(z) + R_2(\mathrm{P}, \mathrm{Q})$$

とかけるとき, これを ψ の **von Mises 展開**という．ただし

$$\int \tilde{\psi}_{\mathrm{P}}(z)\,\mathrm{dP}(z) = 0$$

を仮定する．

これは, 有限次元の Taylor 展開において一次の導関数の項と高次の剰余項に分かれるのとまったく同じ構造である．ただしここでは, 分布そのものを変数とみなして展開している．EIF は, この一次の項を与える「勾配」にほかならない．

この展開を $\mathrm{P} = \hat{\mathrm{P}}_n, \mathrm{Q} = \mathrm{P}_0$ に適用すると,

$$\psi(\hat{\mathrm{P}}_n) - \psi(\mathrm{P}_0) = -\int \tilde{\psi}_{\hat{\mathrm{P}}_n}(z)\,\mathrm{dP}_0(z) + R_2(\hat{\mathrm{P}}_n, \mathrm{P}_0)$$

となる．ここで右辺第 1 項は P_0 に関する期待値なので, これを経験平均で置き換えて補正項として加えるのが自然である．この発想にもとづいて, one-step estimator を次のように定義する．

Definition 10.3: one-step estimator

$\psi(\mathrm{P}_0)$ の plug-in 推定量 $\psi(\hat{\mathrm{P}}_n)$ と, EIF $\tilde{\psi}_{\hat{\mathrm{P}}_n}$ が与えられているとする．このとき

$$\hat{\psi}_{\mathrm{os}} := \psi(\hat{\mathrm{P}}_n) + \frac{1}{n}\sum_{i=1}^{n} \tilde{\psi}_{\hat{\mathrm{P}}_n}(Z_i)$$

を**ワンステップ推定量** (one-step estimator) という．

定義より,

$$\begin{aligned}\hat{\psi}_{\mathrm{os}} - \psi(\mathrm{P}_0) &= \psi(\hat{\mathrm{P}}_n) + \mathbb{P}_n \tilde{\psi}_{\hat{\mathrm{P}}_n} - \psi(\mathrm{P}_0) \\ &= (\mathbb{P}_n - \mathrm{P}_0)\tilde{\psi}_{\hat{\mathrm{P}}_n} + R_2(\hat{\mathrm{P}}_n, \mathrm{P}_0),\end{aligned}$$

ただし

$$\mathbb{P}_n f := \frac{1}{n}\sum_{i=1}^{n} f(Z_i), \quad \mathrm{P}_0 f := \mathrm{E}_0[f(Z)]$$

とかいた. さらに

$$(\mathbb{P}_n - \mathrm{P}_0)\tilde{\psi}_{\hat{\mathrm{P}}_n} = (\mathbb{P}_n - \mathrm{P}_0)\tilde{\psi}_{\mathrm{P}_0} + (\mathbb{P}_n - \mathrm{P}_0)\{\tilde{\psi}_{\hat{\mathrm{P}}_n} - \tilde{\psi}_{\mathrm{P}_0}\}$$

と分解できるから,

$$\hat{\psi}_{\mathrm{os}} - \psi(\mathrm{P}_0) = S_n + T_n^1 + T_n^2,$$

$$S_n := (\mathbb{P}_n - \mathrm{P}_0)\tilde{\psi}_{\mathrm{P}_0}, \qquad T_n^1 := (\mathbb{P}_n - \mathrm{P}_0)\{\tilde{\psi}_{\hat{\mathrm{P}}_n} - \tilde{\psi}_{\mathrm{P}_0}\}, \qquad T_n^2 := R_2(\hat{\mathrm{P}}_n, \mathrm{P}_0).$$

つまり, この 3 項のそれぞれの漸近挙動を制御すればよい. 第 1 項 S_n は固定された関数 $\tilde{\psi}_{\mathrm{P}_0}$ の標本平均だから, 中心極限定理が直接使える. 第 2 項 T_n^1 は推定された EIF を用いたことに起因する経験過程項である. 第 3 項 T_n^2 は von Mises 展開の剰余項であり, 真の意味でのバイアス項である. したがって, もしも

$$T_n^1 = o_{\mathrm{P}_0}(n^{-1/2}), \qquad T_n^2 = o_{\mathrm{P}_0}(n^{-1/2})$$

が成り立てば,

$$\sqrt{n}\big\{\hat{\psi}_{\mathrm{os}} - \psi(\mathrm{P}_0)\big\} = \frac{1}{\sqrt{n}}\sum_{i=1}^{n} \tilde{\psi}_{\mathrm{P}_0}(Z_i) + o_{\mathrm{P}_0}(1)$$

となる. ゆえに, one-step estimator は漸近正規性をみたすだけでなく, EIF について漸近線形にもなる. 9 章の結果より, これはまさに畳み込み定理の意味で漸近有効な推定量の形である.

問題は, 第 2 項 T_n^1 と第 3 項 T_n^2 をどうやって $o_{\mathrm{P}_0}(n^{-1/2})$ に抑えるかである. しかし, それぞれの項を $o_{\mathrm{P}_0}(n^{-1/2})$ にするための, ターゲットの具体形によらない統一的な方法論は, 少なくとも現状では十分に整備されていない. したがって, ターゲットの形が定まるごとに T_n^1 と T_n^2 の具体形を書き下し, そこから $\hat{\mathrm{P}}_n$ がみたすべき条件を個別に検討する必要がある.

ここでもやはり ATE を例に考えてみよう. ATE の EIF を

$$\varphi(z; \mathrm{P}) = \frac{a}{e(x)}\{y - \mu_1(x)\} - \frac{1-a}{1-e(x)}\{y - \mu_0(x)\} + \mu_1(x) - \mu_0(x) - \psi(\mathrm{P})$$

とかく. また, 未知関数の適当な推定量 $\hat{e}, \hat{\mu}_1, \hat{\mu}_0$ に基づく EIF を $\hat{\mathrm{P}}_n$ で評価したものを

$$\hat{\varphi}(z) := \varphi(z; \hat{\mathrm{P}}_n)$$

とかく. このとき, one-step estimator は

$$\hat{\psi}_{\mathrm{os}} = \psi(\hat{\mathrm{P}}_n) + \mathbb{P}_n \hat{\varphi}(Z)$$

であり, 前節の分解は

$$\hat{\psi}_{\mathrm{os}} - \psi(\mathrm{P}_0) = S_n + T_n^1 + T_n^2$$

with

$$S_n = (\mathbb{P}_n - \mathrm{P}_0)\varphi(Z;\mathrm{P}_0), \qquad T_n^1 = (\mathbb{P}_n - \mathrm{P}_0)\{\hat{\varphi}(Z) - \varphi(Z;\mathrm{P}_0)\},$$

$$T_n^2 = \psi(\hat{\mathrm{P}}_n) - \psi(\mathrm{P}_0) + \int \hat{\varphi}(z)\,\mathrm{dP}_0(z)$$

となる.

ATE では T_n^1 と T_n^2 をさらに具体的に書くことができる. まず, 定数項は $(\mathbb{P}_n - \mathrm{P}_0)$ で消えることに注意すれば,

$$\begin{aligned} T_n^1 = (\mathbb{P}_n - \mathrm{P}_0)\Bigg[&\left(1 - \frac{A}{e(X)}\right)\{\hat{\mu}_1(X) - \mu_1(X)\} + A\{Y - \hat{\mu}_1(X)\}\frac{e(X) - \hat{e}(X)}{e(X)\hat{e}(X)} \\ &- \left(1 - \frac{1-A}{1-e(X)}\right)\{\hat{\mu}_0(X) - \mu_0(X)\} + (1-A)\{Y - \hat{\mu}_0(X)\}\frac{e(X) - \hat{e}(X)}{(1-e(X))(1-\hat{e}(X))}\Bigg]. \end{aligned}$$

一方, T_n^2 については直接計算により

$$T_n^2 = \int \{\hat{e}(x) - e(x)\}\left[\frac{\hat{\mu}_1(x) - \mu_1(x)}{\hat{e}(x)} + \frac{\hat{\mu}_0(x) - \mu_0(x)}{1 - \hat{e}(x)}\right]\mathrm{dP}_0(x)$$

となる. したがって ATE においては, one-step 推定量の振る舞いは, EIF 評価の経験過程項 T_n^1 と, 未知関数の推定誤差の積からなる残差項 T_n^2 の大きさに帰着する.

Controlling T_n^1

T_n^1 の制御にはいくつか方法があるが, 本質的に重要なのは, 「外側の経験分布におけるサンプルへの依存性と, 内側の未知関数のフィッティングにおけるサンプルへの依存性が従属してしまう」という問題にどう対処するかである. ここでは経験過程論にもとづく議論は行わず, **cross-fitting** にもとづく方法だけを紹介する. cross-fitting では, EIF 評価に用いる未知関数の推定のためのサンプルと, 外側の経験分布のためのサンプルを分割して別々に構成し, 役割を入れ替えて最後に足し合わせることで, 上記の従属を回避する.

添字集合 $\{1,\ldots,n\}$ を K 個の fold $I_1,\ldots,I_K$ に分割し, 第 k fold を除いたデータから構成した各未知関数の推定量を

$$\hat{e}^{(-k)}, \qquad \hat{\mu}_1^{(-k)}, \qquad \hat{\mu}_0^{(-k)}$$

とかく. また, それらで EIF を評価したものを

$$\hat{\varphi}^{(-k)}(z) := \varphi\big(z;\hat{\mathrm{P}}_n^{(-k)}\big)$$

とする. このとき, 第 k fold に対応する T_n^1 の項は

$$T_{n,k}^1 := \frac{|I_k|}{n}(\mathbb{P}_{n,k} - \mathrm{P}_0)\{\hat{\varphi}^{(-k)} - \varphi(\,\cdot\,;\mathrm{P}_0)\}$$

とかける．ただし, $\mathbb{P}_{n,k}$ は第 k fold の経験分布である．

ここで重要なのは, $\hat{\varphi}^{(-k)}$ が学習用サンプルのみに依存し, fold I_k 上のサンプルとは条件付きで独立であることである．したがって, 学習用サンプルを固定した下では, $T^1_{n,k}$ は平均 0 の標本平均になっている．実際,

$$\mathrm{E}_{\mathrm{P}_0}\left[(\mathbb{P}_{n,k}-\mathrm{P}_0)\{\hat{\varphi}^{(-k)}-\varphi(\,\cdot\,;\mathrm{P}_0)\}\,\middle|\,\hat{\varphi}^{(-k)}\right]=0$$

であり, さらに条件付き分散は

$$\mathrm{Var}_{\mathrm{P}_0}\left[\sqrt{|I_k|}(\mathbb{P}_{n,k}-\mathrm{P}_0)\{\hat{\varphi}^{(-k)}-\varphi(\,\cdot\,;\mathrm{P}_0)\}\,\middle|\,\hat{\varphi}^{(-k)}\right]\leq\|\hat{\varphi}^{(-k)}-\varphi(\,\cdot\,;\mathrm{P}_0)\|^2_{L^2(\mathrm{P}_0)}$$

で抑えられる．したがって,

$$\|\hat{\varphi}^{(-k)}-\varphi(\,\cdot\,;\mathrm{P}_0)\|_{L^2(\mathrm{P}_0)}=o_{\mathrm{P}_0}(1)$$

が成り立てば, 各 fold において

$$(\mathbb{P}_{n,k}-\mathrm{P}_0)\{\hat{\varphi}^{(-k)}-\varphi(\,\cdot\,;\mathrm{P}_0)\}=o_{\mathrm{P}_0}(|I_k|^{-1/2})$$

となる．K は固定個であり, $|I_k|/n$ は有界だから, これらを足し合わせても

$$T^1_n=o_{\mathrm{P}_0}(n^{-1/2})$$

が従う．

cross-fittin は, T^1_n は「同じデータを二度使うこと」による overfitting の影響を避けたうえで, EIF のフィッティングに関する $L^2(\mathrm{P}_0)$ ノルムの制御へと T^1_n の制御を帰着させている．したがって, どれほど遅いスピードで真の EIF への収束が起きたとしても, cross-fitting をしていれば, 理論的には T^1_n を 0 につぶせるということになる．

Controlling T^2_n

T^2_n は von Mises 展開の剰余項にあたる．一般に, あるターゲットに対して T^2_n を $o_{\mathrm{P}_0}(n^{-1/2})$ に抑えられるかどうかは, そのターゲットの具体形と, 対応する EIF から導かれる剰余項の構造に依存する．したがって, T^2_n については一律の一般論を与えることは難しく, 個別のターゲットごとに具体形を書き下して評価する必要がある．

ATE の場合には, 前節で導いた EIF から

$$T^2_n=\int\{\hat{e}(x)-e(x)\}\left[\frac{\hat{\mu}_1(x)-\mu_1(x)}{\hat{e}(x)}+\frac{\hat{\mu}_0(x)-\mu_0(x)}{1-\hat{e}(x)}\right]\mathrm{dP}_0(x)$$

となる．したがって, overlap 条件

$$\hat{e}(x)\in[\varepsilon,1-\varepsilon]$$

を仮定すれば, Cauchy–Schwarz の不等式より

$$|T^2_n|\leq\frac{1}{\varepsilon}\|\hat{e}-e\|_{L^2(\mathrm{P}_0)}\left(\|\hat{\mu}_1-\mu_1\|_{L^2(\mathrm{P}_0)}+\|\hat{\mu}_0-\mu_0\|_{L^2(\mathrm{P}_0)}\right).$$

したがって,

$$\|\hat{e}-e\|_{L^2(\mathrm{P}_0)}\left(\|\hat{\mu}_1-\mu_1\|_{L^2(\mathrm{P}_0)}+\|\hat{\mu}_0-\mu_0\|_{L^2(\mathrm{P}_0)}\right)=o_{\mathrm{P}_0}(n^{-1/2})$$

が成り立てば,

$$T_n^2=o_{\mathrm{P}_0}(n^{-1/2})$$

となる. 特に

$$\|\hat{e}-e\|_{L^2(\mathrm{P}_0)}=o_{\mathrm{P}_0}(n^{-1/4}),\qquad \|\hat{\mu}_a-\mu_a\|_{L^2(\mathrm{P}_0)}=o_{\mathrm{P}_0}(n^{-1/4})\quad (a=0,1)$$

であれば十分であるが, これは必要条件ではない. 必要なのはあくまで積のオーダーが $o_{\mathrm{P}_0}(n^{-1/2})$ になることであり, それぞれが同じ速度で収束する必要はない. この性質は rate doubly robustness とも呼ばれる.

以上をまとめると, 一般のターゲットについて, cross-fitting を行った下でのワンステップ推定量の漸近線形性は次のように述べられる.

Theorem 10.1: cross-fit one-step estimator

$\{I_1,\dots,I_K\}$ を $K\le C<\infty$ をみたす有限個の fold とする. 各 $k=1,\dots,K$ について, 第 k fold を除いたデータから分布推定量 $\hat{\mathrm{P}}_n^{(-k)}$ を構成し, それに対応する EIF 評価を

$$\varphi\big(\,\cdot\,;\hat{\mathrm{P}}_n^{(-k)}\big)$$

とかく. また,

$$\hat{\psi}_{\mathrm{cf}}:=\sum_{k=1}^{K}\frac{|I_k|}{n}\left[\psi(\hat{\mathrm{P}}_n^{(-k)})+\mathbb{P}_{n,k}\varphi\big(Z;\hat{\mathrm{P}}_n^{(-k)}\big)\right]$$

を cross-fit one-step estimator とする. さらに, 各 $k=1,\dots,K$ について

$$\|\varphi(\,\cdot\,;\hat{\mathrm{P}}_n^{(-k)})-\varphi(\,\cdot\,;\mathrm{P}_0)\|_{L^2(\mathrm{P}_0)}=o_{\mathrm{P}_0}(1)$$

および

$$\sum_{k=1}^{K}\frac{|I_k|}{n}R_2(\hat{\mathrm{P}}_n^{(-k)},\mathrm{P}_0)=o_{\mathrm{P}_0}(n^{-1/2})$$

が成り立つとする. ただし

$$R_2(\mathrm{P},\mathrm{Q}):=\psi(\mathrm{P})-\psi(\mathrm{Q})+\int\varphi(z;\mathrm{P})\,\mathrm{dQ}(z)$$

である. このとき,

$$\hat{\psi}_{\mathrm{cf}}-\psi(\mathrm{P}_0)=(\mathbb{P}_n-\mathrm{P}_0)\varphi(Z;\mathrm{P}_0)+o_{\mathrm{P}_0}(n^{-1/2})$$

が成り立つ. したがって,

$$\sqrt{n}\{\hat{\psi}_{\mathrm{cf}}-\psi(\mathrm{P}_0)\}\overset{0}{\Rightarrow}N\big(0,\mathrm{E}_{\mathrm{P}_0}\left[\varphi(Z;\mathrm{P}_0)^2\right]\big).$$

特に $\hat{\psi}_{\mathrm{cf}}$ は EIF について漸近線形であり, 畳み込み定理の意味で漸近有効である.

Example 10.2: ATE に対する十分条件

ATE の場合には, 未知関数は e, μ_1, μ_0 であり, EIF は

$$\varphi(z;\mathrm{P}) = \frac{a}{e(x)}\{y-\mu_1(x)\} - \frac{1-a}{1-e(x)}\{y-\mu_0(x)\} + \mu_1(x) - \mu_0(x) - \psi(\mathrm{P})$$

で与えられる. overlap 条件

$$e(x), \hat{e}^{(-k)}(x) \in [\varepsilon, 1-\varepsilon]$$

および適当なモーメント条件の下では,

$$\|\varphi(\cdot;\hat{\mathrm{P}}_n^{(-k)}) - \varphi(\cdot;\mathrm{P}_0)\|_{L^2(\mathrm{P}_0)} \lesssim \|\hat{\mu}_1^{(-k)} - \mu_1\|_{L^2(\mathrm{P}_0)} + \|\hat{\mu}_0^{(-k)} - \mu_0\|_{L^2(\mathrm{P}_0)} + \|\hat{e}^{(-k)} - e\|_{L^2(\mathrm{P}_0)}.$$

したがって, 各未知関数の推定量が $L^2(\mathrm{P}_0)$ のノルムで真の関数に収束していれば $T_n^1 = o_{\mathrm{P}_0}(n^{-1/2})$ が従う.
また, 剰余項については

$$|T_n^2| \leq \frac{1}{\varepsilon}\|\hat{e} - e\|_{L^2(\mathrm{P}_0)} \left(\|\hat{\mu}_1 - \mu_1\|_{L^2(\mathrm{P}_0)} + \|\hat{\mu}_0 - \mu_0\|_{L^2(\mathrm{P}_0)}\right)$$

であるから,

$$\|\hat{e} - e\|_{L^2(\mathrm{P}_0)} \left(\|\hat{\mu}_1 - \mu_1\|_{L^2(\mathrm{P}_0)} + \|\hat{\mu}_0 - \mu_0\|_{L^2(\mathrm{P}_0)}\right) = o_{\mathrm{P}_0}(n^{-1/2})$$

が成り立てば $T_n^2 = o_{\mathrm{P}_0}(n^{-1/2})$ となる. したがって, cross-fitting の下で各未知関数の推定量が $L^2(\mathrm{P}_0)$ のノルムで真の関数に収束し, さらに上の積率条件が成り立てば, ATE に対する one-step estimator は EIF について漸近線形である.

ここでは主に ATE に注目して方法論の解説を行ったが, pathwise 微分可能な推定量について同様の議論が可能である.